GenoDjib

Les Journées de la génétique et de la génomique de Djibouti

Introduction à la bioinformatique

Les bases de données biologiques

Ou trouver et utiliser les données du vivant

Romain Guyot

Directeur de Recherche IRD

Djibouti, 9–17 novembre 2026

Déployer la recherche
Partager la science
Transformer l'avenir

CERD

Université de Djibouti

Origine des bases de données biologiques

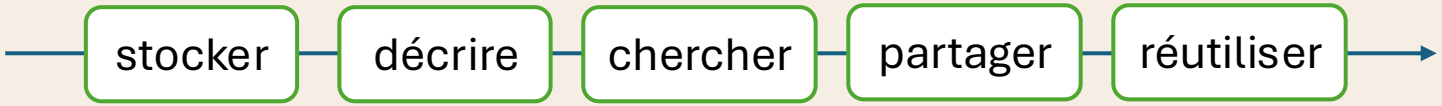


Margaret Dayhoff (1925-1983)

Pionnière dans l'application de méthodes mathématiques et informatiques dans le domaine du vivant.
Elle développe le code aminoacide, la phylogénie protéique, l'organisation des protéines en famille de similarité, le système de base de données aminoacides et nucléotides, …
Développement des outils qui ont permis la fondation de la bioinformatique

Qu’est ce qu’une base de données biologique?

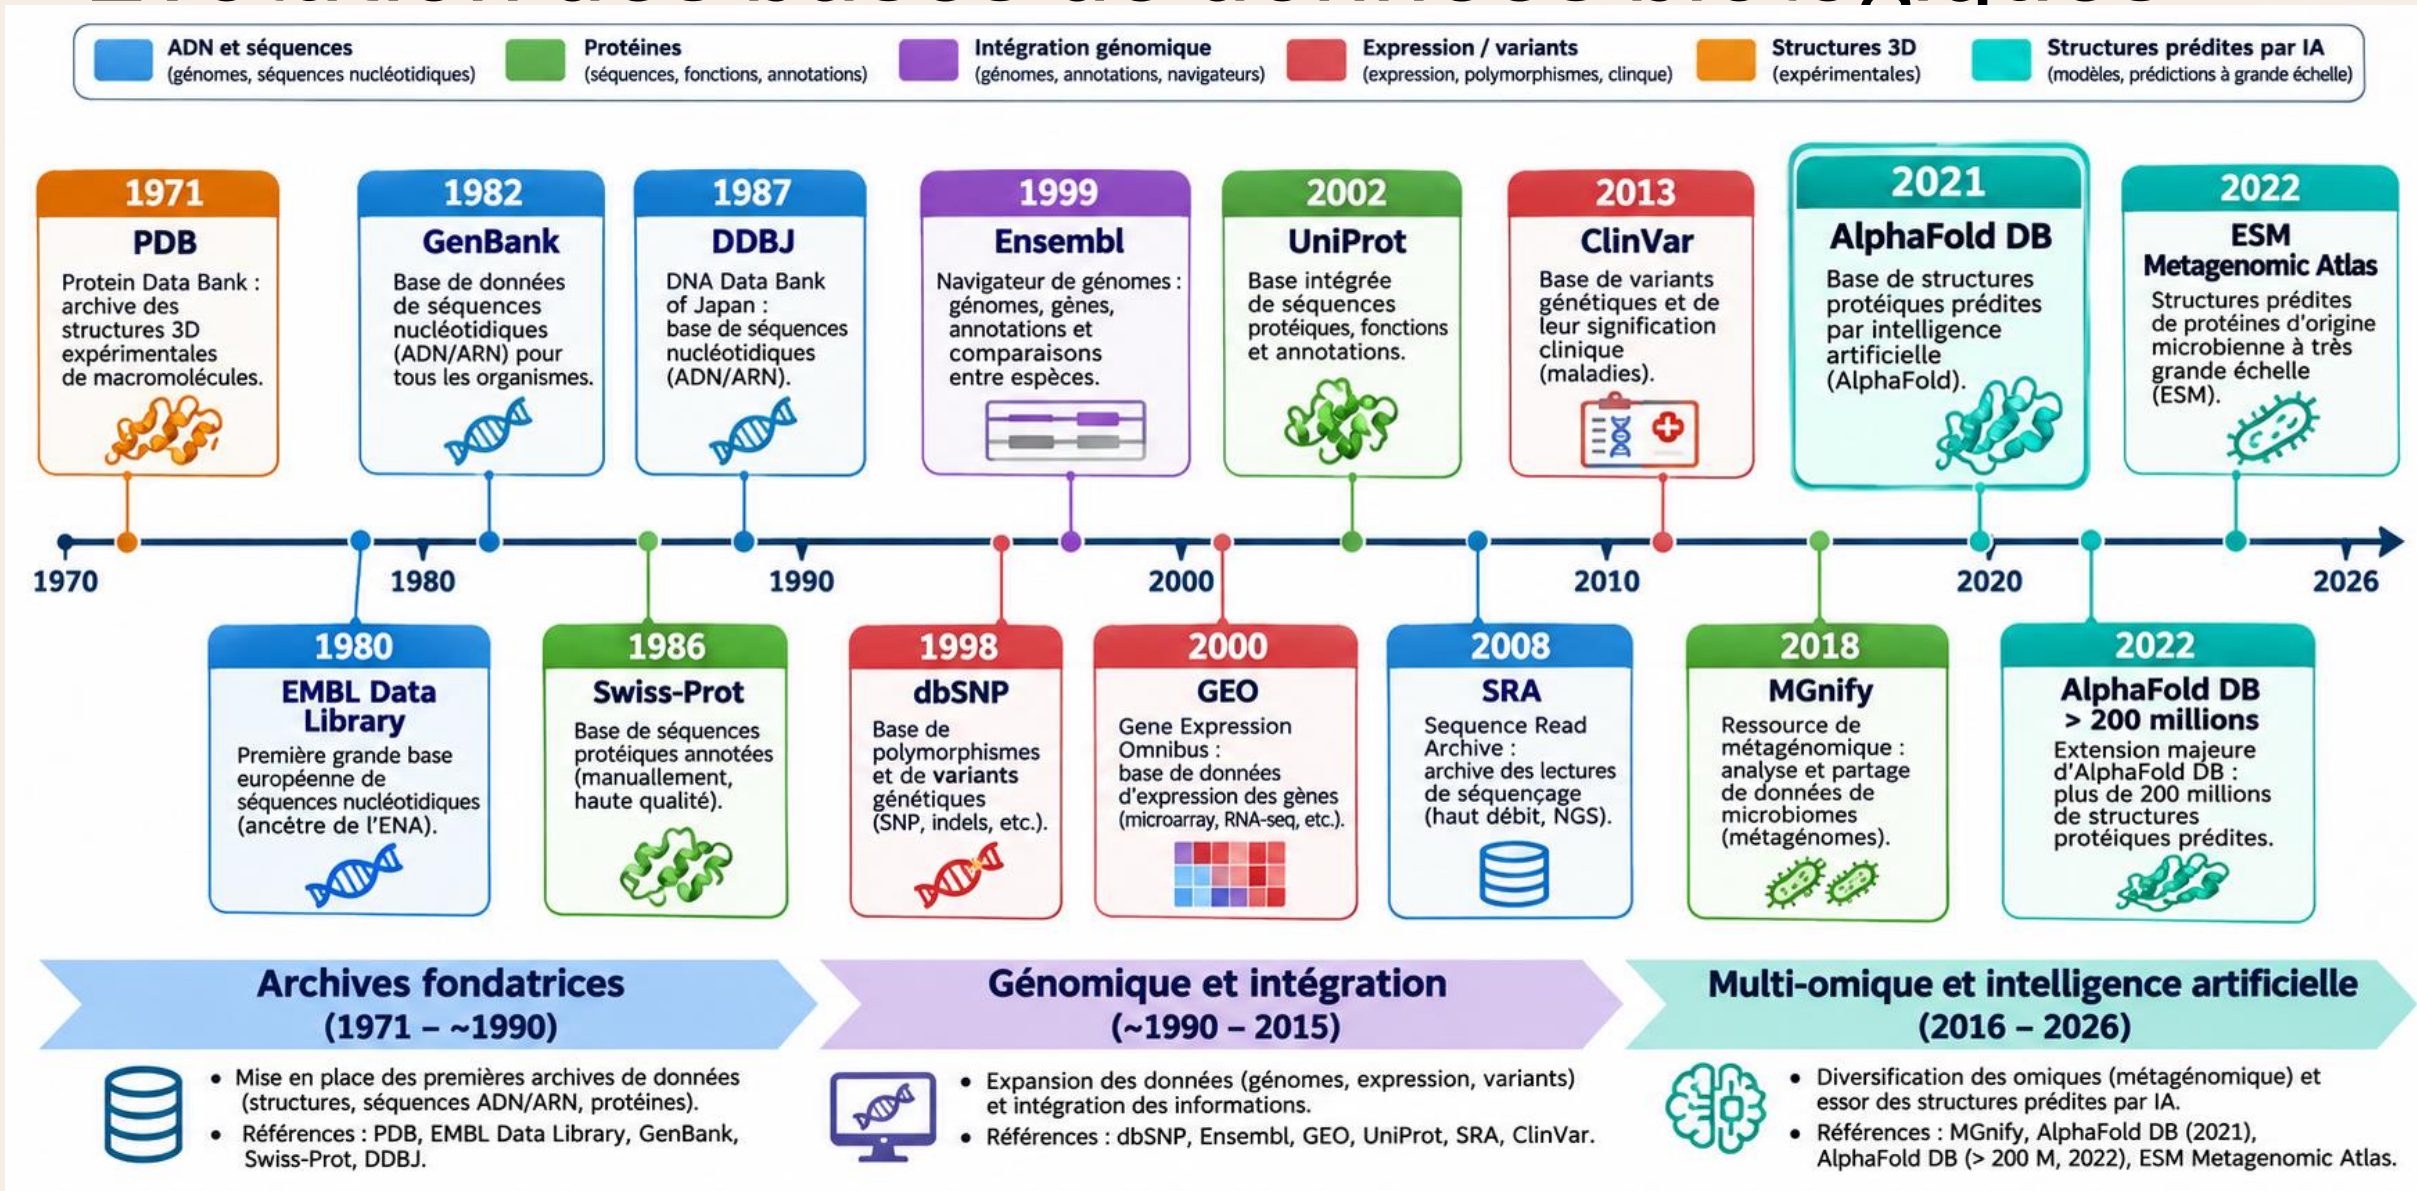
Une collection organisée de données, de métadonnées et d’outil de recherche



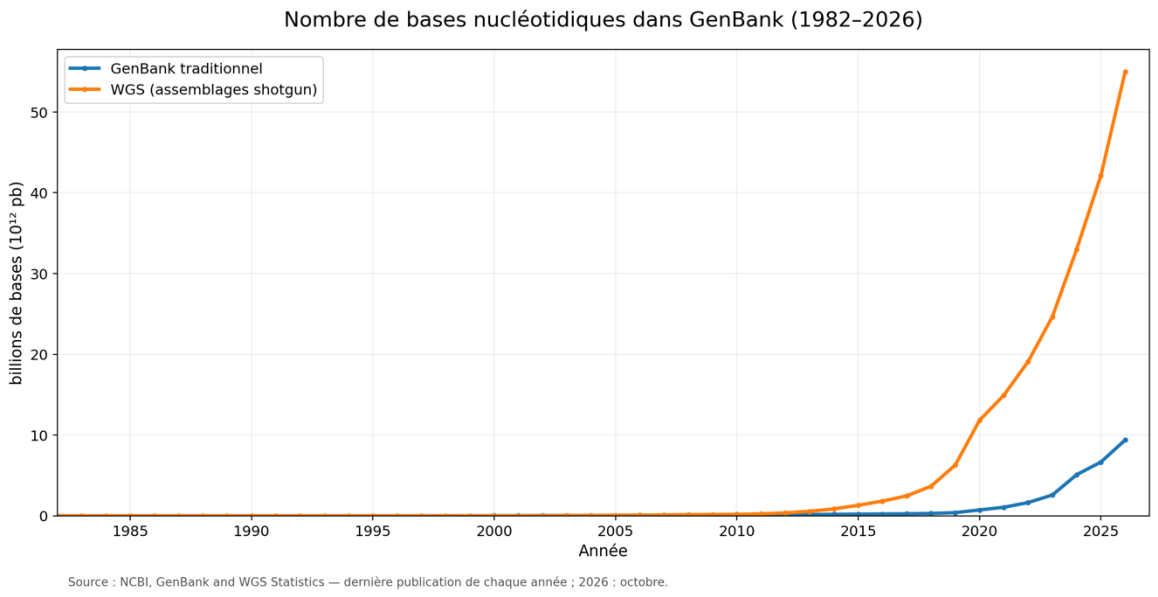
Quel type de données biologiques et quel format

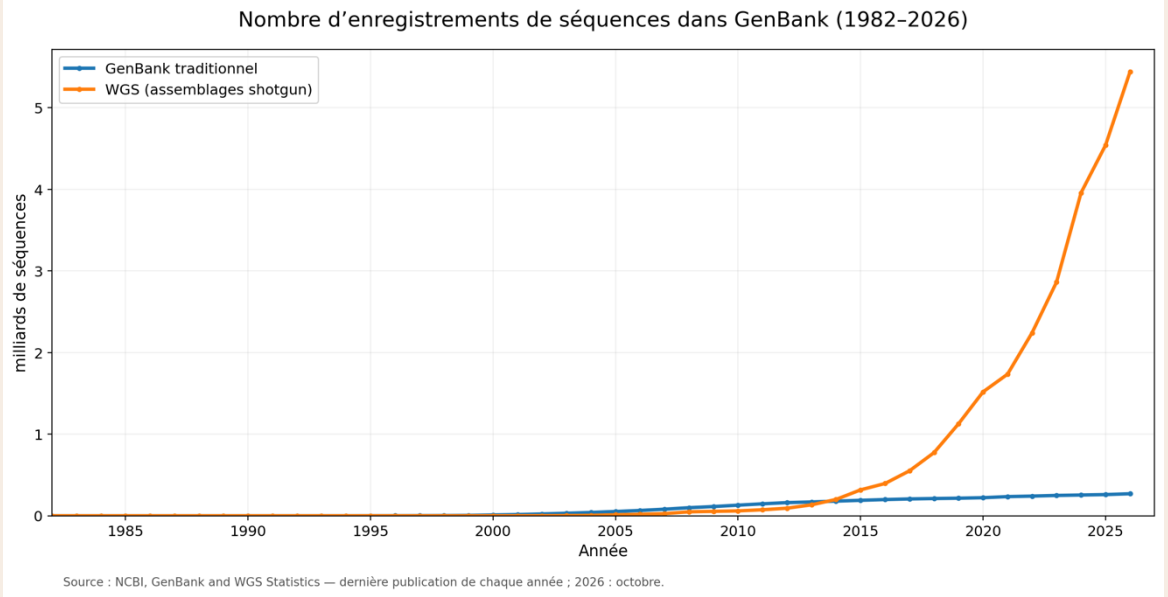
ADN/ARN	séquence de nucléotides	format FASTA ou FASTQ
Génome/gène	coordonnées et annotation	format GFF3, Genbank
Protéines	séquence, fonction et domaines	format FASTA Uniprot
Structure 3D	positions atomiques	format PDB
Expression	quantité de transcrits	format Matrice, GEO
Biodiversité	occurrences, taxonomie	Darwin core, GBIF

Evolution des bases de données biologiques

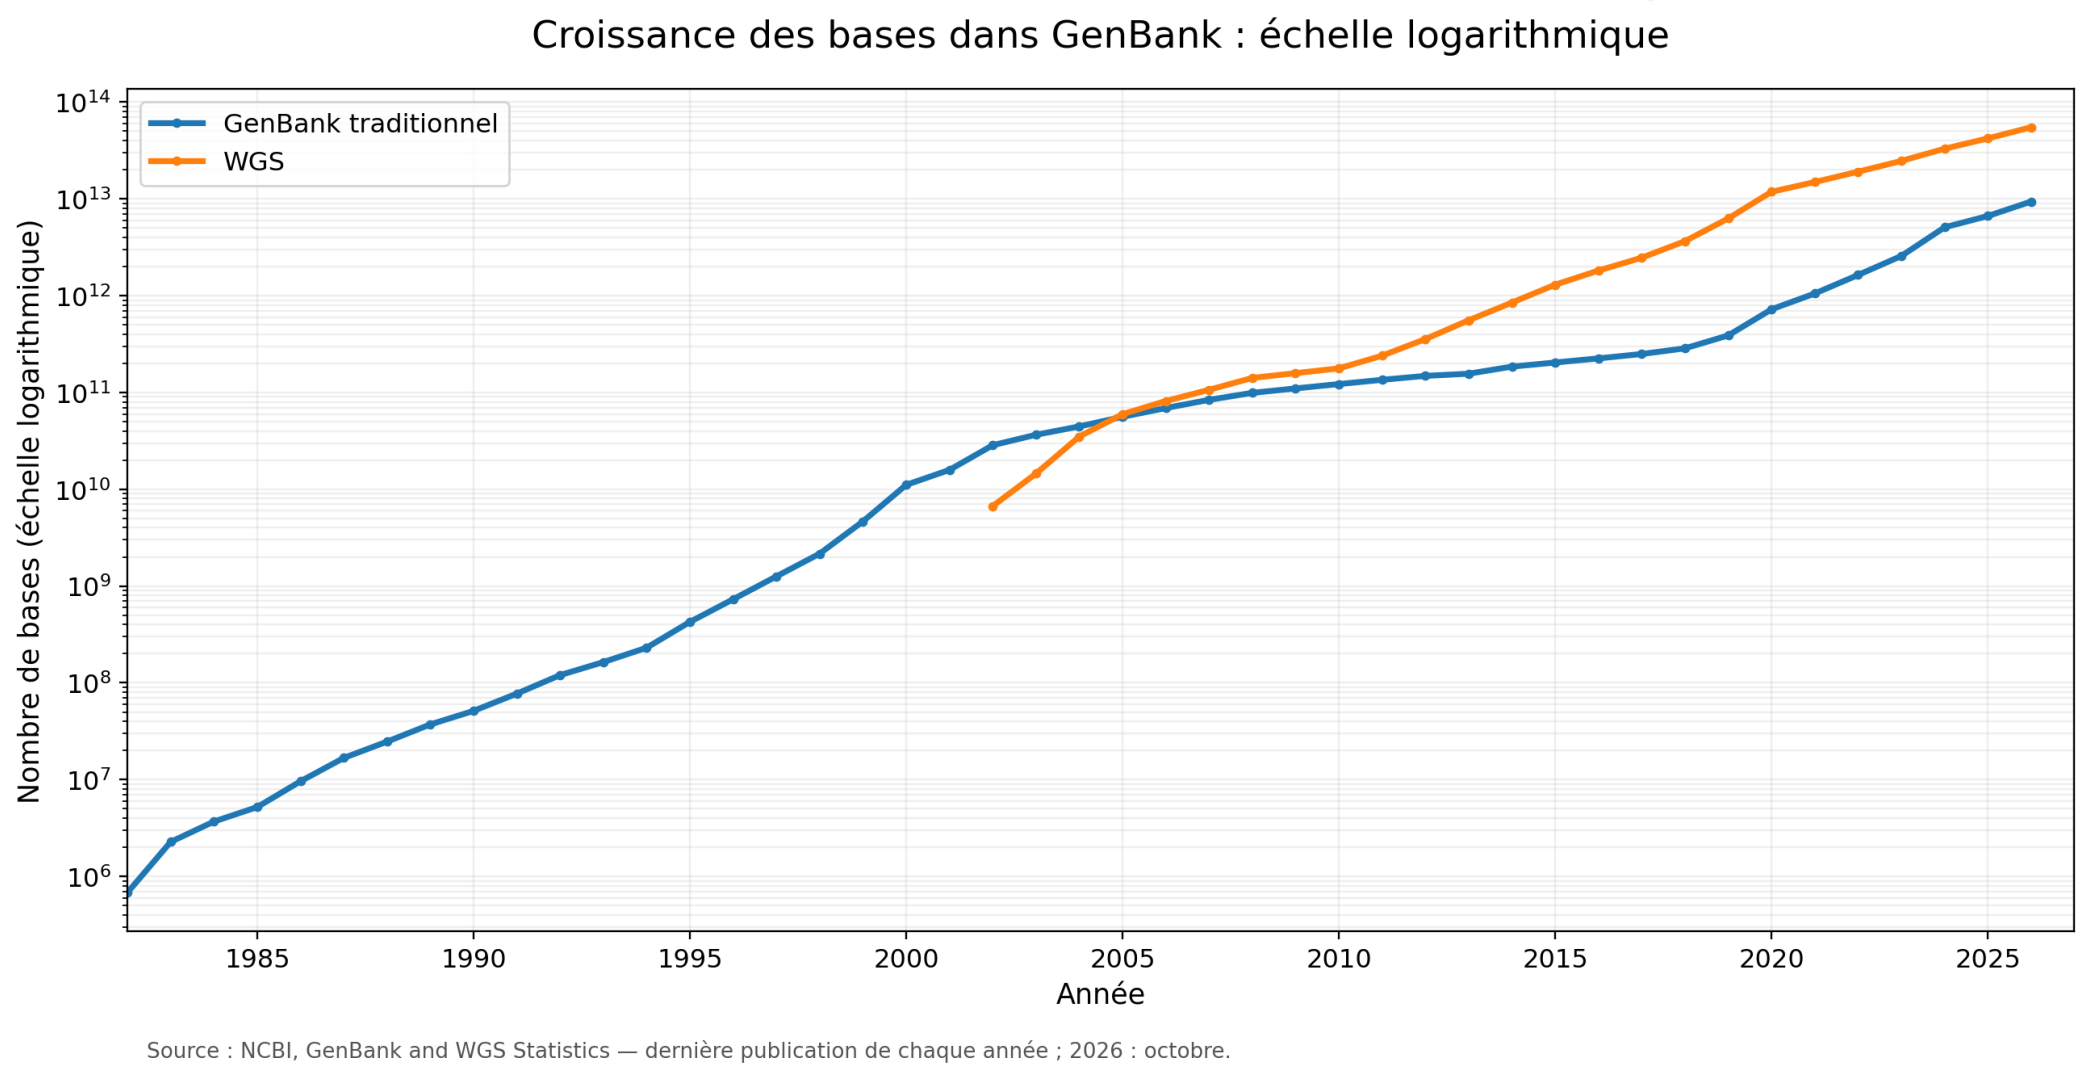


Evolution de GenBank: Le défi du Big Data





Evolution de GenBank: Le défi du Big Data



Source : NCBI, GenBank and WGS Statistics — dernière publication de chaque année ; 2026 : octobre.

Evolution de GenBank: Le défi du Big Data

Au NCBI (*National center for Biotechnology Information*): https://www.ncbi.nlm.nih.gov

GenBank (la division nucléotidique principale, incluant tous les assemblages de génomes validés et le WGS - *Whole Genome Shotgun*) pèse environ **13 021 Go**

La base de données de structure taxonomique du NCBI répertorie le matériel génétique et les génomes de plus de **557 000 espèces formalisées**

Cout du stockage:

Données accessibles: 12 millions/an

Données archivés: 2,4 millions/an

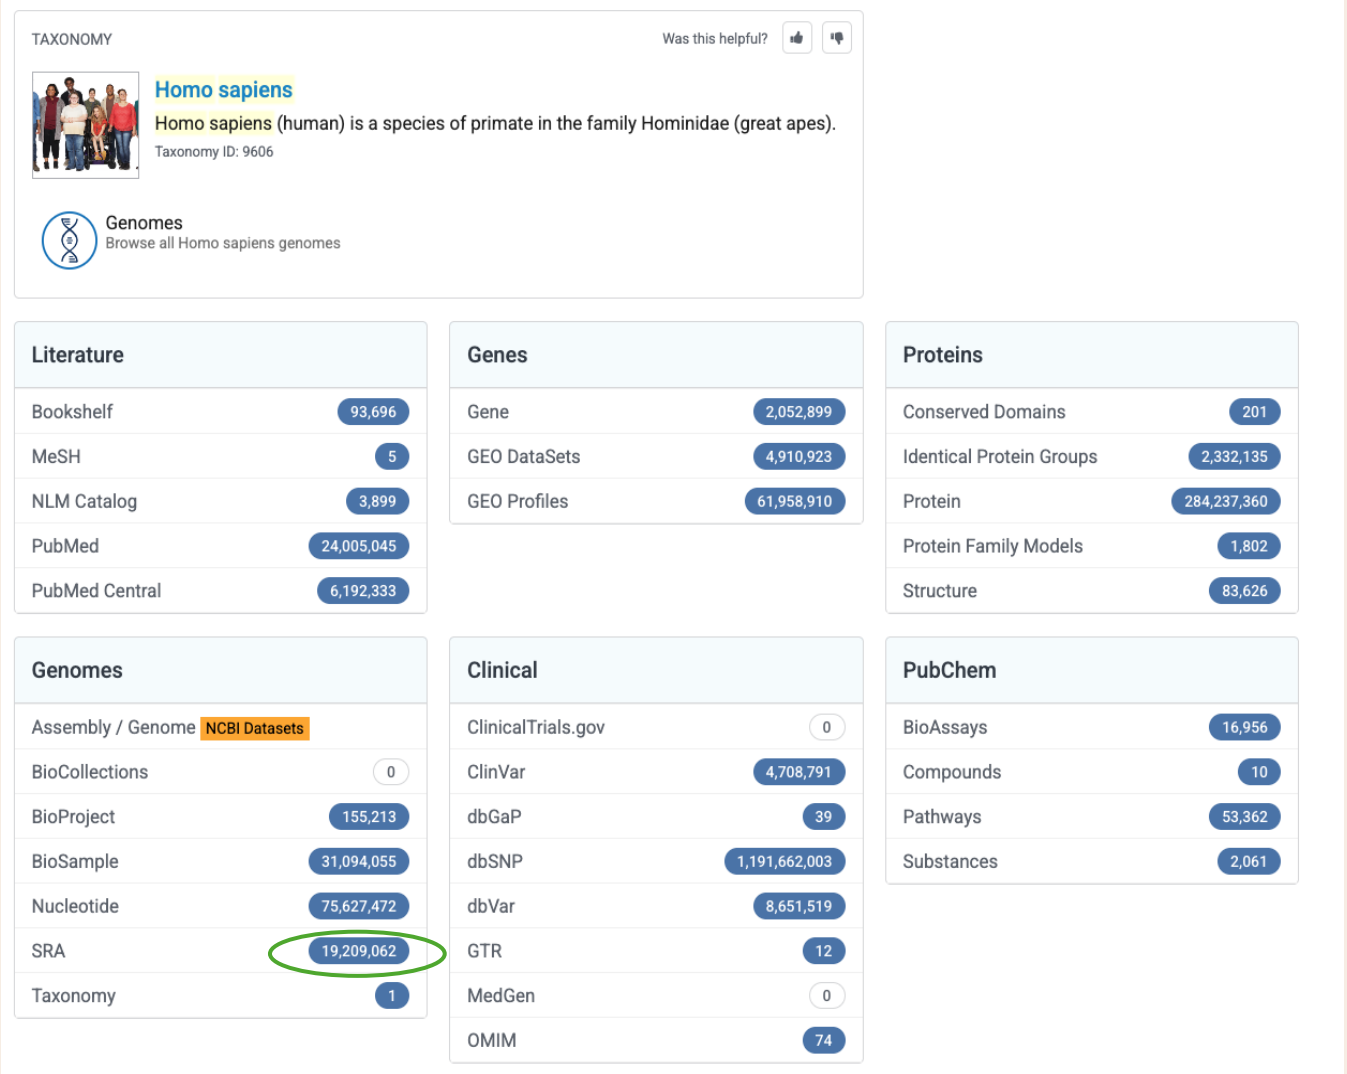
Pas de frais de transfert sortant

Quel type de bases ?

Bases primaires

Ce sont les données déposées par ceux qui les ont produites: lectures brutes de séquençage, génomes, séquences , ...

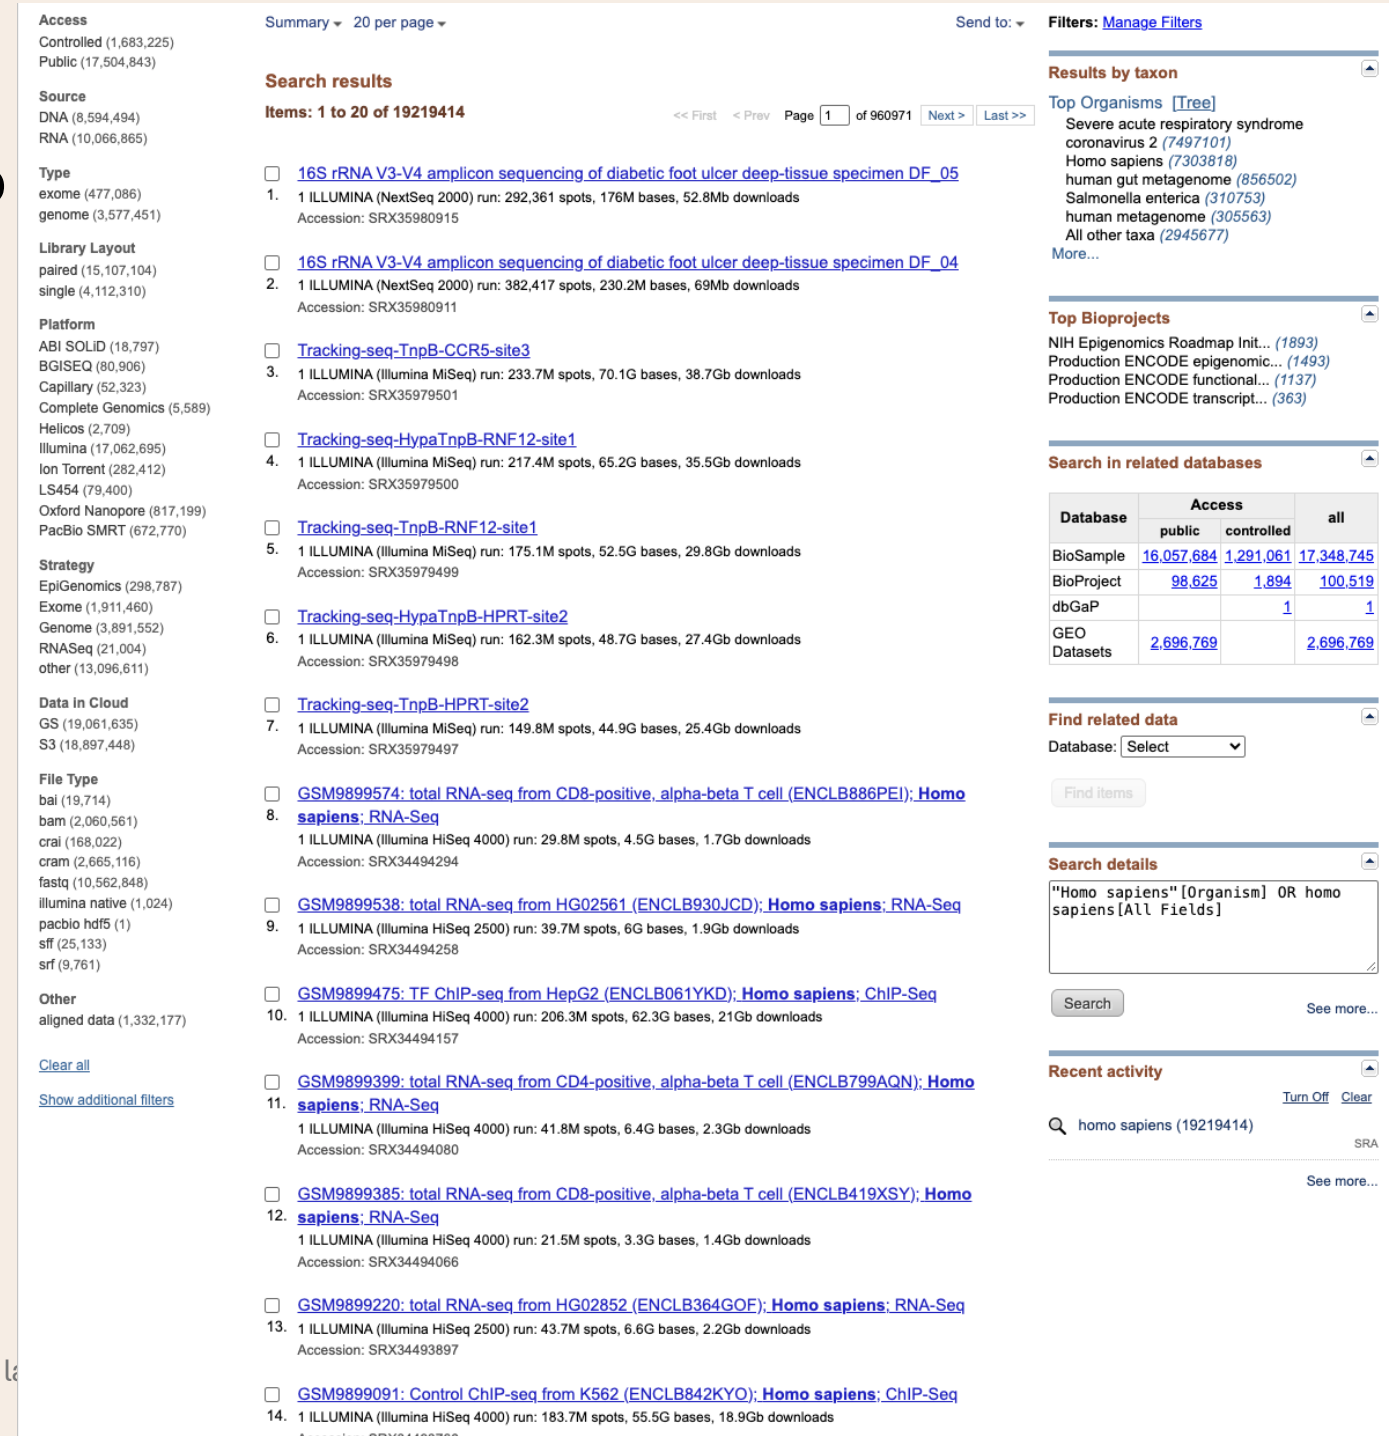
Par exemple SRA, GenBank et ENA



Quel type de bases ?

Bases primaires

Ce sont les données déposées par ceux qui les ont produites: lectures brutes de séquençage, génomes, séquences , ...
Par exemple SRA, GenBank et ENA



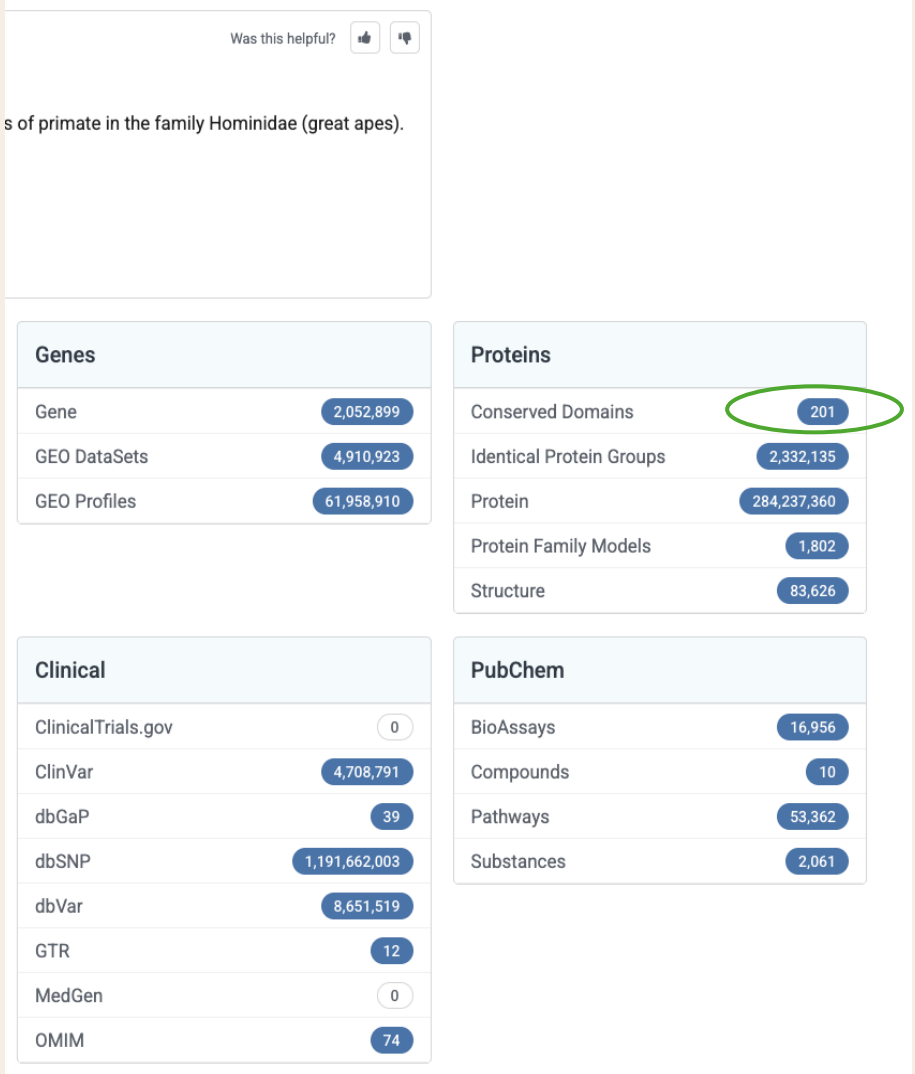
Quel type de bases ?

Bases primaires

Ce sont les données déposées par ceux qui les ont produites: lectures brutes de séquençage, génomes, séquences , ...
Par exemple SRA, GenBank et ENA

Bases secondaires

Ce sont les données analysées: annotations classification produite à partir des données existantes
Par exemple interPro ou NCBI conserved Domain Database



Quel type de bases ?

Bases primaires

Ce sont les données déposées par ceux qui les ont produites: lectures brutes de séquençage, génomes, séquences , ...
Par exemple SRA, GenBank et ENA

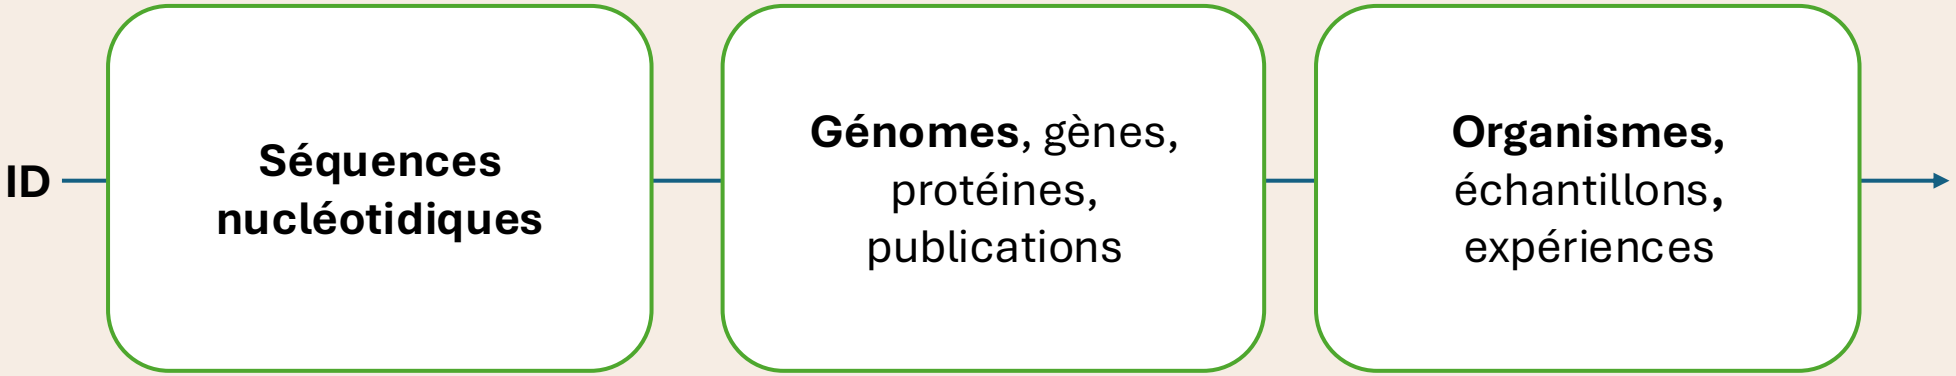
Bases secondaires

Ce sont les données analysées: annotations classification produite à partir des données existantes
Par exemple interPro ou NCBI conserved Domain Database

Bases intégratives

Ce sont les données de plusieurs BD reliées entre elles pour
Par exemple uniprot (Séquences protéiques, domaines, fonctions, structures)**, NCBI gene (**Séquences, fonctions, publications, phénotypes)

NCBI/ GenBank: retrouver des séquences

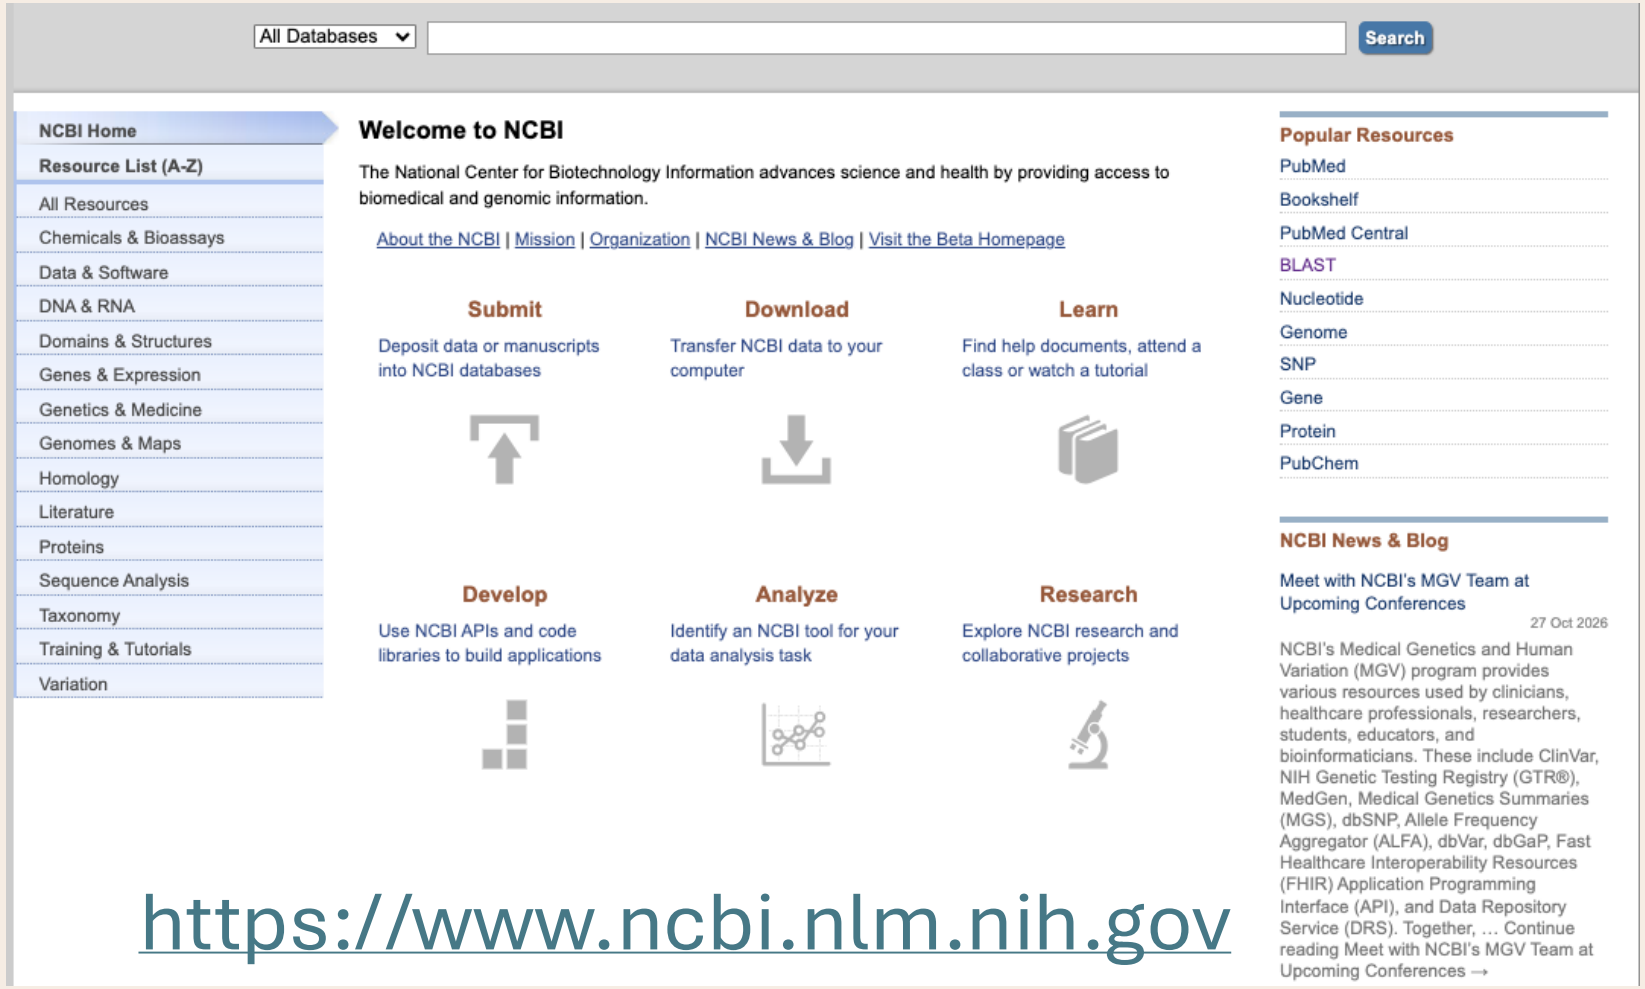


Déposées par la communauté en libre accès

Equivalent européen : ENA/EMBL-EBI

NCBI/ GenBank: retrouver des séquences

NCBI
Une ressource de bases de données intégratives qui inclue
GenBank:
Séquences
Protéines,
Génomes,
Taxonomie,
SNP,



https://www.ncbi.nlm.nih.gov

TD 1- L’identifiant ou ID unique

Ouvrir NCBI Datasets, https://www.ncbi.nlm.nih.gov/
rechercher cet identifiant GCF_036785885

Le nom scientifique de l'organisme.
Le nom et la version de l'assemblage.
La taille du génome.
Le nombre de gènes annotés.
La différence entre accession et version.

4 minutes.





Search NCBI GCF_036785885.1 Search

GenoDjib

Results found in 3 databases

GENOME

Coffea arabica reference genome Coffea Arabica ET-39 HiFi
Submitted by Coffee Consortium (February 2024)
RefSeq: GCF_036785885.1

- **Genomes** — Browse all Coffea arabica genomes
- **Genes** — Browse and download annotated genes
- **Genome Data Viewer** — Browse the reference genome
- **BLAST** — Search the reference sequence

Literature	
Bookshelf	0
MeSH	0
NLM Catalog	0
PubMed	0
PubMed Central	4

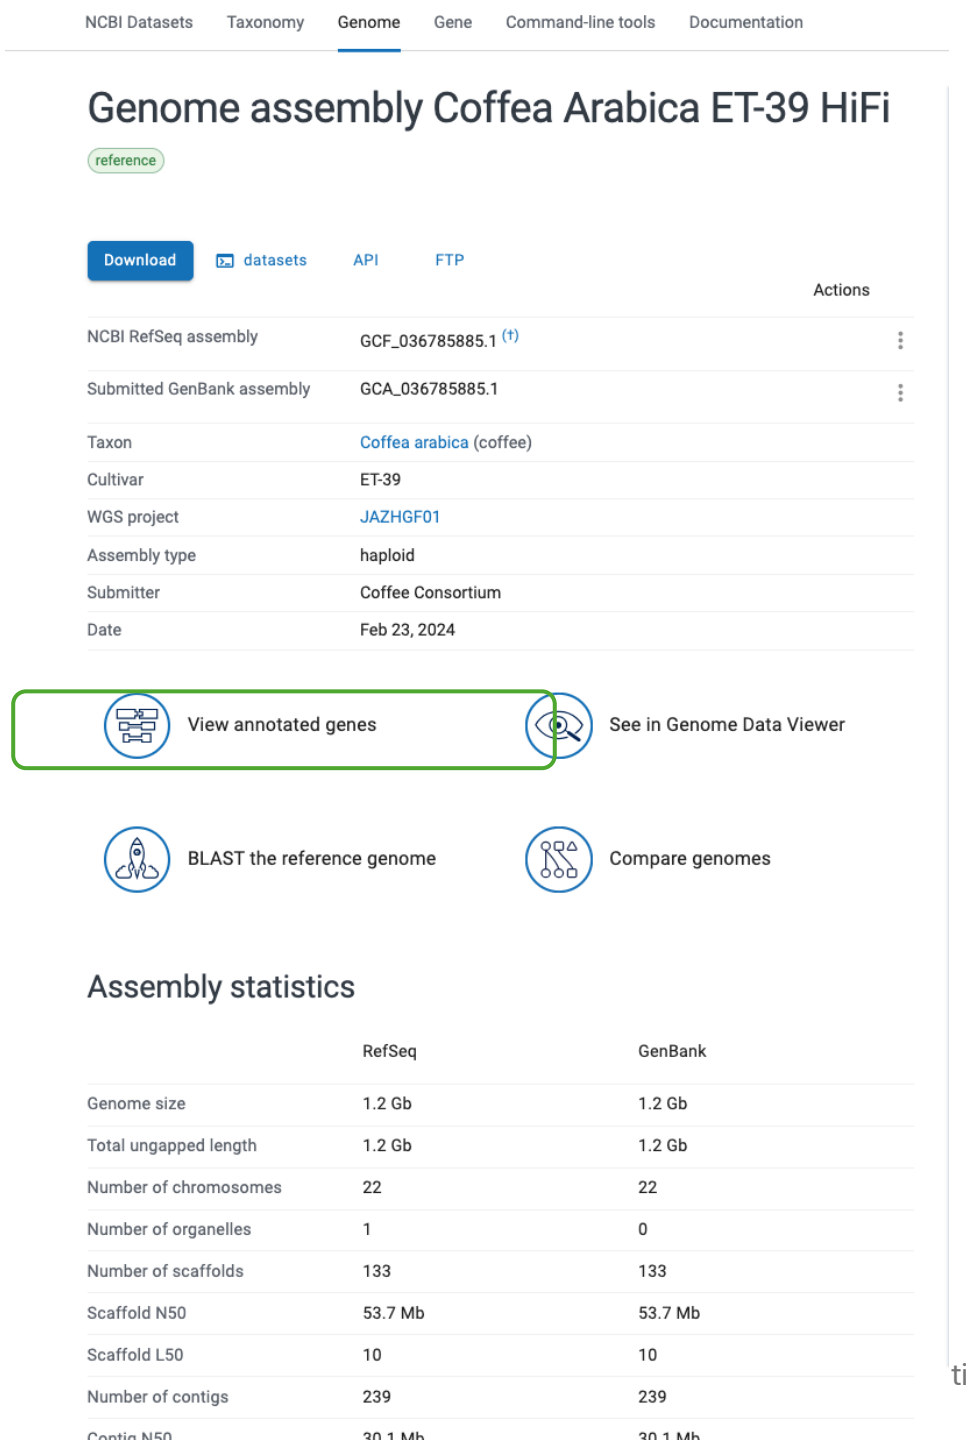
Genes	
Gene	80,883
GEO DataSets	0
GEO Profiles	0

Proteins	
Conserved Domains	0
Identical Protein Groups	0
Protein	0
Protein Family Models	0
Structure	0

Genomes	
Assembly / Genome NCBI Datasets	1
BioCollections	0
BioProject	0
BioSample	0
Nucleotide	0
SRA	0
Taxonomy	0

Clinical	
ClinicalTrials.gov	0
ClinVar	0
dbGaP	0
dbSNP	0
dbVar	0
GTR	0
MedGen	0
OMIM	0

PubChem	
BioAssays	0
Compounds	0
Pathways	0
Substances	0



NCBI Datasets Taxonomy Genome Gene Command-line tools Documentation

Genome assembly Coffea Arabica ET-39 HiFi

reference

Download datasets API FTP

		Actions
NCBI RefSeq assembly	GCF_036785885.1 (†)	
Submitted GenBank assembly	GCA_036785885.1	
Taxon	Coffea arabica (coffee)	
Cultivar	ET-39	
WGS project	JAZHGF01	
Assembly type	haploid	
Submitter	Coffee Consortium	
Date	Feb 23, 2024	

View annotated genes

See in Genome Data Viewer

BLAST the reference genome

Compare genomes

Assembly statistics

	RefSeq	GenBank
Genome size	1.2 Gb	1.2 Gb
Total ungapped length	1.2 Gb	1.2 Gb
Number of chromosomes	22	22
Number of organelles	1	0
Number of scaffolds	133	133
Scaffold N50	53.7 Mb	53.7 Mb
Scaffold L50	10	10
Number of contigs	239	239
Contig N50	30.1 Mb	30.1 Mb

L’identifiant ou ID

Identifiant unique servant à retourner un enregistrement. Par exemple sur le NCBI: https://www.ncbi.nlm.nih.gov/

Recherchons **LOC113707649**

Retrouvons sa séquence protéique au format FASTA

RecName: Full=Probable caffeine synthase 4; Short=CtCS4; AltName: Full=Methyltransferase-like 1; Short=CaMTL1

UniProtKB/Swiss-Prot: Q9AVL9.1

Identical Proteins FASTA Graphics

Go to:

```
LOCUS       CS4_COFAR               385 aa            linear   PLN 02-SEP-2026
DEFINITION  RecName: Full=Probable caffeine synthase 4; Short=CtCS4; AltName:
            Full=Methyltransferase-like 1; Short=CaMTL1.
ACCESSION   Q9AVL9
VERSION     Q9AVL9.1
DBSOURCE    UniProtKB: locus CS4_COFAR, accession Q9AVL9;
            class: standard.
            extra accessions:A0A096X776,Q8H0F8
            created: May 3, 2011.
            sequence updated: Jun 1, 2001.
            annotation updated: Sep 2, 2026.
            xrefs: AB039725.1, BAB39213.1, AB054843.1, BAC43759.1, KF743059.1,
            AHA82523.1
            xrefs (non-sequence databases): AlphaFoldDB:Q9AVL9, SMR:Q9AVL9,
            Proteomes:UP001652660, GO:0008168, Gene3D:1.10.1200.270,
            Gene3D:3.40.50.150, InterPro:IPR005299, InterPro:IPR042086,
            InterPro:IPR029063, PANTHER:PTHR31009, Pfam:PF03492,
            SUPFAM:SSF53335
KEYWORDS    Alkaloid metabolism; Magnesium; Metal-binding; Methyltransferase;
            Reference proteome; S-adenosyl-L-methionine; Transferase.
SOURCE      Coffea arabica (coffee)
  ORGANISM  Coffea arabica
            Eukaryota; Viridiplantae; Streptophyta; Embryophyta; Tracheophyta;
            Spermatophyta; Magnoliopsida; eudicotyledons; Gunneridae;
            Pentapetalae; asterids; lamiids; Gentianales; Rubiaceae;
            Ixoroideae; Gardenieae complex; Bertiereae - Coffeeae clade;
            Coffeeae; Coffea.
REFERENCE   1  (residues 1 to 385)
  AUTHORS   Ogawa,M., Herai,Y., Koizumi,N., Kusano,T. and Sano,H.
  TITLE     7-Methylxanthine methyltransferase of coffee plants. Gene isolation
            and enzymatic properties
  JOURNAL   J Biol Chem 276 (11), 8213-8218 (2001)
   PUBMED   11108716
  REMARK    NUCLEOTIDE SEQUENCE [MRNA], AND TISSUE SPECIFICITY.;
            STRAIN=cv. Caturra
REFERENCE   2  (residues 1 to 385)
  AUTHORS   Mizuno,K., Okuda,A., Kato,M., Yoneyama,N., Tanaka,H., Ashihara,H.
            and Fujimura,T.
  TITLE     Isolation of a new dual-functional caffeine synthase gene encoding
            an enzyme for the conversion of 7-methylxanthine to caffeine from
            coffee (Coffea arabica L.)
  JOURNAL   FEBS Lett 534 (1-3), 75-81 (2003)
   PUBMED   12527364
  REMARK    NUCLEOTIDE SEQUENCE [MRNA].
REFERENCE   3  (residues 1 to 385)
  AUTHORS   Perrois,C., Strickler,S.R., Mathieu,G., Lepelley,M., Bedon,L.,
            Michaux,S., Husson,J., Mueller,L. and Privat,I.
  TITLE     Differential regulation of caffeine metabolism in Coffea arabica
            (Arabica) and Coffea canephora (Robusta)
  JOURNAL   Planta 241 (1), 179-191 (2015)
   PUBMED   25249475
  REMARK    NUCLEOTIDE SEQUENCE [GENOMIC DNA], GENE FAMILY, AND NOMENCLATURE.;
            STRAIN=cv. ET39
COMMENT     On May 6, 2011 this sequence version replaced gi:75151769.
            [FUNCTION] May be involved in the biosynthesis of caffeine.
            {ECO:0000250|UniProtKB:Q8H0D2}.
            [COFACTOR] Name=Mg(2+); Xref=ChEBI:CHEBI:18420;
            Evidence={ECO:0000250|UniProtKB:Q9FLN8}; Note=Binds 1 Mg(2+) ion
            per subunit. {ECO:0000250|UniProtKB:Q9FLN8}.
            [PATHWAY] Alkaloid biosynthesis. {ECO:0000250|UniProtKB:Q8H0D2}.
            [TISSUE SPECIFICITY] Expressed in roots, stems, young and old
            leaves. {ECO:0000269|PubMed:11108716}.
            [SIMILARITY] Belongs to the methyltransferase superfamily. Type-7
            methyltransferase family. {ECO:0000305}.
FEATURES             Location/Qualifiers
     source          1..385
                     /organism="Coffea arabica"
                     /db_xref="taxon:13443"
     gene            1..385
                     /gene="CS4"
                     /gene_synonym="MTL1"
     Protein         1..385
                     /product="Probable caffeine synthase 4"
                     /EC_number="2.1.1.-"
```

Customize view

Analyze this sequence

Run BLAST

Identify Conserved Domains

Highlight Sequence Features

Find in this Sequence

More about the gene LOC113707649

LOC113707649 gene

Also Known As: CS4, CTgS2, CaMTL1, CtC...

Related information

PubMed

Taxonomy

CDD Search Results

Conserved Domains (Concise)

Conserved Domains (Full)

Domain Relatives

Gene

Protein (RefSeq)

Recent activity

Turn Off Clear

RecName: Full=Probable caffeine synthase 4; Short=CtCS4; AltName: Full=MethylT Protein

GCF_036785885.1 AND (alive[prop]) (80883) Gene

LOC113707649 [Coffea arabica] Gene

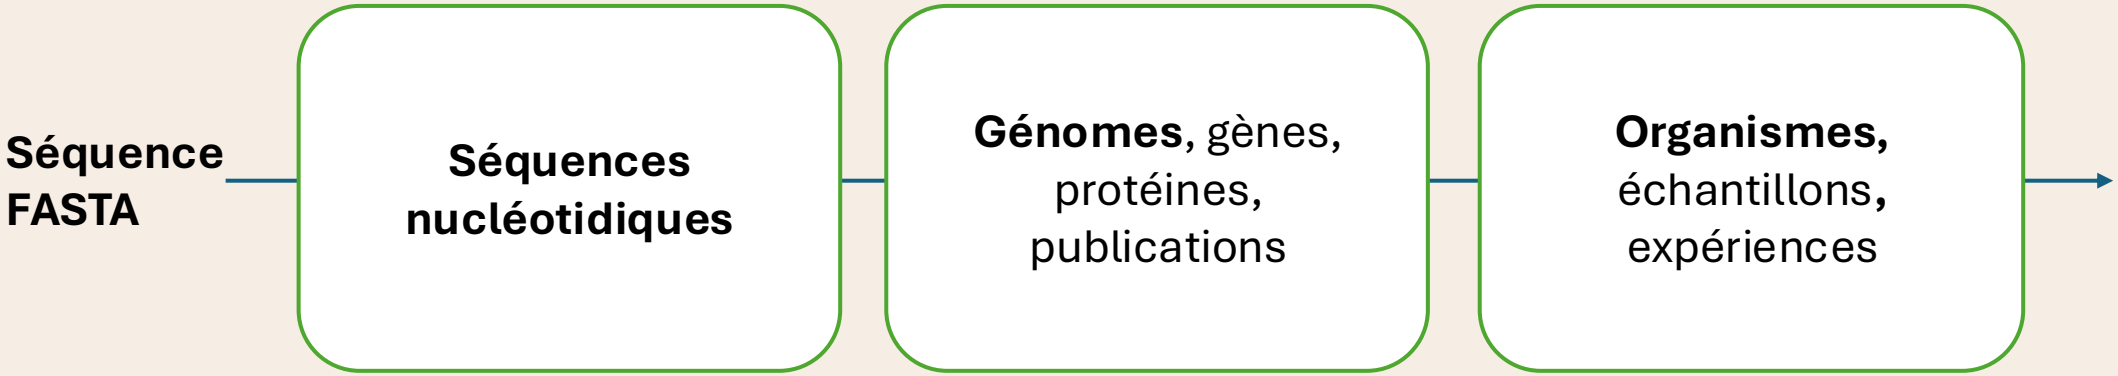
LOC113707649 AND (alive[prop]) (1) Gene

caffeine synthase coffea AND (alive[prop]) (25) Gene

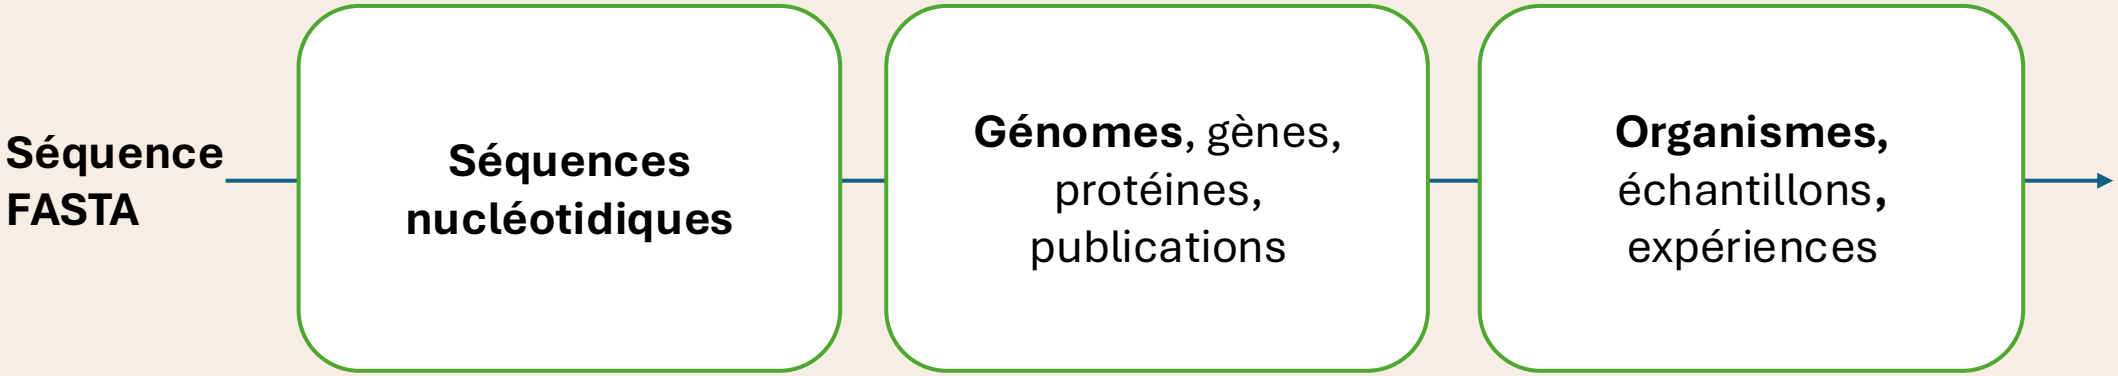
See more...

>NP_001413593.1 probable caffeine synthase 4 [Coffea arabica]
MELQEVLHMNGGEGEASYAKNSSFNQLVLAKVKPVLEQCVRELLRANLPNINKCIKVADLGCASGPNTLL
TVWDTVQSIDKVRQEMKNELERPTIQVFLTDLFQNDFNSVFMLLPSFYRKLEKENGRKIGSCLIAAMPGS
FHGRLFPEESMHFLHSSYSLQFLSQVPSGLVTELGITANKRSIYSSKASPPPVQKAYLDQFTKDFTTFLR
MRSEELLSRGRMLLTCICKGDECDGPNTMDLLEMAINDLVVEGRLGEEKLDSFNVPIYTASVEEVKCMVE
EEGSFEILYLQTFKLRYDAGFSIDDDCQVRSHSPVYSDEHARAAHVASLIRSVYEPILASHFGEAIIPDI
FHRFATNAAKVIRLGKGFYNNLIISLAKKPEKSDI

NCBI/ GenBank: retrouver des séquences

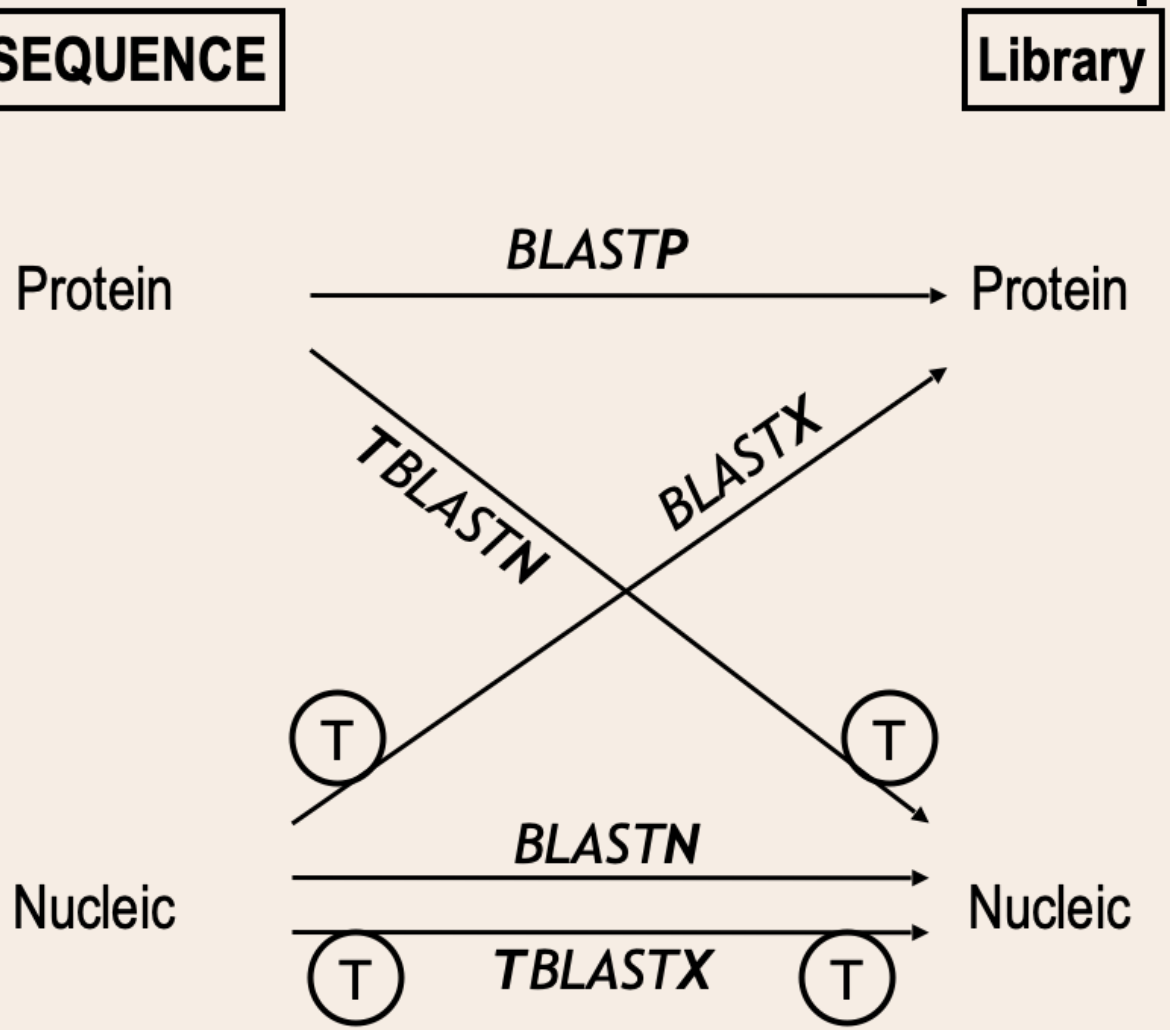


NCBI/ GenBank: BLAST identifier par similarité



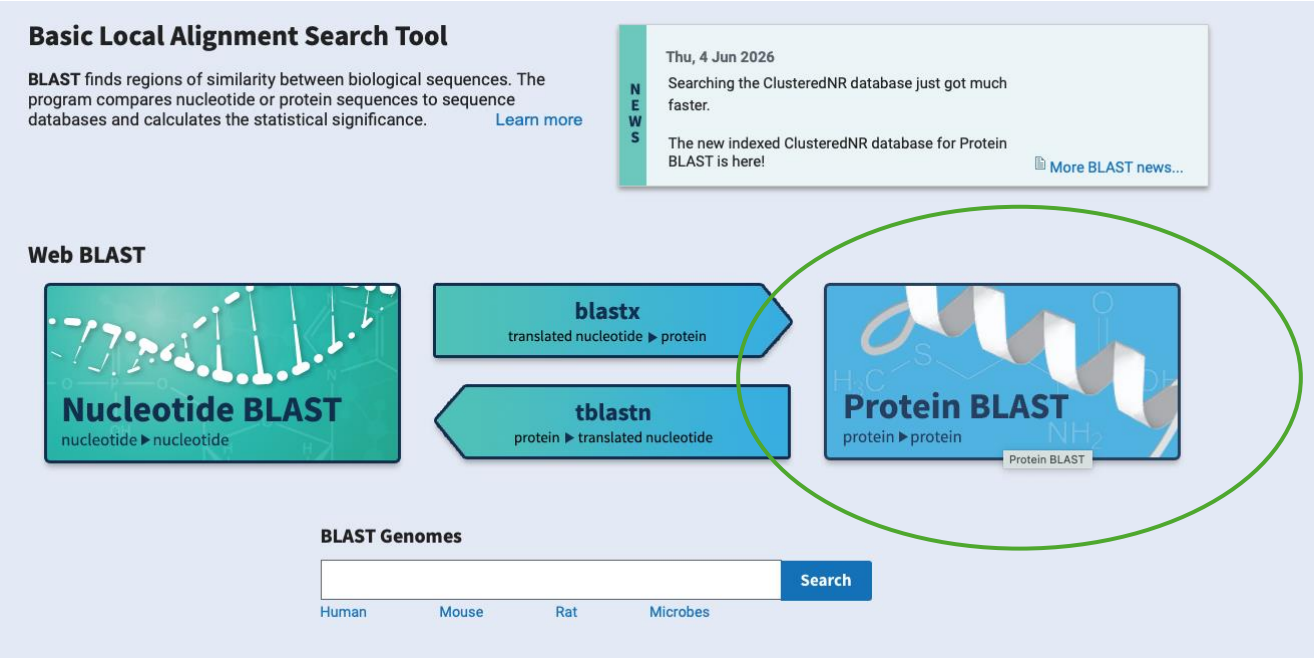
BLAST: *Basic Local Alignment Tool*
permet de rechercher dans une base de données des séquences d'ADN ou de protéines qui ressemblent à une séquence que l'on possède.
Il recherche de petits segment similaires entre la séquence soumise et la base de donnée, puis étend les correspondances et enfin évalue la qualité de l'alignement avec un score de probabilité

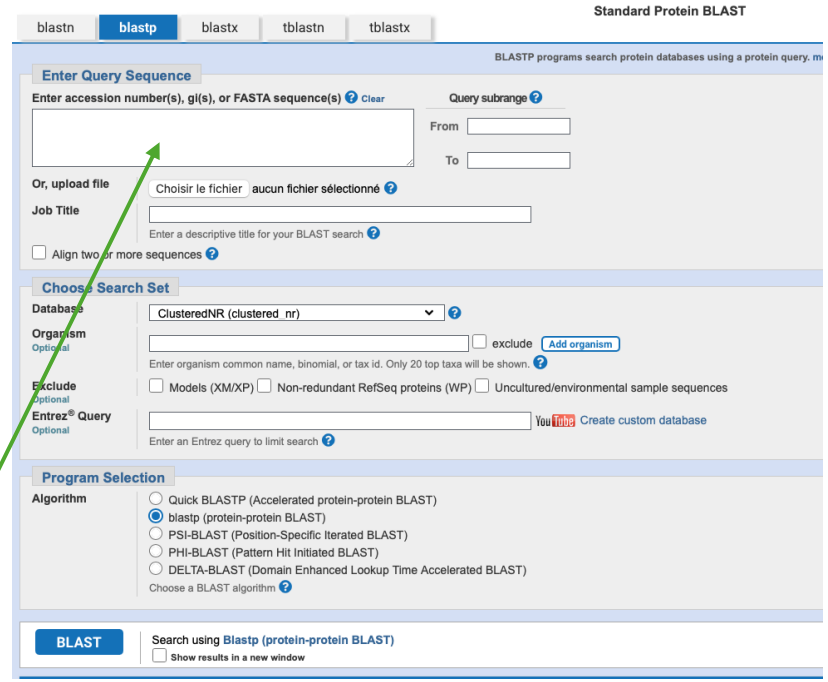
NCBI/ GenBank: BLAST identifier par similarité



TD - 2 BLAST identifier par similarité

Cas pratique: Etudier le gène de la caféine synthase



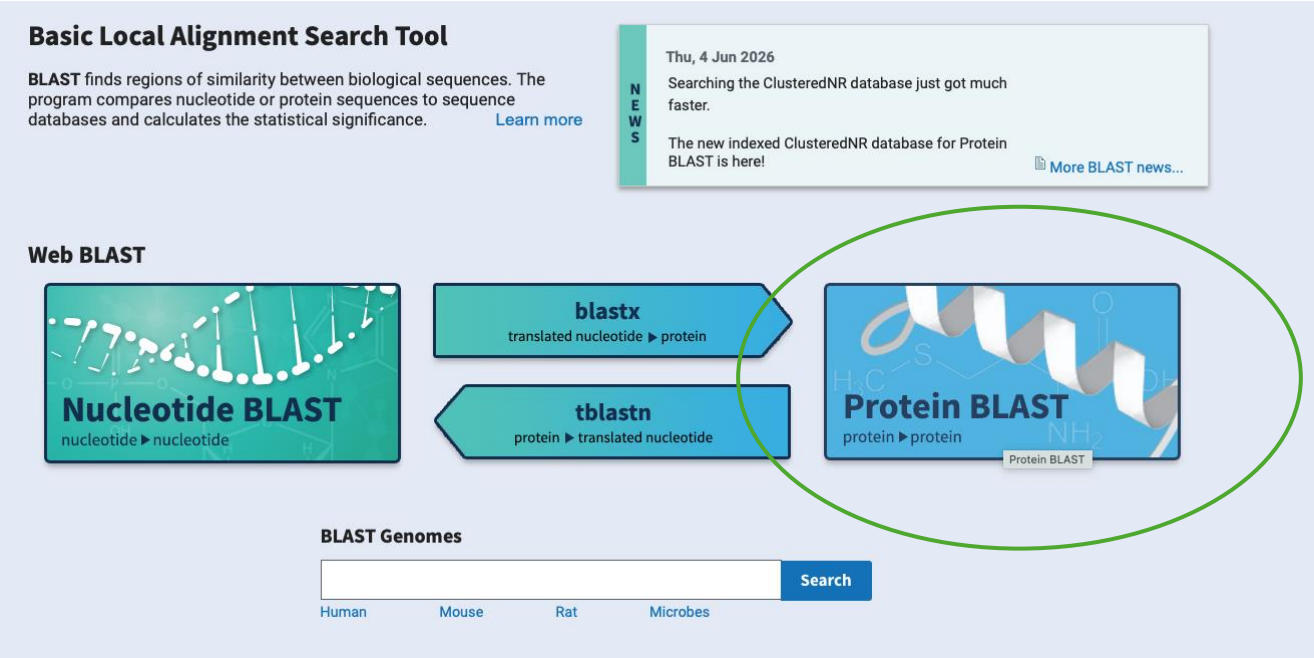


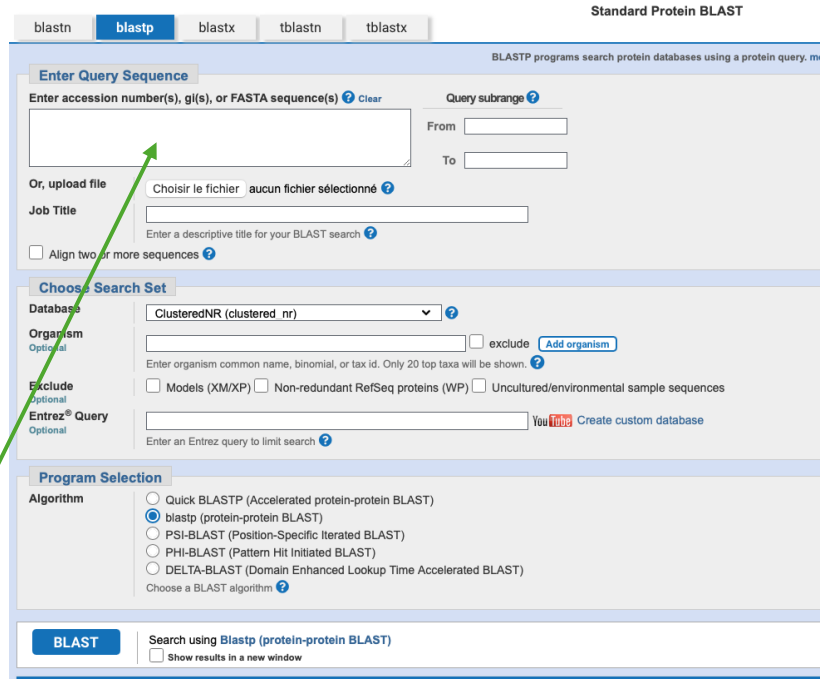
5 minutes

COPIER/COLLER ICI votre séquence ou l'ID

NCBI/ GenBank: BLAST identifier par similarité

Cas pratique: Etudier le gène de la caféine synthase





COPIER/COLLER ICI votre séquence

Job Title	sp|Q9AVL9.1
RID	EPAG353V014 *Search expires on 11-05 19:50 pm* Download All
Program	BLASTP Citation
Database	ClusteredNR See details
Query ID	lcl|Query_12566822
Description	sp|Q9AVL9.1
Molecule type	amino acid
Query Length	385
Other reports	Distance tree of results Multiple alignment MSA viewer

Filter Results

Organism *only top 20 will appear*

Type common name, binomial, taxid or group name

+ Add organism

Percent Identity to

E value to

Query Coverage to

Filter Reset

RESULTATS

Clusters | Graphic Summary | Alignments | Taxonomy

Clusters producing significant alignments Download Select columns Show 100

select all *100 clusters selected* GenPept Graphics Distance tree of results Multiple alignment MSA Viewer

Cluster Composition (Click the ⊞ to see the cluster contents)	Cluster Ancestor	Cluster Representative Sequence	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
⊞14 member(s), 4 organism(s)	coffee	probable caffeine synthase 4 [Coffea arabica]	796	796	100%	0.0	99.48%	385	NP_001413593.1
⊞6 member(s), 3 organism(s)	coffee	unnamed protein product [Coffea canephora]	668	668	100%	0.0	83.90%	385	CDP12639.1
⊞10 member(s), 4 organism(s)	coffee	monomethylxanthine methyltransferase 2 [Coffea arabica]	649	649	100%	0.0	82.34%	384	NP_001413597.1
⊞17 member(s), 4 organism(s)	coffee	3,7-dimethylxanthine N-methyltransferase 2 [Coffea arabica]	635	635	100%	0.0	80.78%	384	NP_001392356.1
⊞16 member(s), 5 organism(s)	coffee	7-methylxanthosine synthase 1 [Coffea arabica]	635	635	100%	0.0	81.56%	372	NP_001413594.1
⊞6 member(s), 2 organism(s)	coffee	monomethylxanthine methyltransferase 1 [Coffea arabica]	624	624	100%	0.0	80.26%	378	NP_001392358.1
⊞2 member(s), 1 organism(s)	coffee	probable caffeine synthase MTL2 isoform X2 [Coffea arabica]	609	609	100%	0.0	77.14%	385	XP_071922499.1
⊞1 member(s), 1 organism(s)	coffee	probable caffeine synthase MTL3 [Coffea arabica]	570	570	90%	0.0	79.19%	346	XP_071920732.1
⊞2 member(s), 1 organism(s)	eudicots	xanthosine methyltransferase 2, partial [Coffea liberica var. liberica]	529	529	84%	0.0	80.43%	323	YER57992.1
⊞3 member(s), 1 organism(s)	eudicots	7-methylxanthine methyltransferase 2, partial [Coffea liberica var. liberica]	519	519	84%	0.0	79.88%	308	YER57994.1
⊞6 member(s), 1 organism(s)	eudicots	3,7-dimethylxanthine methyltransferase, partial [Coffea liberica var. liberica]	494	494	79%	6e-173	80.33%	304	YER57998.1
⊞1 member(s), 1 organism(s)	robusta coffee	putative N-methyltransferase, partial [Coffea canephora]	487	487	72%	2e-170	85.66%	278	AAX07285.1
⊞1 member(s), 1 organism(s)	eudicots	3,7-dimethylxanthine methyltransferase, partial [Coffea liberica var. liberica]	486	486	78%	5e-170	79.67%	299	YER58005.1
⊞1 member(s), 1 organism(s)	coffee	probable caffeine synthase MTL2 isoform X2 [Coffea arabica]	486	486	82%	2e-169	76.19%	326	XP_071930164.1
⊞2 member(s), 2 organism(s)	coffee	methyltransferase-like 3 [Coffea pseudozanguebariae]	480	480	68%	6e-168	88.59%	271	AFV60452.1
⊞1 member(s), 1 organism(s)	eudicots	O-methyltransferase 4 [Hamelia patens]	460	460	98%	1e-158	60.95%	364	WKU83440.1
⊞1 member(s), 1 organism(s)	quinine	hypothetical protein ACH5RR_016516 [Cinchona calisaya]	445	883	98%	3e-148	62.10%	678	KAL3523682.1
⊞1 member(s), 1 organism(s)	quinine	hypothetical protein ACH5RR_018656 [Cinchona calisaya]	417	417	91%	8e-142	58.00%	340	KAL3520507.1
⊞1 member(s), 1 organism(s)	eudicots	OLC1v1026441C2 [Oldenlandia corymbosa var. corymbosa]	403	403	98%	9e-136	53.61%	376	CAI9091409.1
⊞1 member(s), 1 organism(s)	common oleander	hypothetical protein [Nerium oleander]	400	400	98%	8e-135	52.77%	382	MIU4369163.1
⊞1 member(s), 1 organism(s)	eudicots	OLC1v1026442C1 [Oldenlandia corymbosa var. corymbosa]	396	396	98%	3e-133	52.74%	371	CAI9091411.1
⊞1 member(s), 1 organism(s)	eudicots	OLC1v1026439C2 [Oldenlandia corymbosa var. corymbosa]	393	393	98%	6e-132	52.44%	378	CAI9091407.1
⊞1 member(s), 1 organism(s)	quinine	hypothetical protein ACH5RR_016512 [Cinchona calisaya]	386	386	73%	2e-130	67.02%	288	KAL3523678.1
⊞1 member(s), 1 organism(s)	robusta coffee	3,7-dimethylxanthine N-methyl transferase, partial [Coffea canephora]	372	372	56%	5e-126	82.95%	217	ADR30040.1

Putative conserved domains have been detected, click on the image below for detailed results.

Query

Superfamily arch. Methyltransf_7

DOMAINE

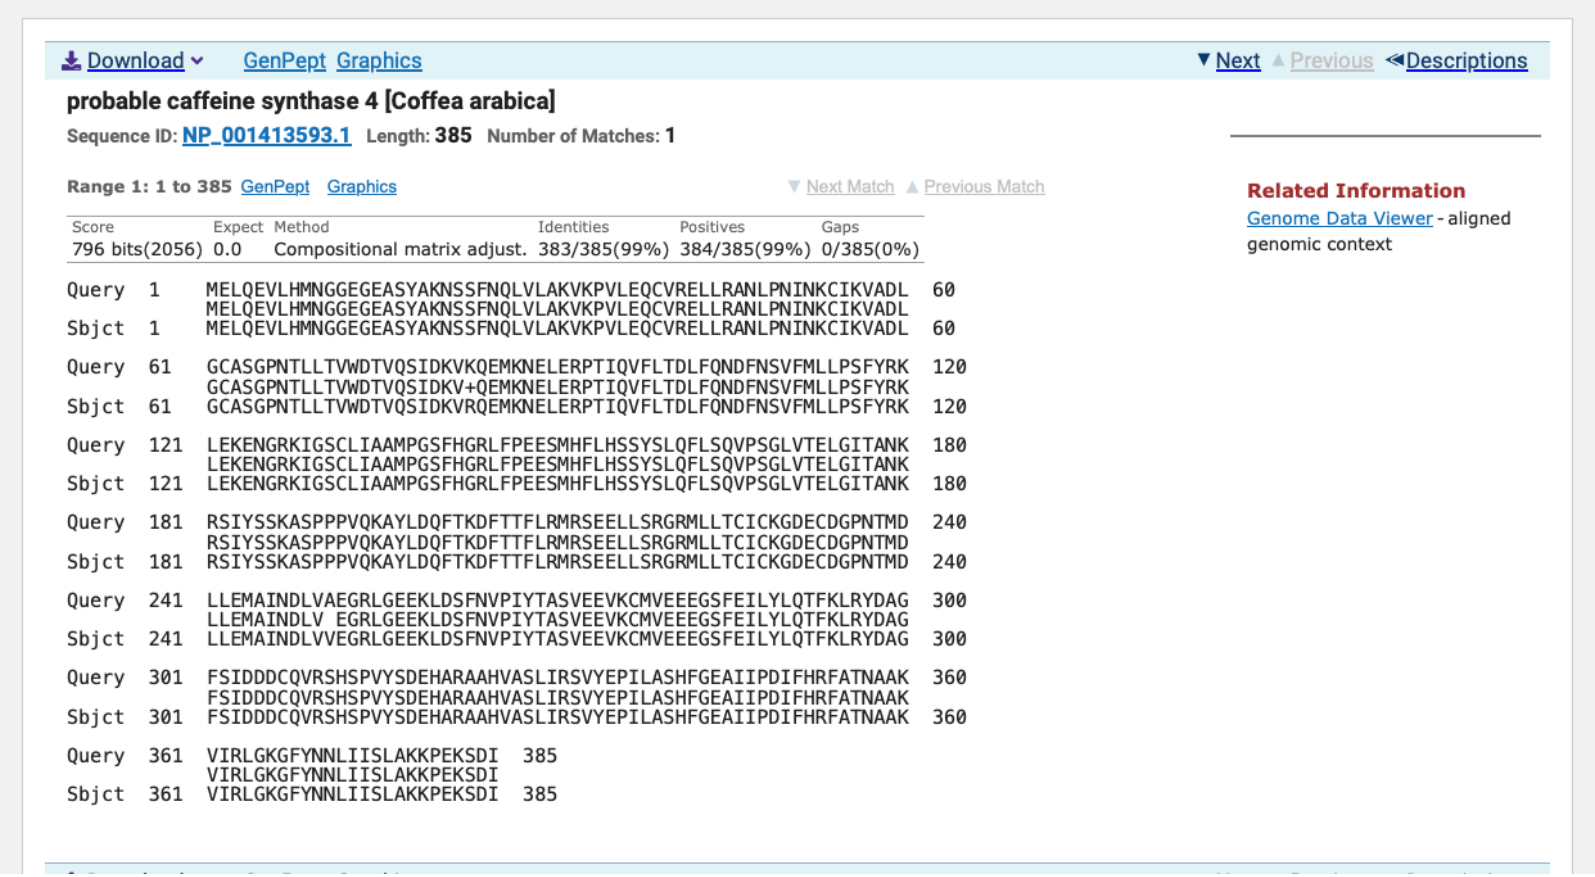
SEQUENCE SOUMISE

Distribution of the top 103 Blast Hits on 100 subject clusters



NCBI/ Genbank: BLAST identifier par similarité

Cas pratique: Etudier le gène de la caféine synthase



Download GenPept Graphics ▼Next ▲Previous ◀◀Descriptions

probable caffeine synthase 4 [Coffea arabica]

Sequence ID: NP_001413593.1 Length: 385 Number of Matches: 1

Range 1: 1 to 385 GenPept Graphics ▼Next Match ▲Previous Match

Score	Expect	Method	Identities	Positives	Gaps
796 bits(2056)	0.0	Compositional matrix adjust.	383/385(99%)	384/385(99%)	0/385(0%)

```
Query  1    MELQEVLHMNGGEGEASYAKNSSFNQLVLAKVKPVLEQCVRELLRANLPNINKCIKVADL  60
            MELQEVLHMNGGEGEASYAKNSSFNQLVLAKVKPVLEQCVRELLRANLPNINKCIKVADL
Sbjct  1    MELQEVLHMNGGEGEASYAKNSSFNQLVLAKVKPVLEQCVRELLRANLPNINKCIKVADL  60

Query  61   GCASGPNTLLTVWDTVQSIDKVKQEMKNELERPTIQVFLTDLFQNDFNSVFMLLPSFYRK  120
            GCASGPNTLLTVWDTVQSIDKV+QEMKNELERPTIQVFLTDLFQNDFNSVFMLLPSFYRK
Sbjct  61   GCASGPNTLLTVWDTVQSIDKVRQEMKNELERPTIQVFLTDLFQNDFNSVFMLLPSFYRK  120

Query  121  LEKENGRKIGSCLIAAMPGSFHGRLFPEESMHFLHSSYSLQFLSQVPSGLVTELGITANK  180
            LEKENGRKIGSCLIAAMPGSFHGRLFPEESMHFLHSSYSLQFLSQVPSGLVTELGITANK
Sbjct  121  LEKENGRKIGSCLIAAMPGSFHGRLFPEESMHFLHSSYSLQFLSQVPSGLVTELGITANK  180

Query  181  RSIYSSKASPPPVQKAYLDQFTKDFTTFLRMRSEELLSRGRMLLTCICKGDECDGPNTMD  240
            RSIYSSKASPPPVQKAYLDQFTKDFTTFLRMRSEELLSRGRMLLTCICKGDECDGPNTMD
Sbjct  181  RSIYSSKASPPPVQKAYLDQFTKDFTTFLRMRSEELLSRGRMLLTCICKGDECDGPNTMD  240

Query  241  LLEMAINDLVAEGRLGEEKLDSFNVPIYTASVEEVKCMVEEEGSFEILYLQTFKLRYDAG  300
            LLEMAINDLV EGRLGEEKLDSFNVPIYTASVEEVKCMVEEEGSFEILYLQTFKLRYDAG
Sbjct  241  LLEMAINDLVVEGRLGEEKLDSFNVPIYTASVEEVKCMVEEEGSFEILYLQTFKLRYDAG  300

Query  301  FSIDDDCQVRSHSPVYSDEHARAAHVASLIRSVYEPILASHFGEAIIPDIFHRFATNAAK  360
            FSIDDDCQVRSHSPVYSDEHARAAHVASLIRSVYEPILASHFGEAIIPDIFHRFATNAAK
Sbjct  301  FSIDDDCQVRSHSPVYSDEHARAAHVASLIRSVYEPILASHFGEAIIPDIFHRFATNAAK  360

Query  361  VIRLGKGFYNNLIISLAKKPEKSDI  385
            VIRLGKGFYNNLIISLAKKPEKSDI
Sbjct  361  VIRLGKGFYNNLIISLAKKPEKSDI  385
```

Related Information

Genome Data Viewer - aligned genomic context

Alignement
Comment Evaluer cet alignement?
Score:
Expect/Evalue
Identité
Gap

NCBI/ Genbank: BLAST identifier par similarité

Quel programme BLAST choisir ?

Quels organismes possèdent des séquences similaires ?

Que signifie 90 % d'identité ?

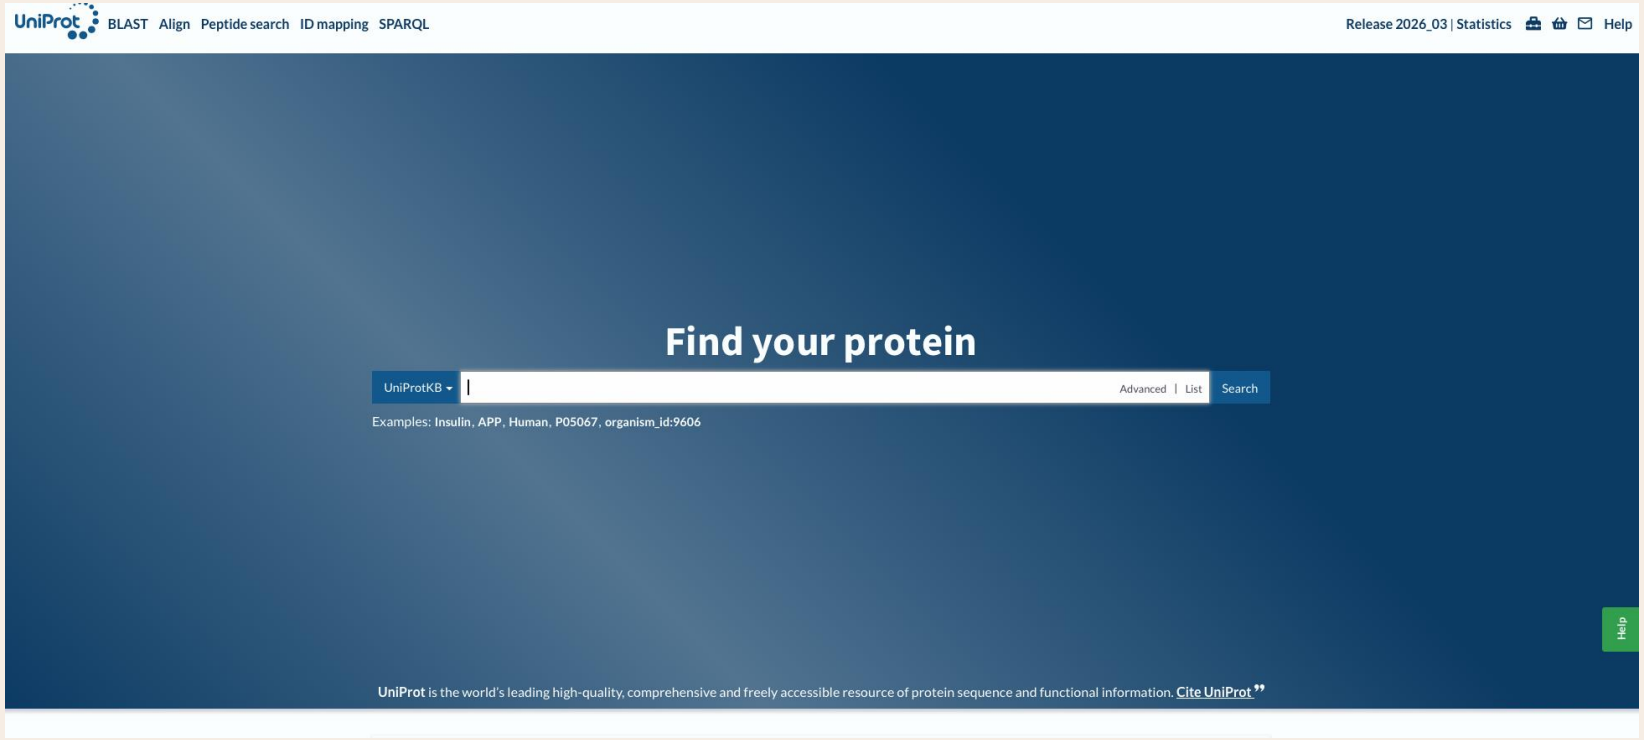
Que signifie une E-value très faible ?

Peut-on conclure que toutes ces protéines ont la même fonction ?

Les bases de données de protéine: Uniprot

Une base integrative: donnée d séquence, bibliographique, phylogénétique, nucleotidique qui combine d'autres bases comme Swiss-Prot, TrEMBL et PIR:

Séquence / Fonction



Les bases de données de protéine: Uniprot

Une base integrative: donnée d séquence, bibliographique, phylogénétique, nucleotidique qui combine d'autres bases comme Swiss-Prot, TrEMBL et PIR.

Cherchons « caffeine synthase »



Status
- Reviewed (Swiss-Prot) (48)
- Unreviewed (TrEMBL) (1,087)

Popular organisms
- Rat (3)
- S. cerevisiae (3)
- Mouse (2)
- A. thaliana (1)
- Human (1)

Taxonomy
Filter by taxonomy

Group by
- Taxonomy
- Keywords
- Gene Ontology
- Enzyme Class

Proteins with
- 3D structure (10)
- Active site (101)
- Activity regulation (7)
- Alternative products (isoforms) (3)
- Alternative splicing (3)

More items

Protein existence
- Homology (783)
- Predicted (308)
- Protein level (30)
- Transcript level (14)

Annotation score

UniProtKB 1,135 results

Tools | Download (1k) | Add | View: Cards / Table | Customize columns | Share

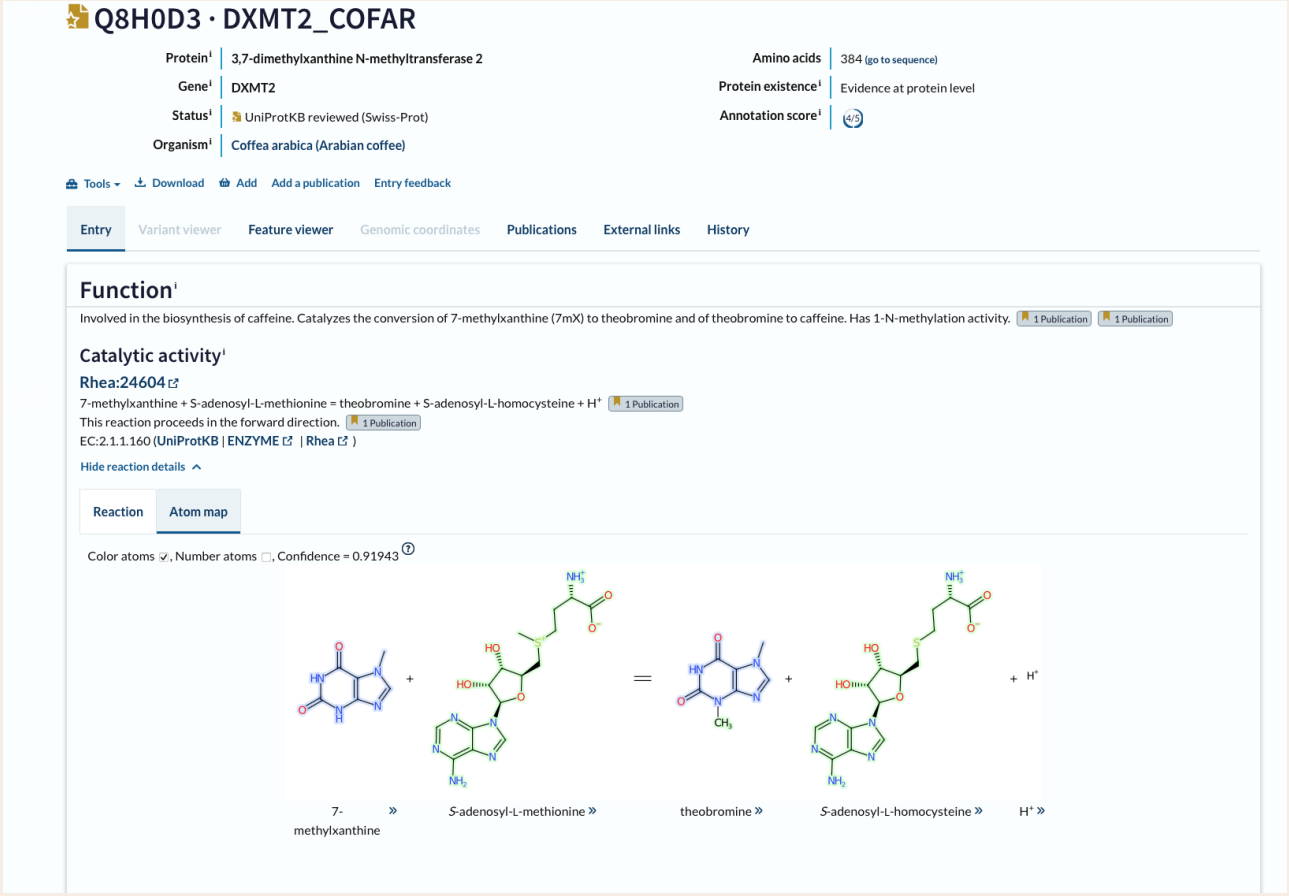
Entry	Entry Name	Protein Names	Gene Names	Organism	Length
Q9FZN8	TCS1_CAMSI	3,7-dimethylxanthine N-methyltransferase TCS1[...]	**TCS1**, TCS1A	Camellia sinensis (Tea plant) (Thea sinensis)	369 AA
Q8H0D3	DXMT2_COFAR	3,7-dimethylxanthine N-methyltransferase 2[...]	**DXMT2**, CCS1, CS6	Coffea arabica (Arabian coffee)	384 AA
A4GE70	DXMT1_COFCA	3,7-dimethylxanthine N-methyltransferase[...]	**DXMT**, GSCOC_T00011062001	Coffea canephora (Robusta coffee)	384 AA
Q8H0D2	DXMT1_COFAR	3,7-dimethylxanthine N-methyltransferase 1[...]	**DXMT1**, CS7	Coffea arabica (Arabian coffee)	384 AA
A0A0S2PMA8	TCS1D_CAMTA	Caffeine synthase 1[...]	**TCS1D**	Camellia taliensis (Wild tea) (Thea taliensis)	369 AA
A0A0S2PM92	TCS1F_CAMCR	Caffeine synthase 1[...]	**TCS1F**	Camellia crassicolumna (Evergreen tea)	369 AA
A0A0S2PM82	TCS3_CAMSI	Caffeine synthase 3[...]	**TCS1E**	Camellia sinensis (Tea plant) (Thea sinensis)	368 AA
Q3E840	DPH3_YEAST	Diphthamide biosynthesis protein 3 [...]	**KTI11**, DPH3, YBL071W-A	Saccharomyces cerevisiae (strain ATCC 204508 / S288c) (Baker's yeast)	82 AA
P38689	KPR3_YEAST	Ribose-phosphate pyrophosphokinase 3[...]	**PRS3**, PRPS3, YHL011C	Saccharomyces cerevisiae (strain ATCC 204508 / S288c) (Baker's yeast)	320 AA
P06525	ADH1_ARATH	Alcohol dehydrogenase class-P[...]	**ADH1**, ADH, At1g77120, F22K20.19	Arabidopsis thaliana (Mouse-ear cress)	379 AA
A0A6C0WW38	CKCS_CAMSB	3,7-dimethylxanthine N-methyltransferase TCS1[...]	**CS**	Camellia sinensis var. assamica (Assam tea) (Thea assamica)	369 AA
Q84PP7	MXMT2_COFAR	Monomethylxanthine methyltransferase 2[...]	**MXMT2**, CTS2	Coffea arabica (Arabian coffee)	384 AA
Q2HXI6	PCS1_CAMPL	7-methylxanthine methyltransferase PCS1[...]	**PCS1**, TCS1C	Camellia ptilophylla (Cocoa tea)	365 AA
P27708	PYR1_HUMAN	Multifunctional protein CAD[...]	**CAD**	Homo sapiens (Human)	2,225 AA
A4GE69	XMT1_COFCA	7-methylxanthosine synthase 1[...]	**XMT1**, GSCOC_T00036338001	Coffea canephora (Robusta coffee)	372 AA
O94614	CHR4_SCHPO	1,3-beta-glucan synthase regulatory factor chr4[...]	**chr4**, cfh3, SPBC1289.01c, SPBC1539.11c	Schizosaccharomyces pombe (strain 972 / ATCC 24843) (Fission yeast)	633 AA
Q9AVJ9	MXMT1_COFAR	Monomethylxanthine	**MXMT1**, CTS1	Coffea arabica (Arabian coffee)	378 AA

Help

Les bases de données de protéine: Uniprot

Une base integrative: donnée d séquence, bibliographique, phylogénétique, nucleotidique qui combine d'autres bases comme Swiss-Prot, TrEMBL et PIR.

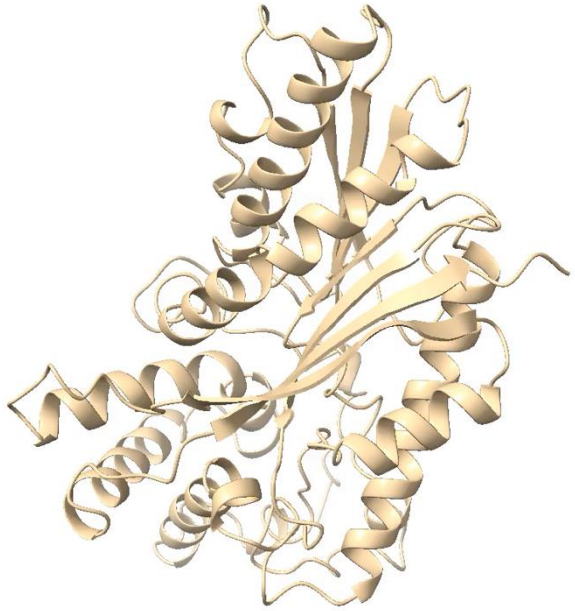
Cherchons « caffeine synthase »

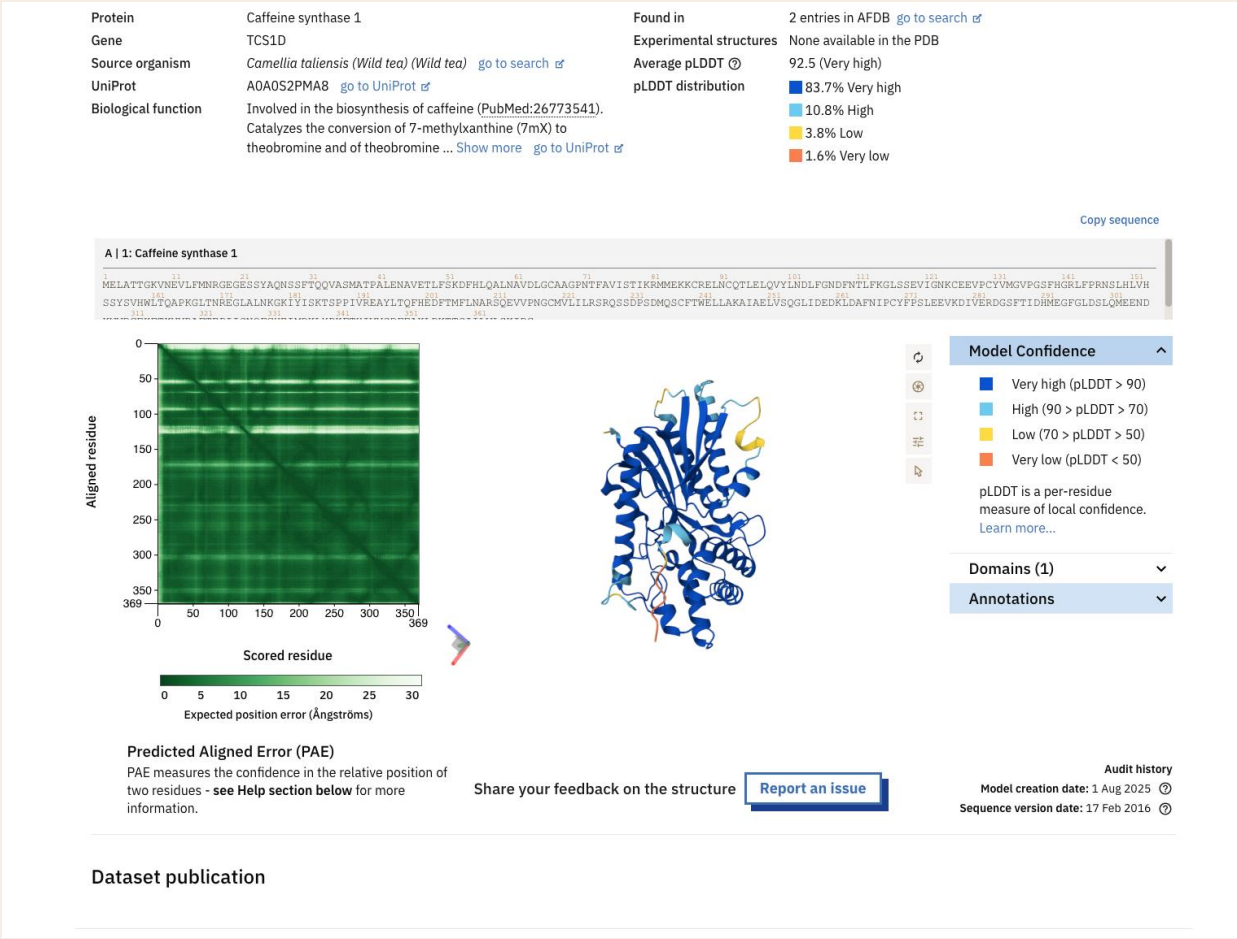


Les bases de données de protéine: Alphafold DB

AlphaFold est un logiciel d'intelligence artificielle développé par Google DeepMind qui fournit une prédiction de la structure des protéines à partir de leur séquence en acides aminés.

Chercher « Caffeine synthase »

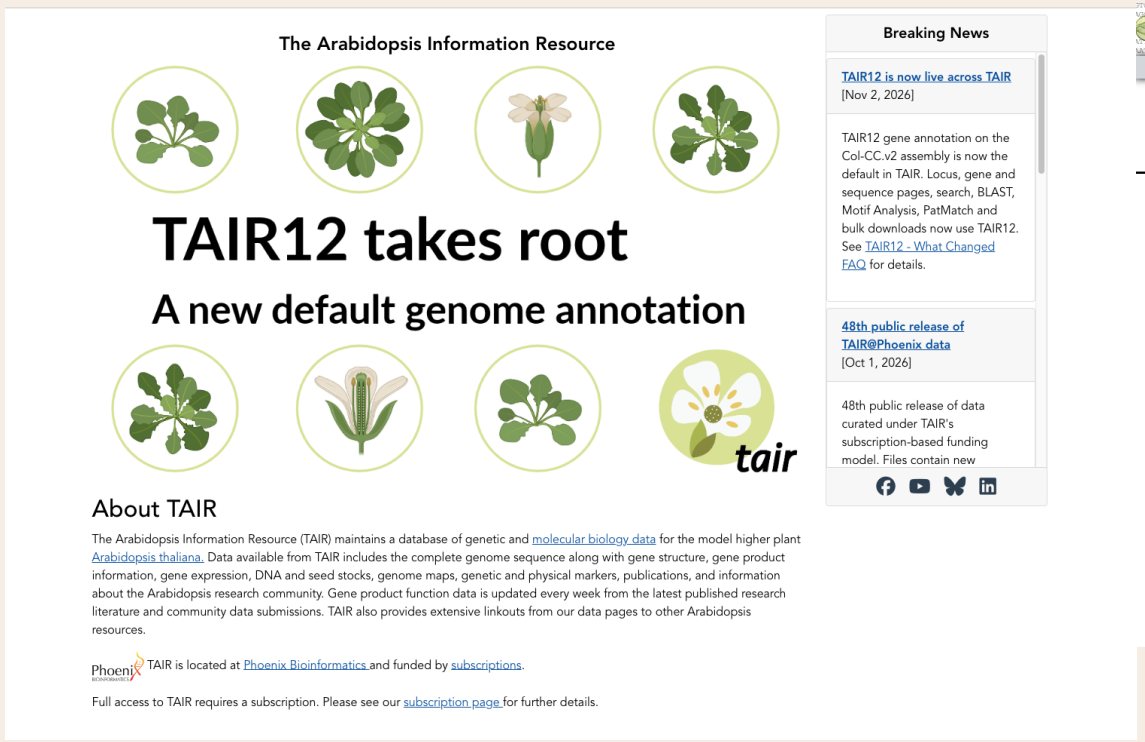


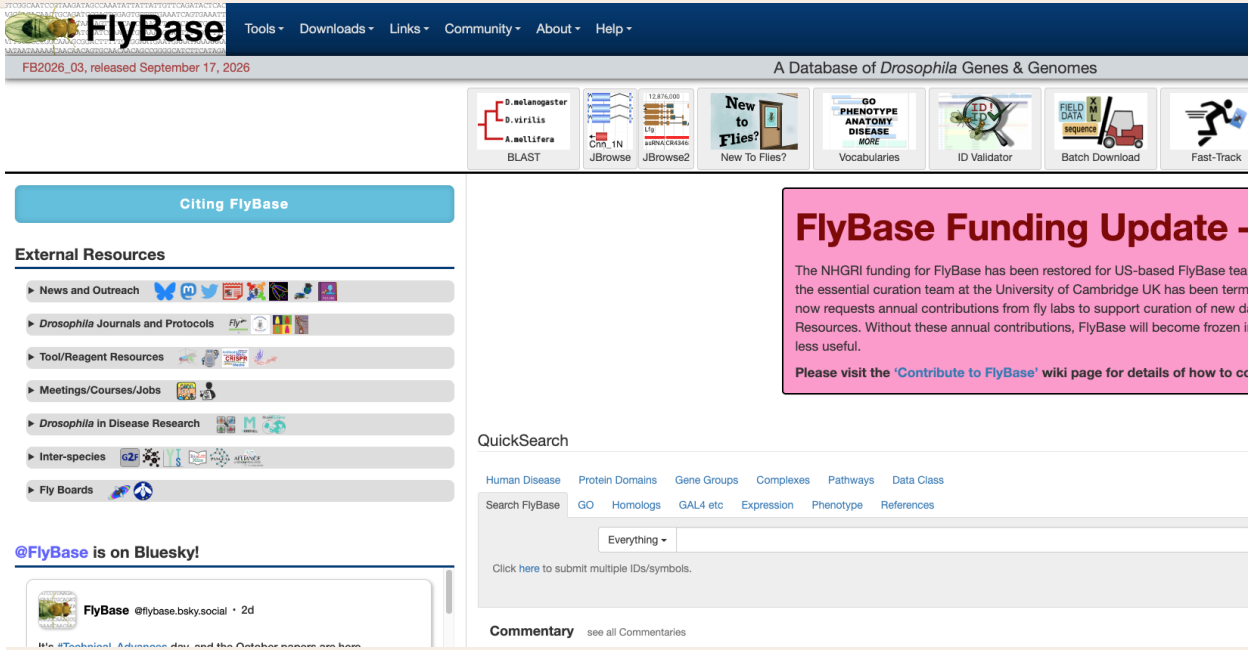


Les bases de données de génomes

Ces bases collectent des génomes, parfois les annotent et proposent des outils d'analyse génomique.

https://www.arabidopsis.org/ https://flybase.org/





Les bases de données de génomes

https://coffee-genome-hub.southgreen.fr/

Accès aux données de séquences et annotations

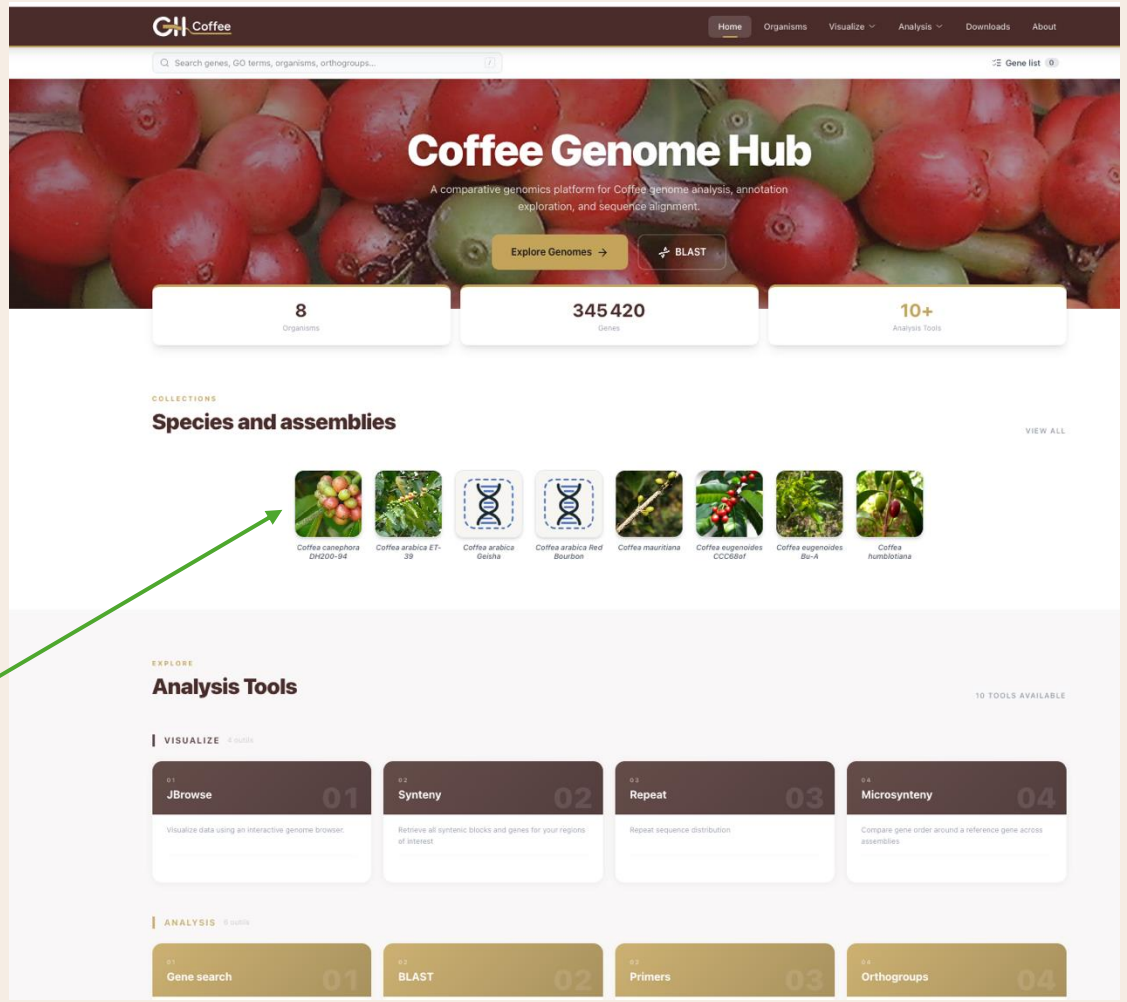
Exploration des génome (GenomeBrowser)

Recherche de gene (mot clé, ID, BLAST)

Chercher des amorces PCR

Génomique comparative

Pangenomique



CHOISIR CANEPHORA

Les bases de c

https://coffee-genome-hub.southgreen.fr/



Les bases de données spécialisées

GBIF

https://www.gbif.org

Chercher « Coffea arabica »



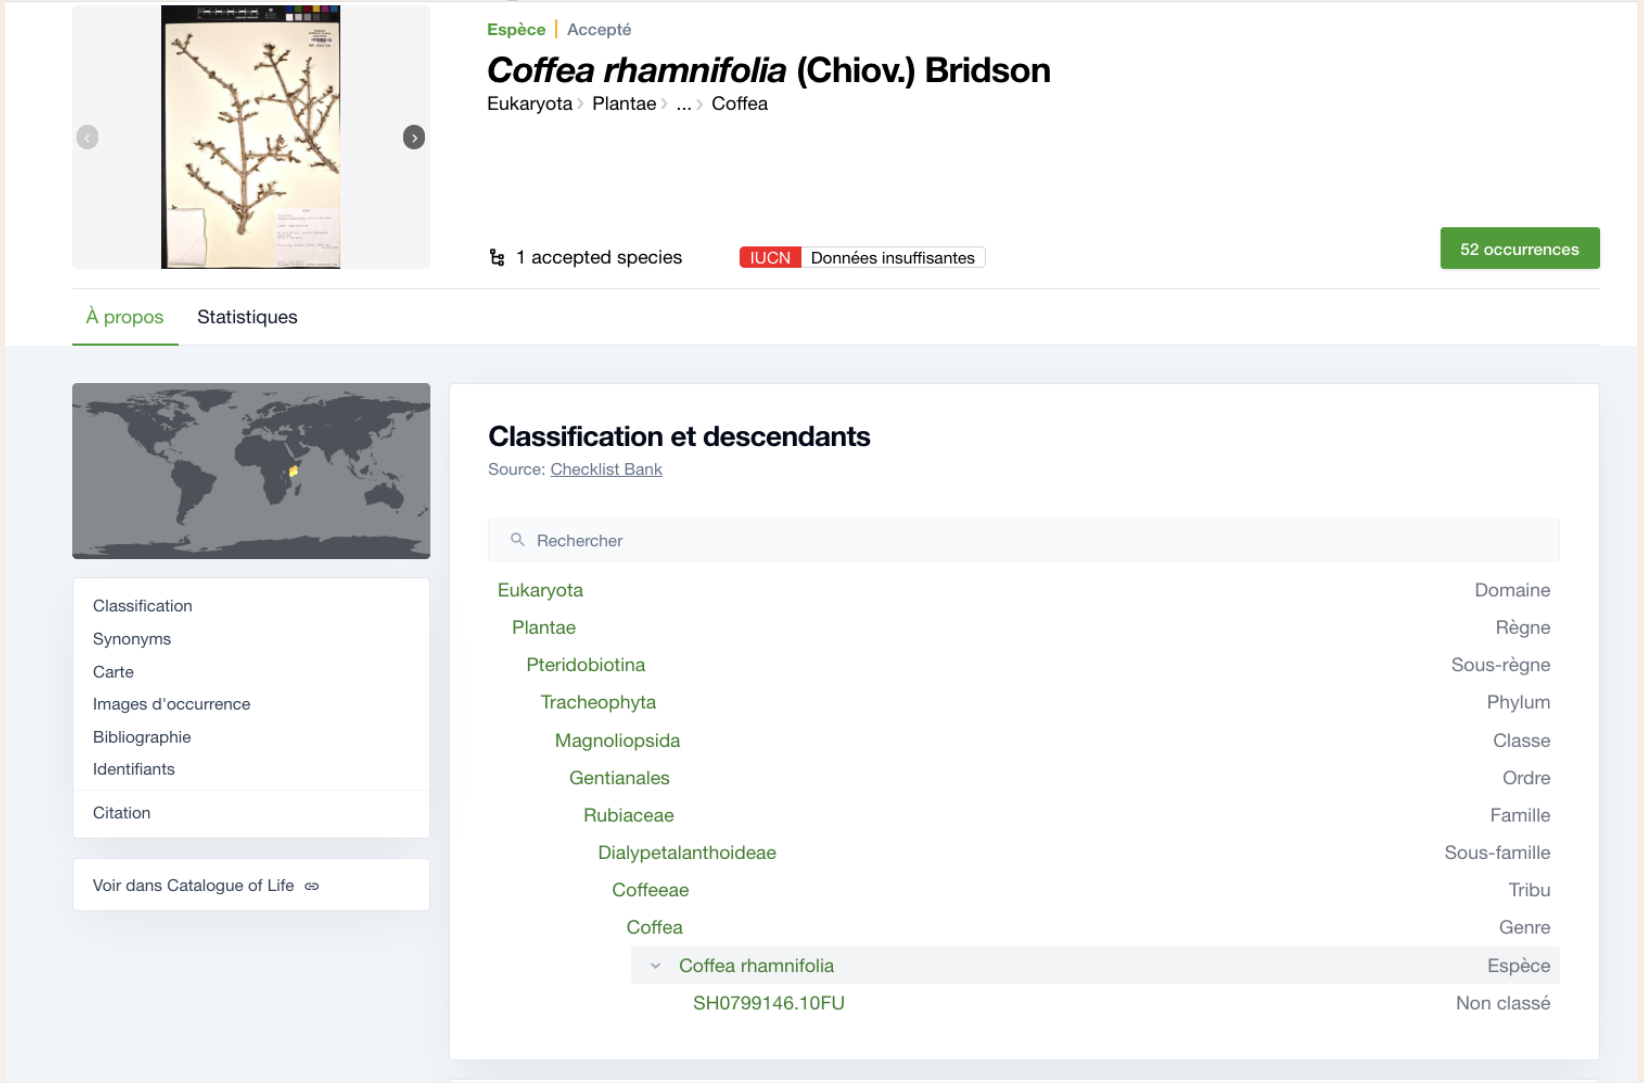
Les bases de données spécialisées

GBIF

https://www.gbif.org

Chercher « Coffea arabica »

Ou « Coffea rhamnifolia »

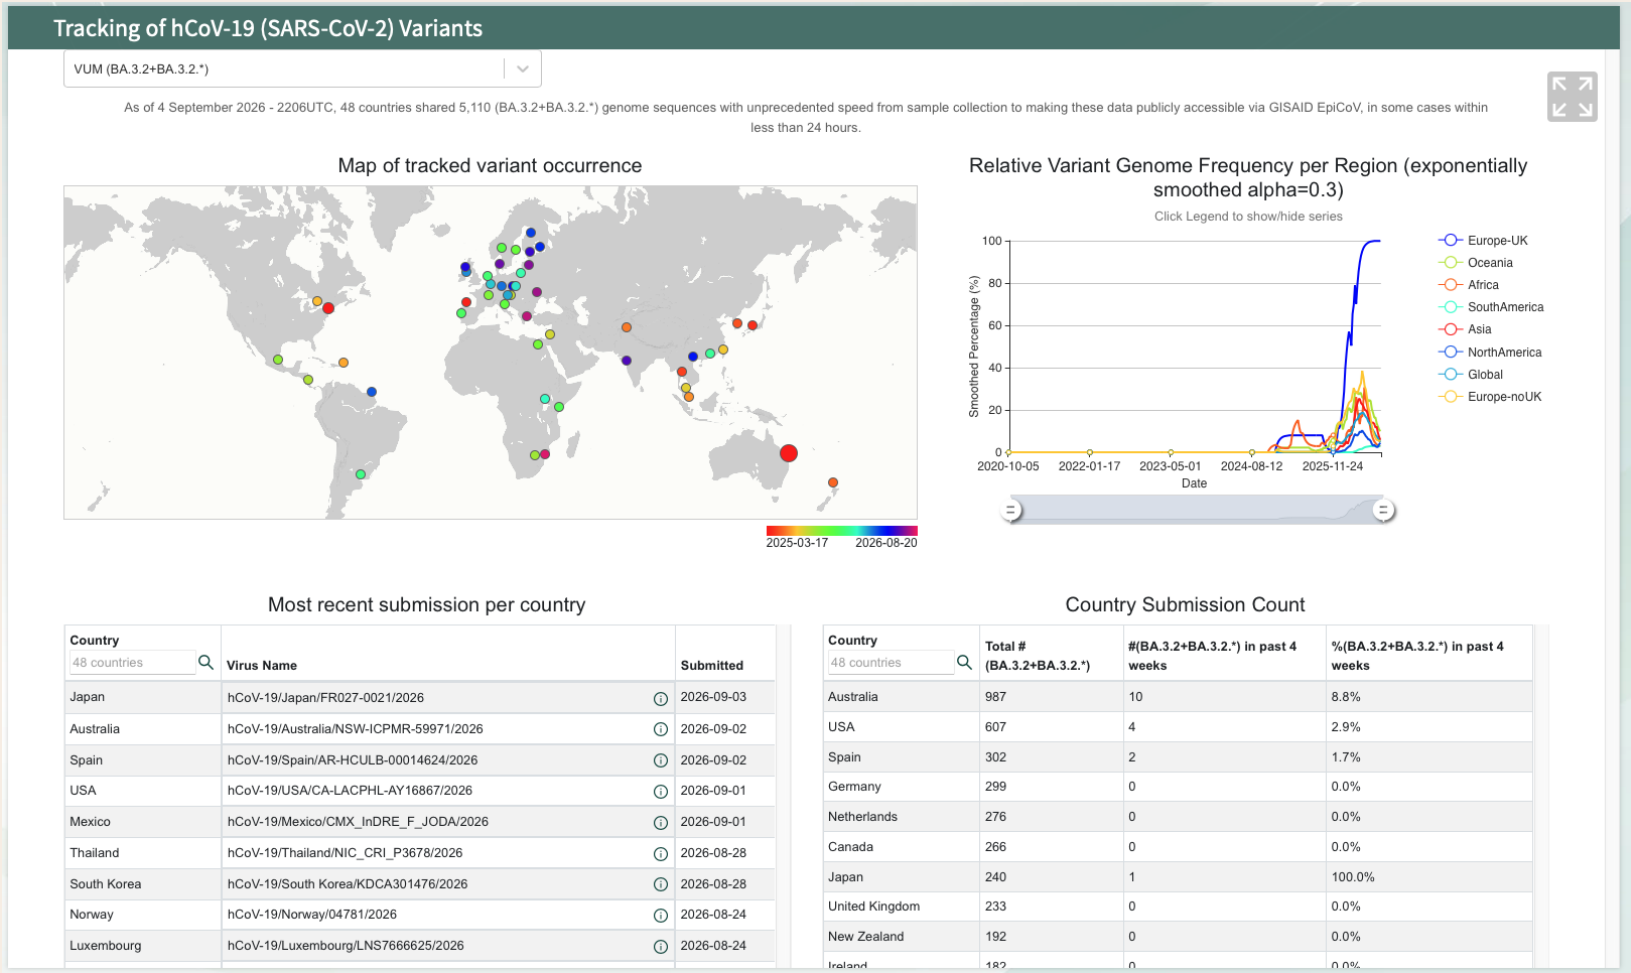


Les bases de données spécialisées

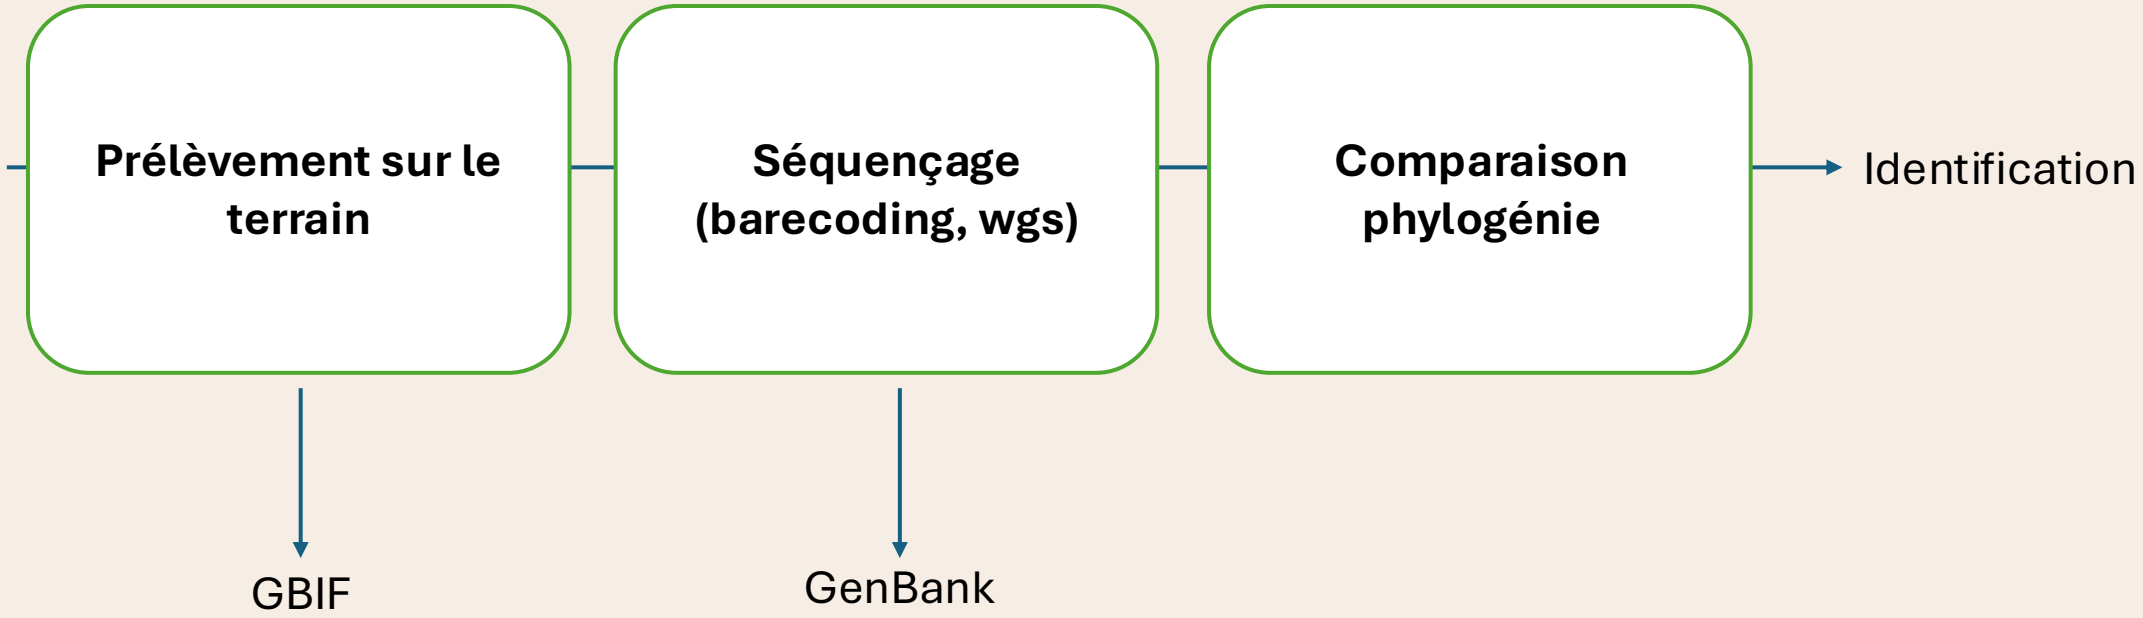
https://gisaid.org/hcov19-variants/

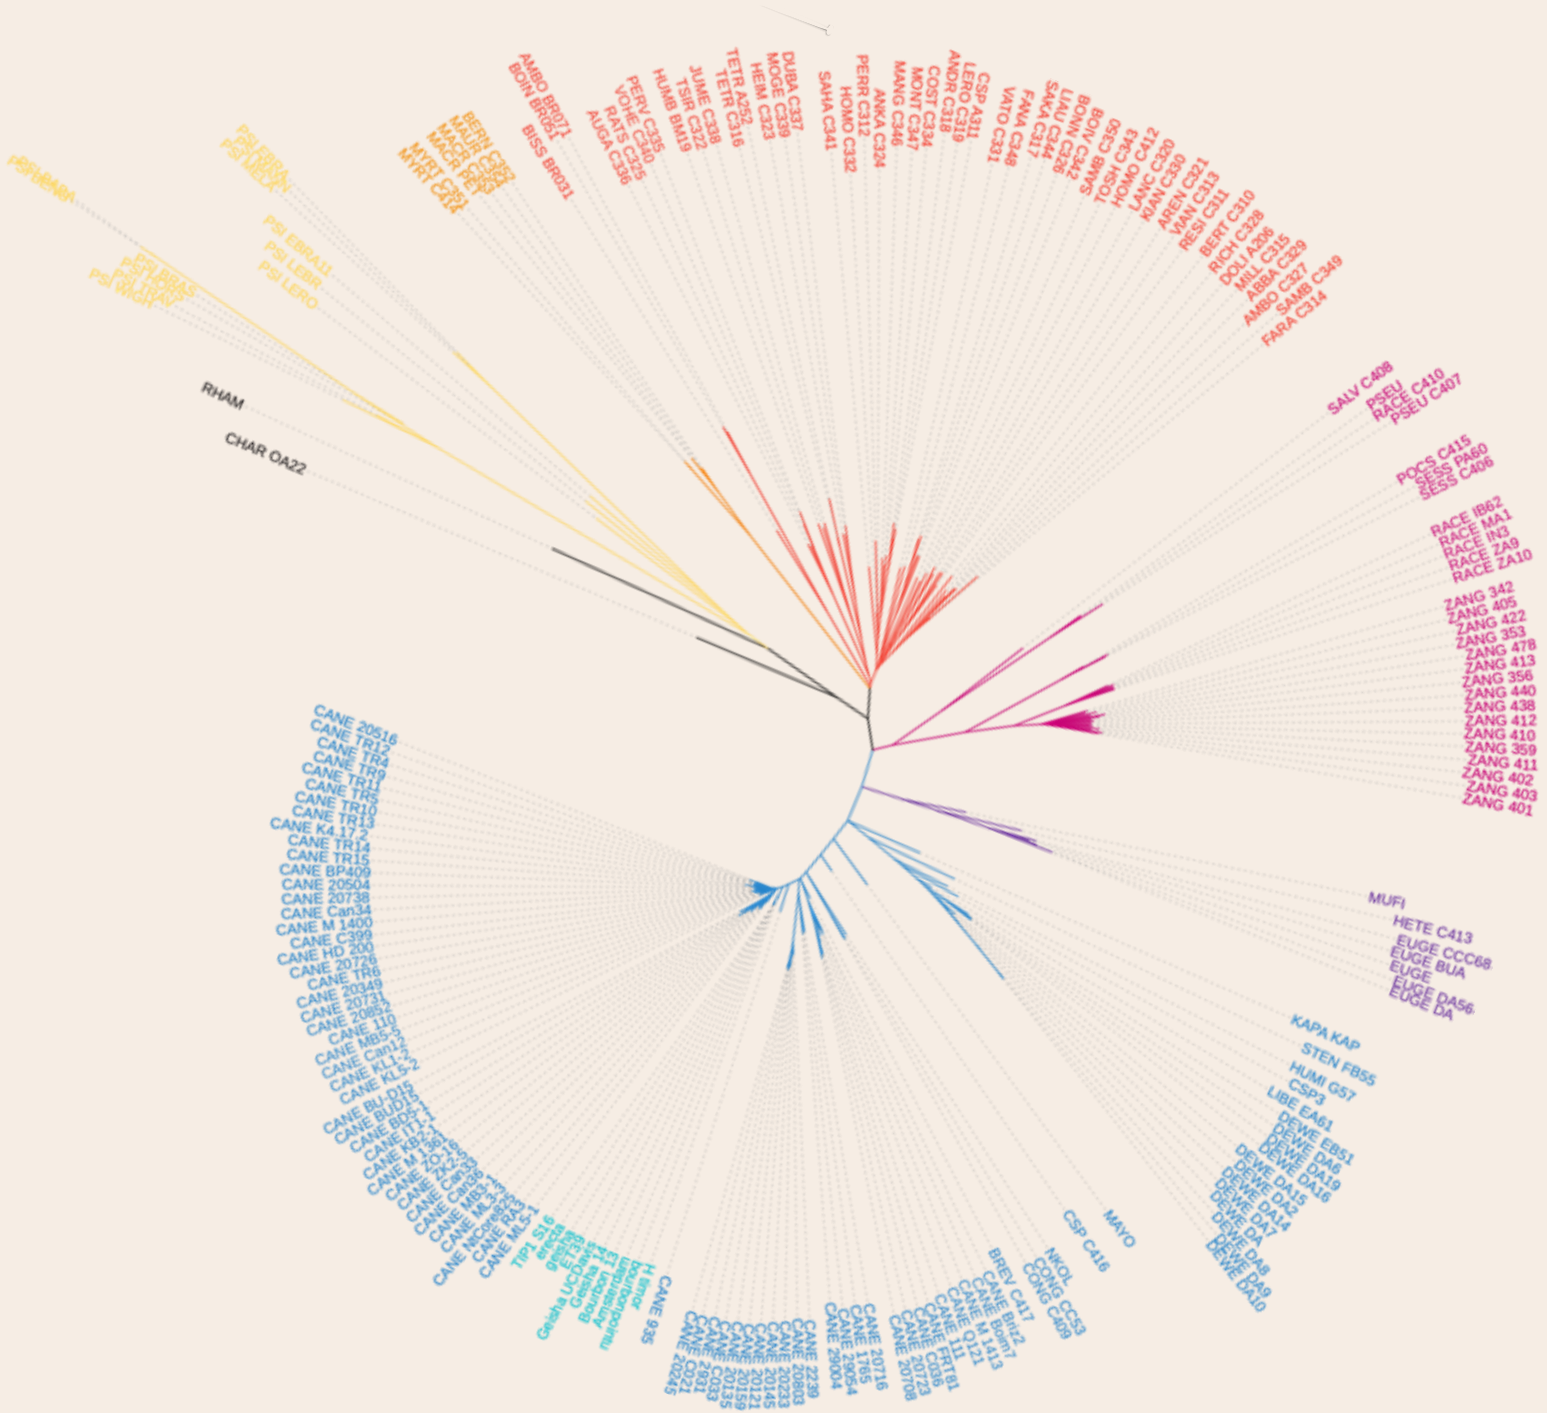
Base de données mondiale

du COVID-19



Cas pratique: identifier une espèces





6,708,319
SNP markers

Autres cas pratique ?

A Retenir

Des données très variées	**ADN, ARN, protéines, expression, métadonnées, …**
Des bases complémentaires	**GenBank, Uniprot, PDB**
Des bases intégratives	**NCBI: du gène à la bibliographie**
Des outils pour interroger les bases	**les ID, BLAST**
Mais garder à l'esprit que l'information peut être corrompue …	
Mais une donnée n'est pas une connaissance validée	