GenoDjib

Les Journées de la génétique et de la génomique de Djibouti

Introduction à la bioinformatique

Qu'est-ce que la bioinformatique?

et à quelles questions biologiques peut-elle répondre ?

Romain Guyot

Directeur de Recherche IRD

Djibouti, 9–17 novembre 2026

IRD
Déployer la recherche
Partager la science
Transformer l'avenir

CERD

Université de Djibouti

Pourquoi la bioinformatique ?

Une nouvelle science qui permet de répondre à des questions fondamentales et appliquées à partir de données biologiques et informatiques comme:

- Pourquoi deux individus de la même espèce sont-ils différents ?
- Comment une bactérie devient elle résistante à un antibiotique ?
- Comment les espèces ont-elles évolué ?

Pourquoi la bioinformatique ?

Une révolution scientifique due à de grande quantité de données.

Par exemple le génome humain :

3,2 milliards de paires de bases	20 000 gènes codants	… des millions de données archivées

Pourquoi la bioinformatique ?

Pour '*homo sapiens*' dans NCBI (National Center for Biotechnology Informatiov https://www.ncbi.nlm.nih.gov)

Le défi est donc de stocker, comparer, analyser et interpréter ces informations



Literature	
Bookshelf	93,696
MeSH	5
NLM Catalog	3,899
PubMed	24,005,045
PubMed Central	6,192,333

Genes	
Gene	2,052,899
GEO DataSets	4,910,923
GEO Profiles	61,958,910

Proteins	
Conserved Domains	201
Identical Protein Groups	2,332,135
Protein	284,237,360
Protein Family Models	1,802
Structure	83,626

Genomes	
Assembly / Genome NCBI Datasets	
BioCollections	0
BioProject	155,213
BioSample	31,094,055
Nucleotide	75,627,472
SRA	19,209,062
Taxonomy	1

Clinical	
ClinicalTrials.gov	0
ClinVar	4,708,791
dbGaP	39
dbSNP	1,191,662,003
dbVar	8,651,519
GTR	12
MedGen	0
OMIM	74

PubChem	
BioAssays	16,956
Compounds	10
Pathways	53,362
Substances	2,061

Pourquoi la bioinformatique ?

Pour 2 individus:

A ATG AAA CCT GCT TAA

B ATG AAA TCT GCT TAA

1 nucléotide de différences ou SNP (Single Nucleotide Polymorphism)

Mais pour 155 213 séquences génomiques du NCBI dont 2 587 génomes humains complets ?
Comment les comparer et trouver les différences ?

Pour 2 individus:

A ATG AAA CCT GCT TAA

B ATG AAA TCT GCT TAA

Que nous apprend cette variation de séquences ?

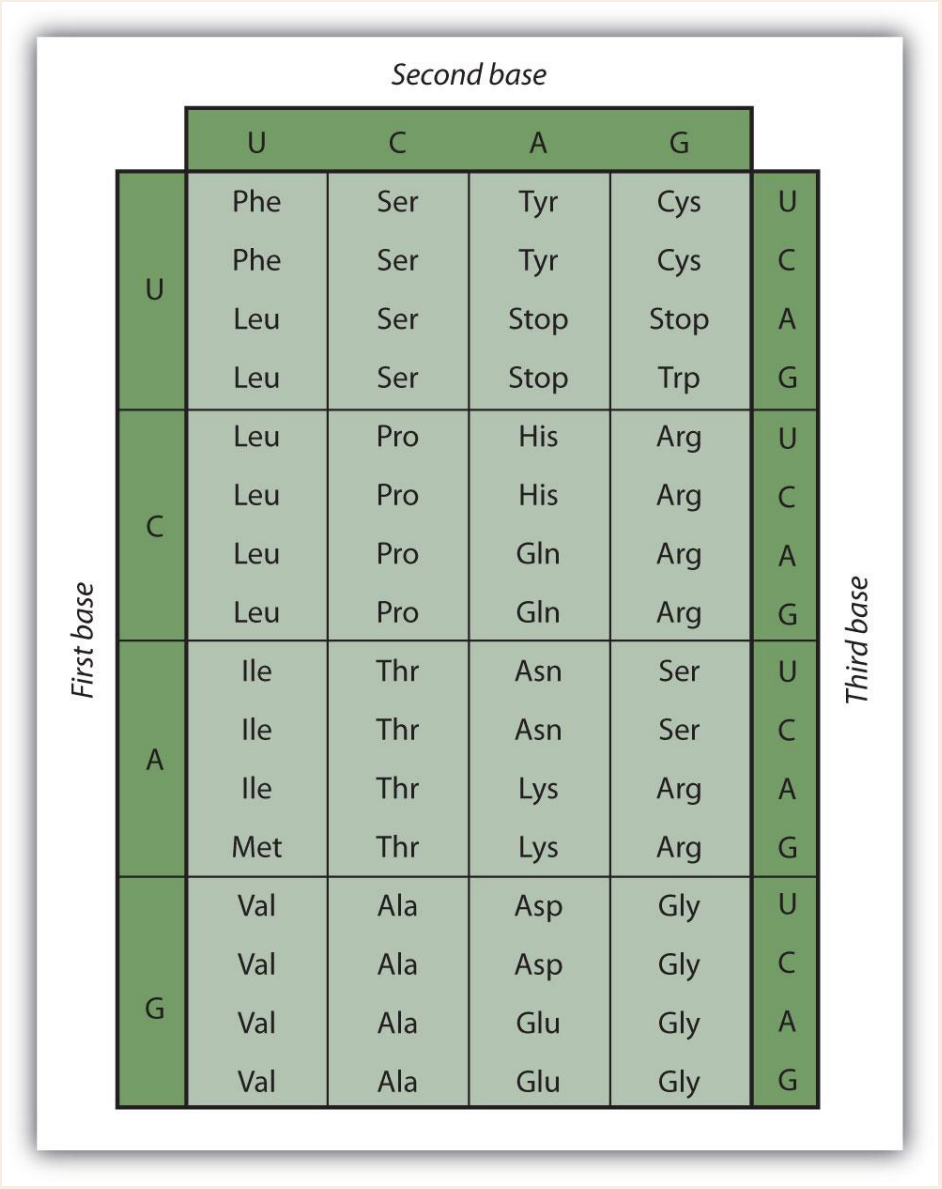
Pour 2 individus:

A ATG AAA CCT GCT TAA

Met Lys Pro Arg Stop

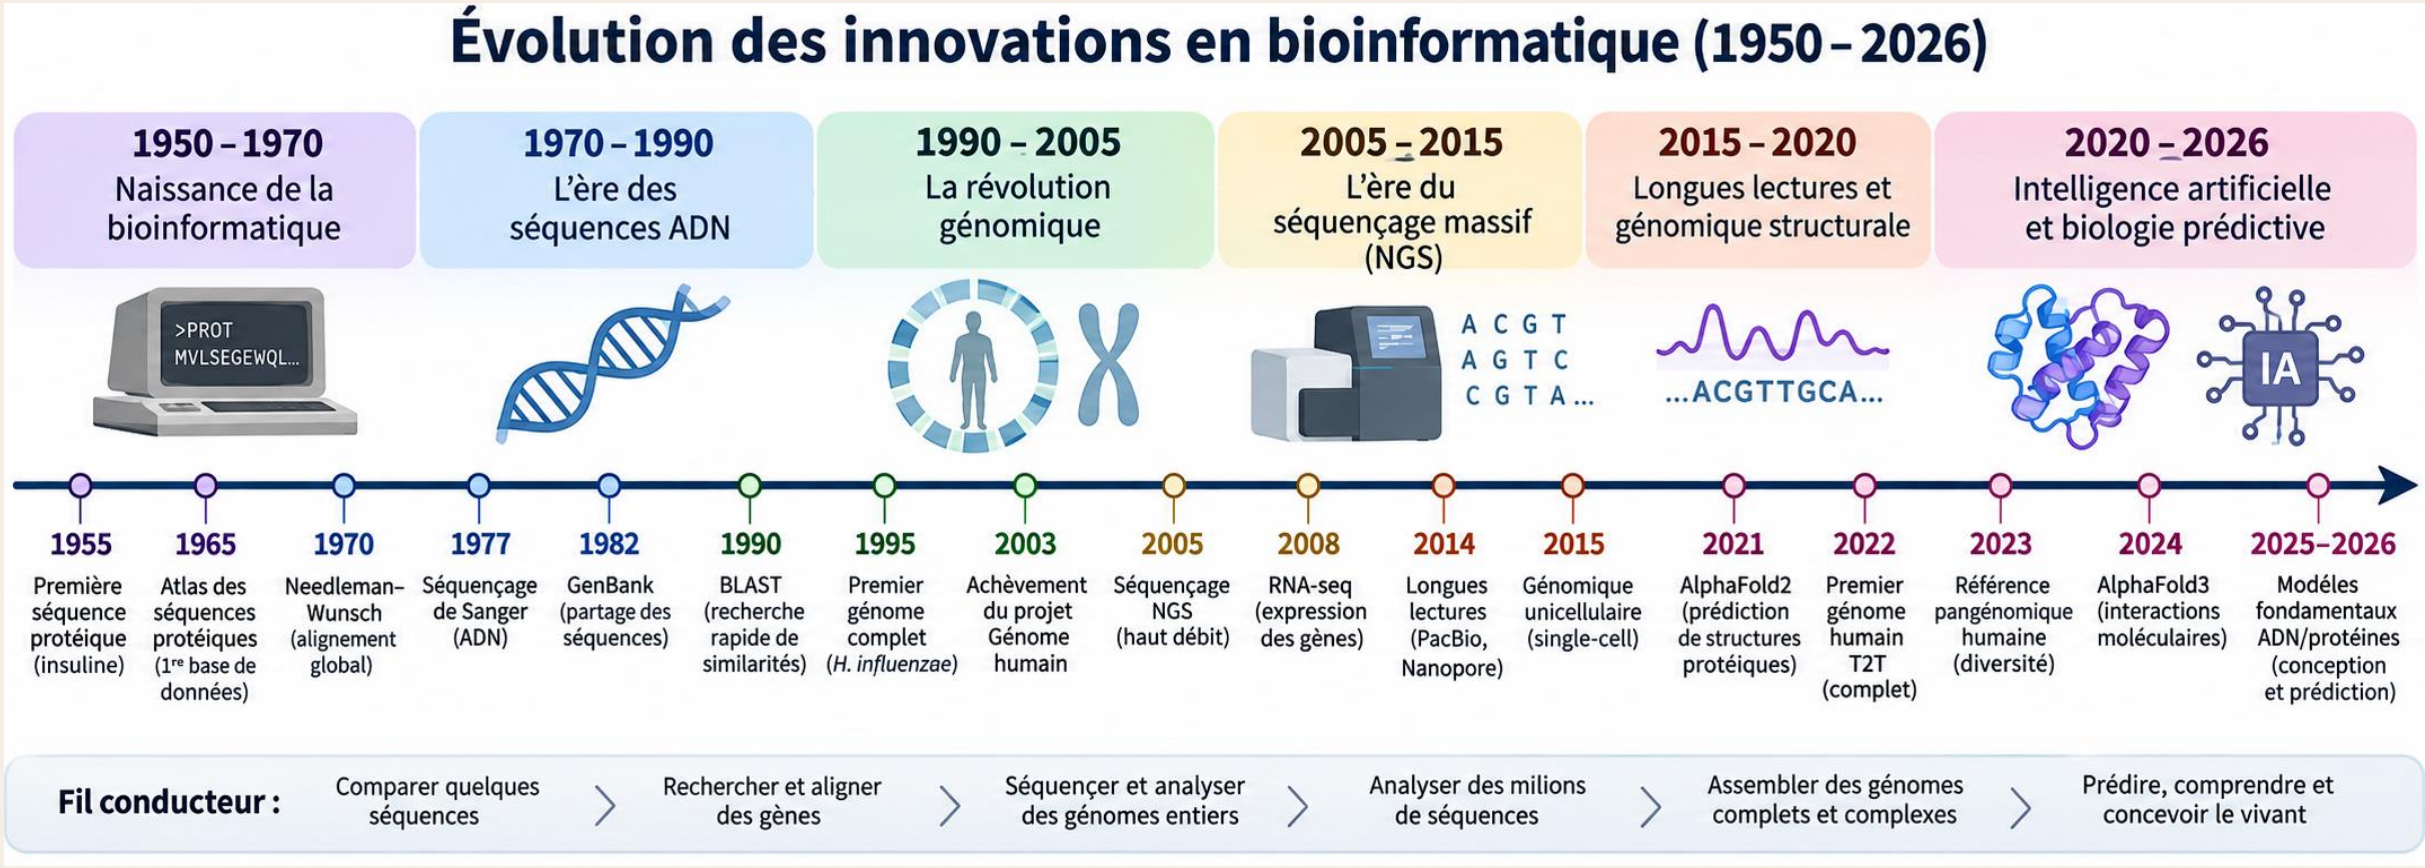
B ATG AAA TCT GCT TAA

Met Lys Ser Arg Stop



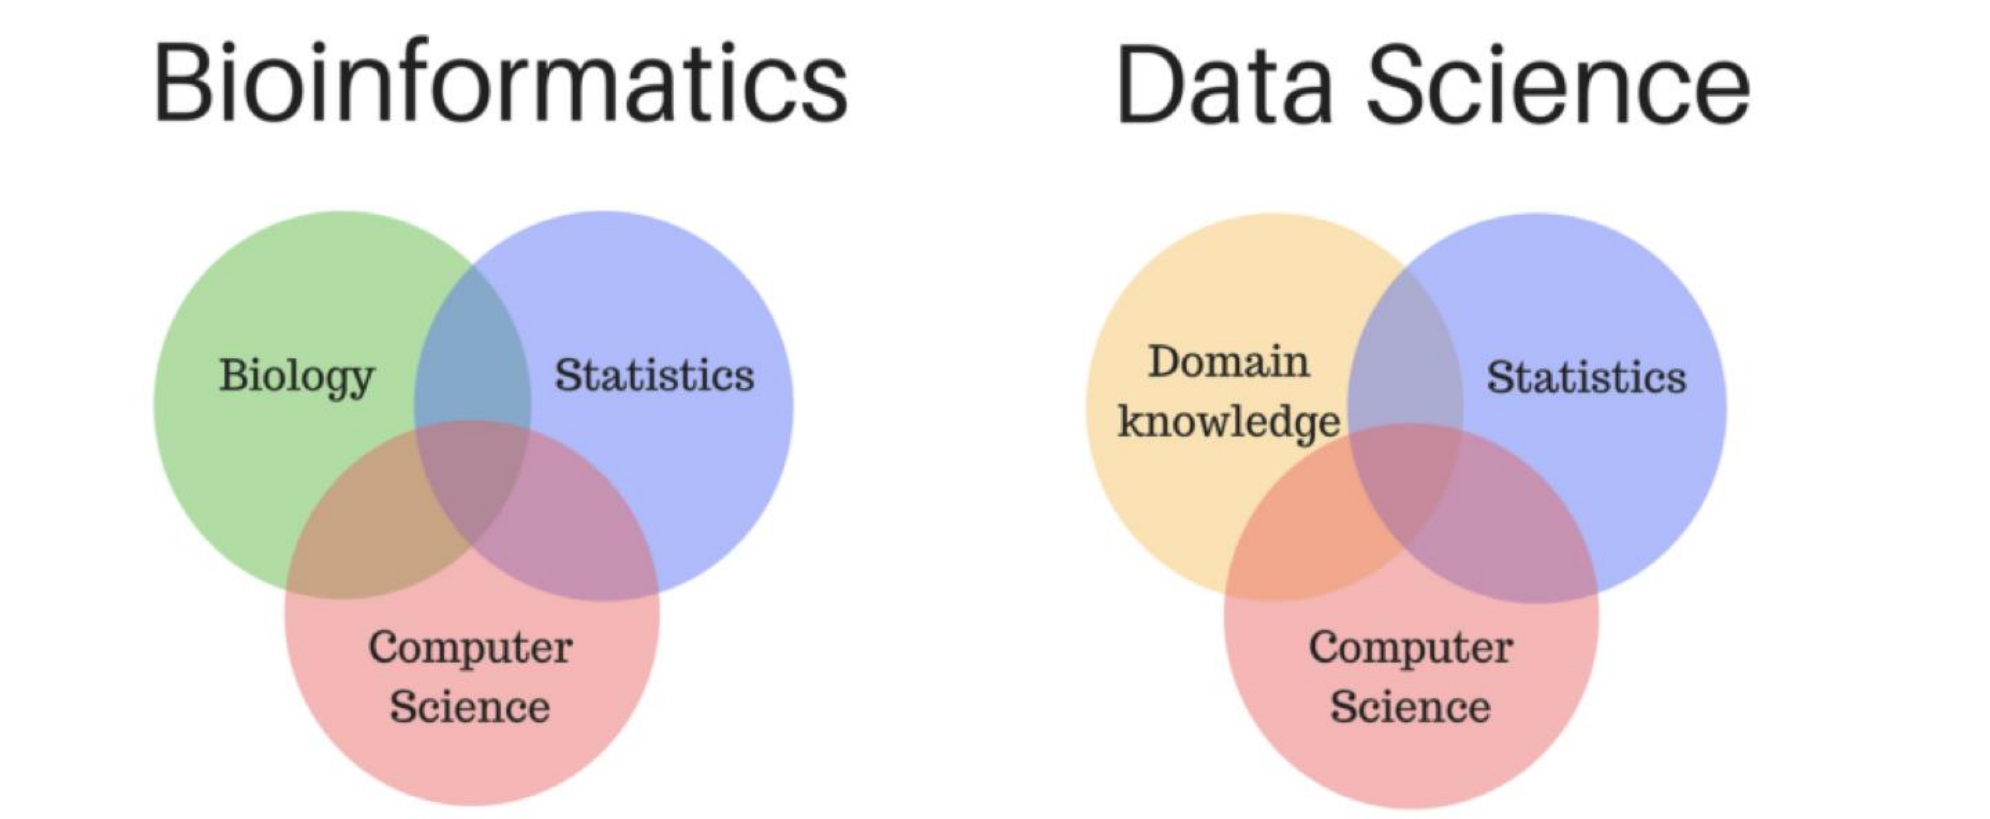
First base	Second base: U	Second base: C	Second base: A	Second base: G	Third base
U	Phe	Ser	Tyr	Cys	U
	Phe	Ser	Tyr	Cys	C
	Leu	Ser	Stop	Stop	A
	Leu	Ser	Stop	Trp	G
C	Leu	Pro	His	Arg	U
	Leu	Pro	His	Arg	C
	Leu	Pro	Gln	Arg	A
	Leu	Pro	Gln	Arg	G
A	Ile	Thr	Asn	Ser	U
	Ile	Thr	Asn	Ser	C
	Ile	Thr	Lys	Arg	A
	Met	Thr	Lys	Arg	G
G	Val	Ala	Asp	Gly	U
	Val	Ala	Asp	Gly	C
	Val	Ala	Glu	Gly	A
	Val	Ala	Glu	Gly	G

Qu’est ce que la bioinformatique



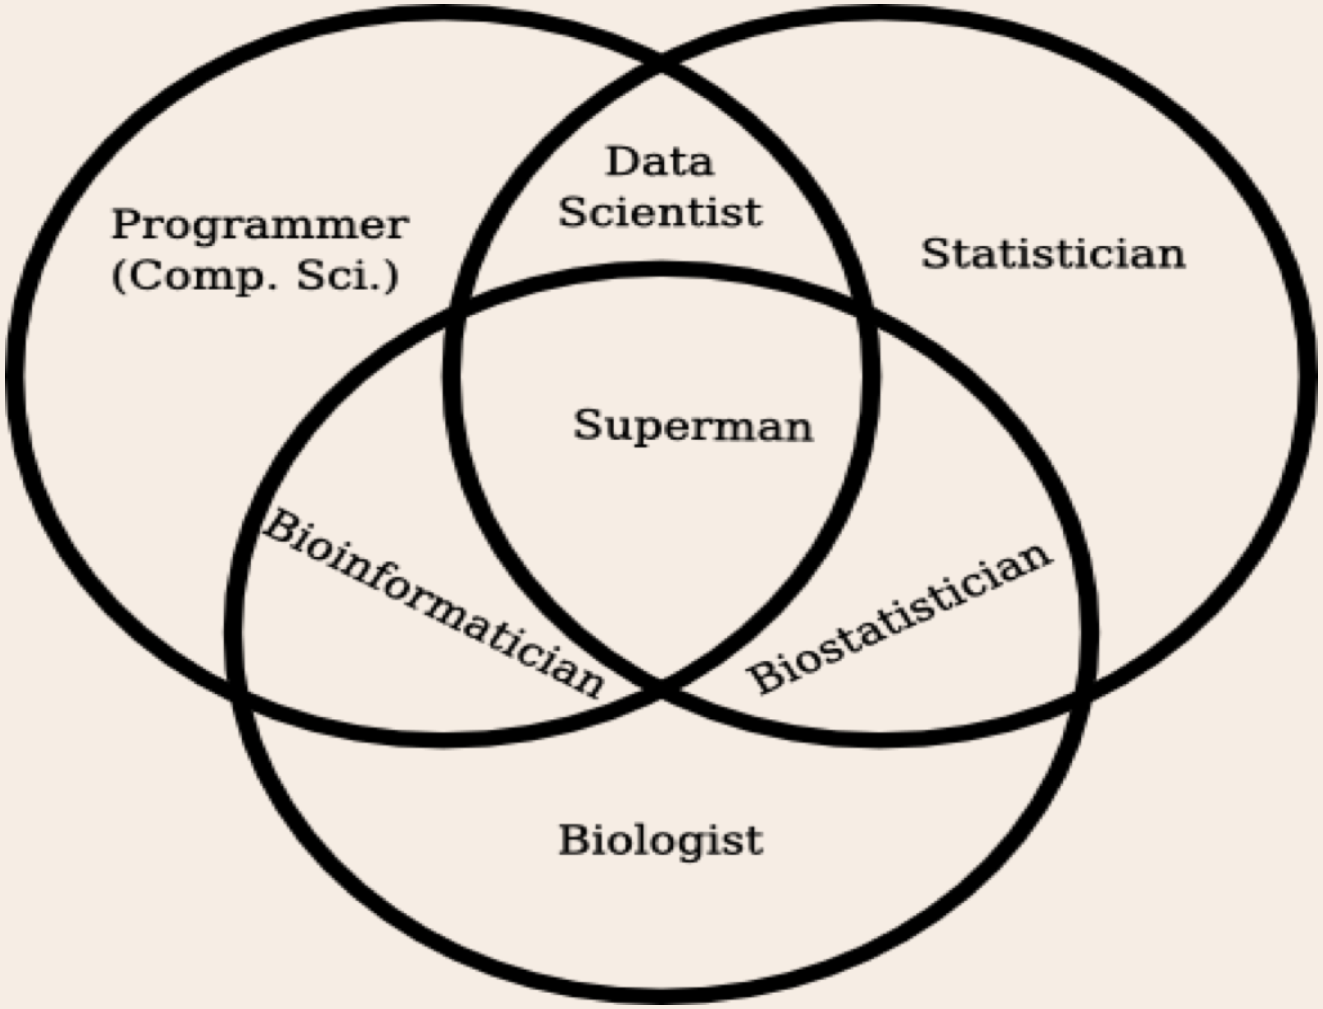
Frise chronologique

La Bioinformatique: une discipline à l'interface de plusieurs sciences



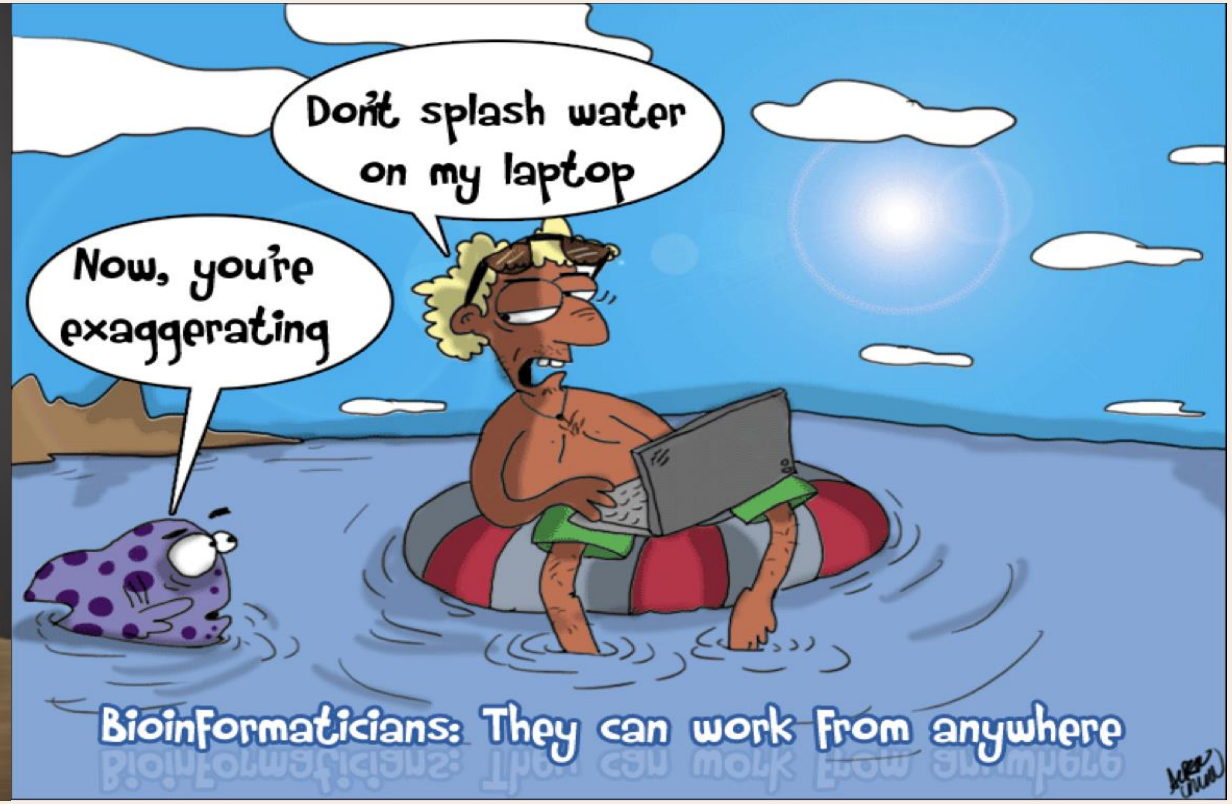
Analyse de données biologiques; développent d'application bioinformatique; modélisation du vivant

Qu’est ce qu’un bioinformaticien ?



Qu’est ce q’un bioinformaticien ?





4 grandes activités bioinformatiques

Organiser les données: BD, archivage, formats

Comparer les données

Modéliser les données

Interpréter les données

Pour quelles types de données ?

Des molécules aux écosystemes

De l'**ADN** aux génomes: gènes variations, chromosomes

De l'**ARN** : expression des gènes de différents organes ou conditions

De **protéines** : domaines, structure, fonctions, interactions

De **populations** : diversité, évolution, écologie

Quels outils pour quelles tâches?

- **NCBI, Uniprot** Recherche des séquences
- **BLAST** Séquences similaires
- **Bash, R, Python** Langage de programmation pour analyser, automatiser et visualiser l'information.
- **Navigateurs** Explorer les génomes
- **Cluster de calcul** Traitement des données (gros volumes).

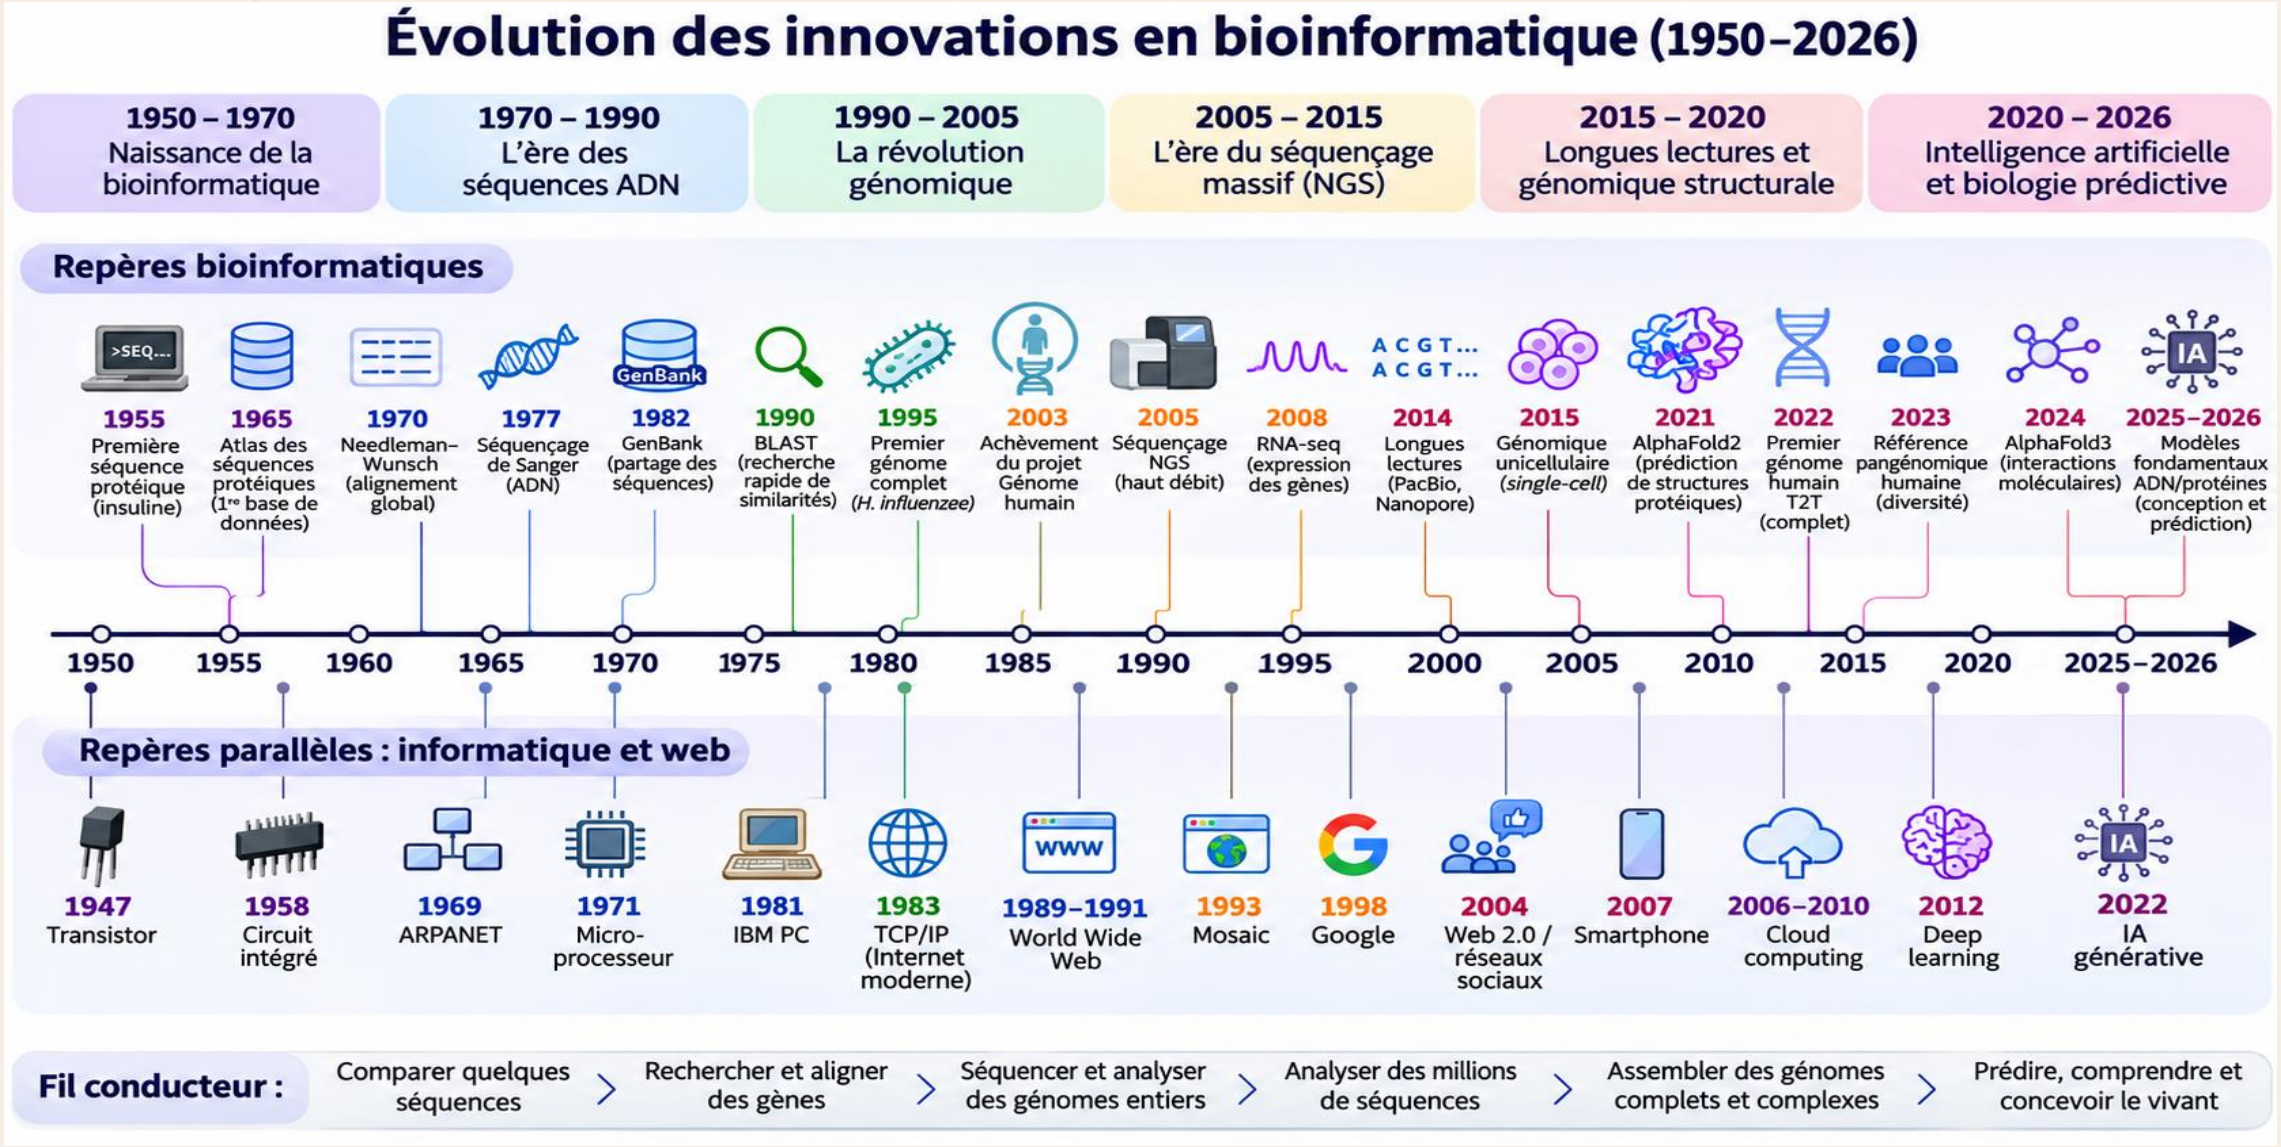
Origine de la bioinformatique



Margaret Dayhoff (1925-1983)

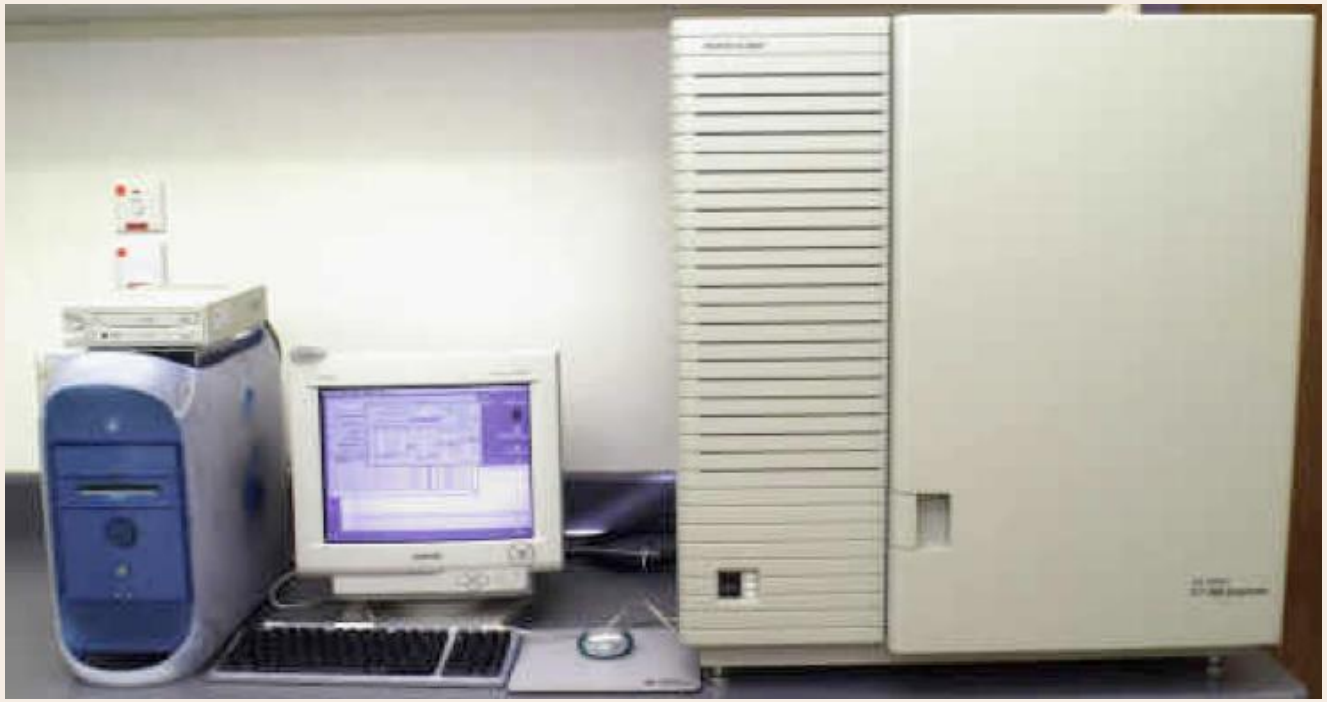
Pionnière dans l'application de méthodes mathématiques et informatiques dans le domaine du vivant.
Elle développe le code aminoacide, la phylogénie protéique, l'organisation des protéines en famille de silimarité, le système de base de données aminoacides et nucléotides, …
Développement des outils qui ont permis la fondation de la bioinformatique

Origines et évolution de la bioinformatique



Origines des données de séquence ADN

- Depuis 2005: l’ére du séquençage massif



Type: Sanger
Séquences: ~600 – 700 bp
384 séquences
5/10 $ / séquences
24h

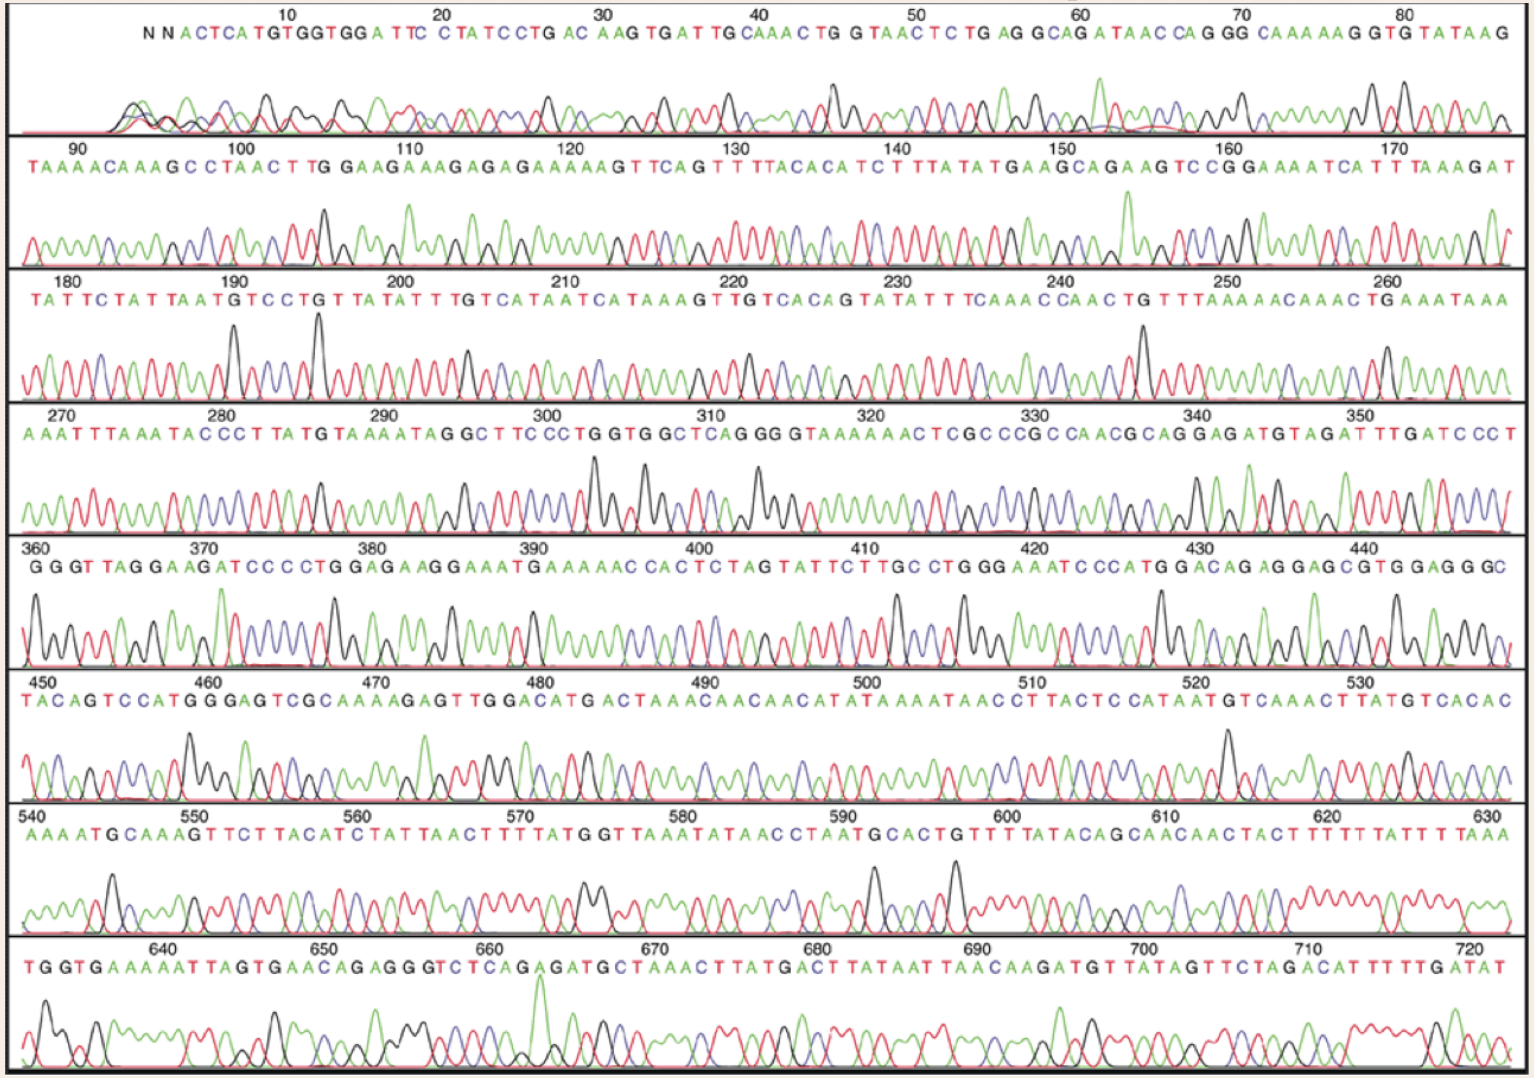
Origines des données de séquence ADN



Génome humain dans les années 2000
13 ans pour le premier séquençage
30 ans pour le séquençage parfait
Cout: 3 milliards $ pour le premier séquençage

Mais génération de 800 milliards de $ de retombés économiques

Origines des données de sequence ADN



Origines des données de sequence ADN

- Aujourd’hui 3 plateformes principales de séquençage:
- Illumina (séquences courtes, grand volume de données)
- PacBio (séquences longues, très bonne qualité)
- Oxford Nanopore (séquences très longues)

Origines des données de sequence ADN

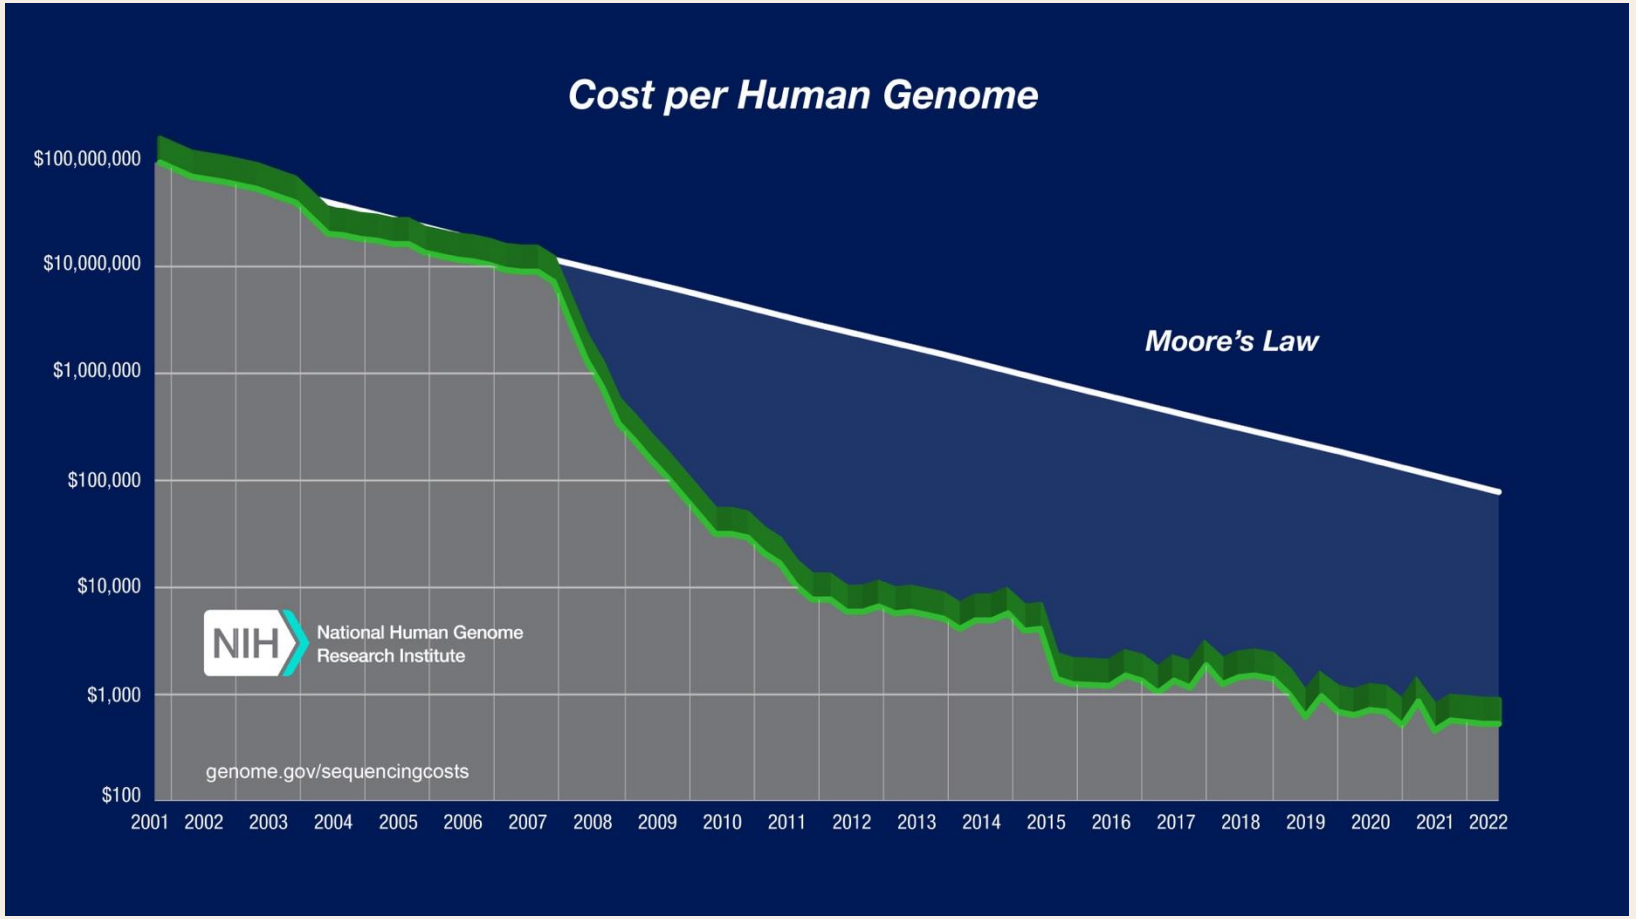
- Oxford Nanopore (séquences longues)



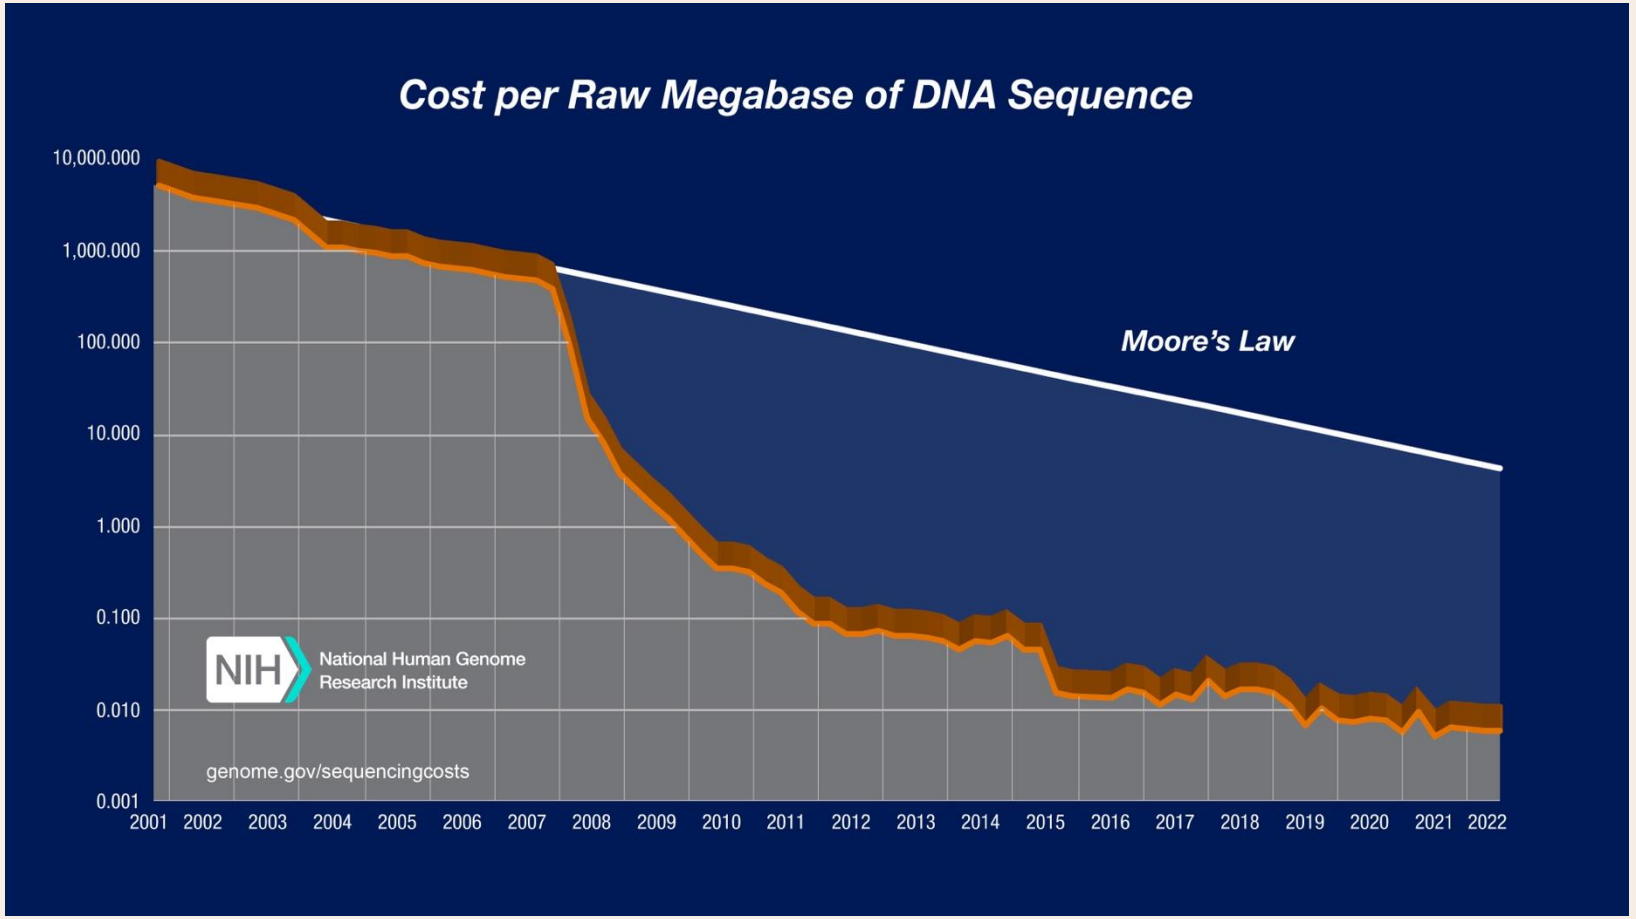
Type: Nanopore
Séquences: > 30 000 bp
Minion: max 48 Milliards de bases
Promethion: max 290 Milliards de bases
Soit entre 10 et 100 fois le génome humains en 72h



Couts des données de séquence ADN



Couts des données de séquence ADN



Couts des données de séquence ADN

Au NCBI: https://www.ncbi.nlm.nih.gov

GenBank (la division nucléotidique principale, incluant tous les assemblages de génomes validés et le WGS - *Whole Genome Shotgun*) pèse environ **13 021 Go**

La base de données de structure taxonomique du NCBI répertorie le matériel génétique et les génomes de plus de **557 000 espèces formalisées**

Cout du stockage:

Données accessibles: 12 millions/an

Données archivés: 2,4 millions/an

Pas de frais de transfert sortant

La bioinformatique, pourquoi faire ?

En **santé:** identification de variations, cancers pathogènes.

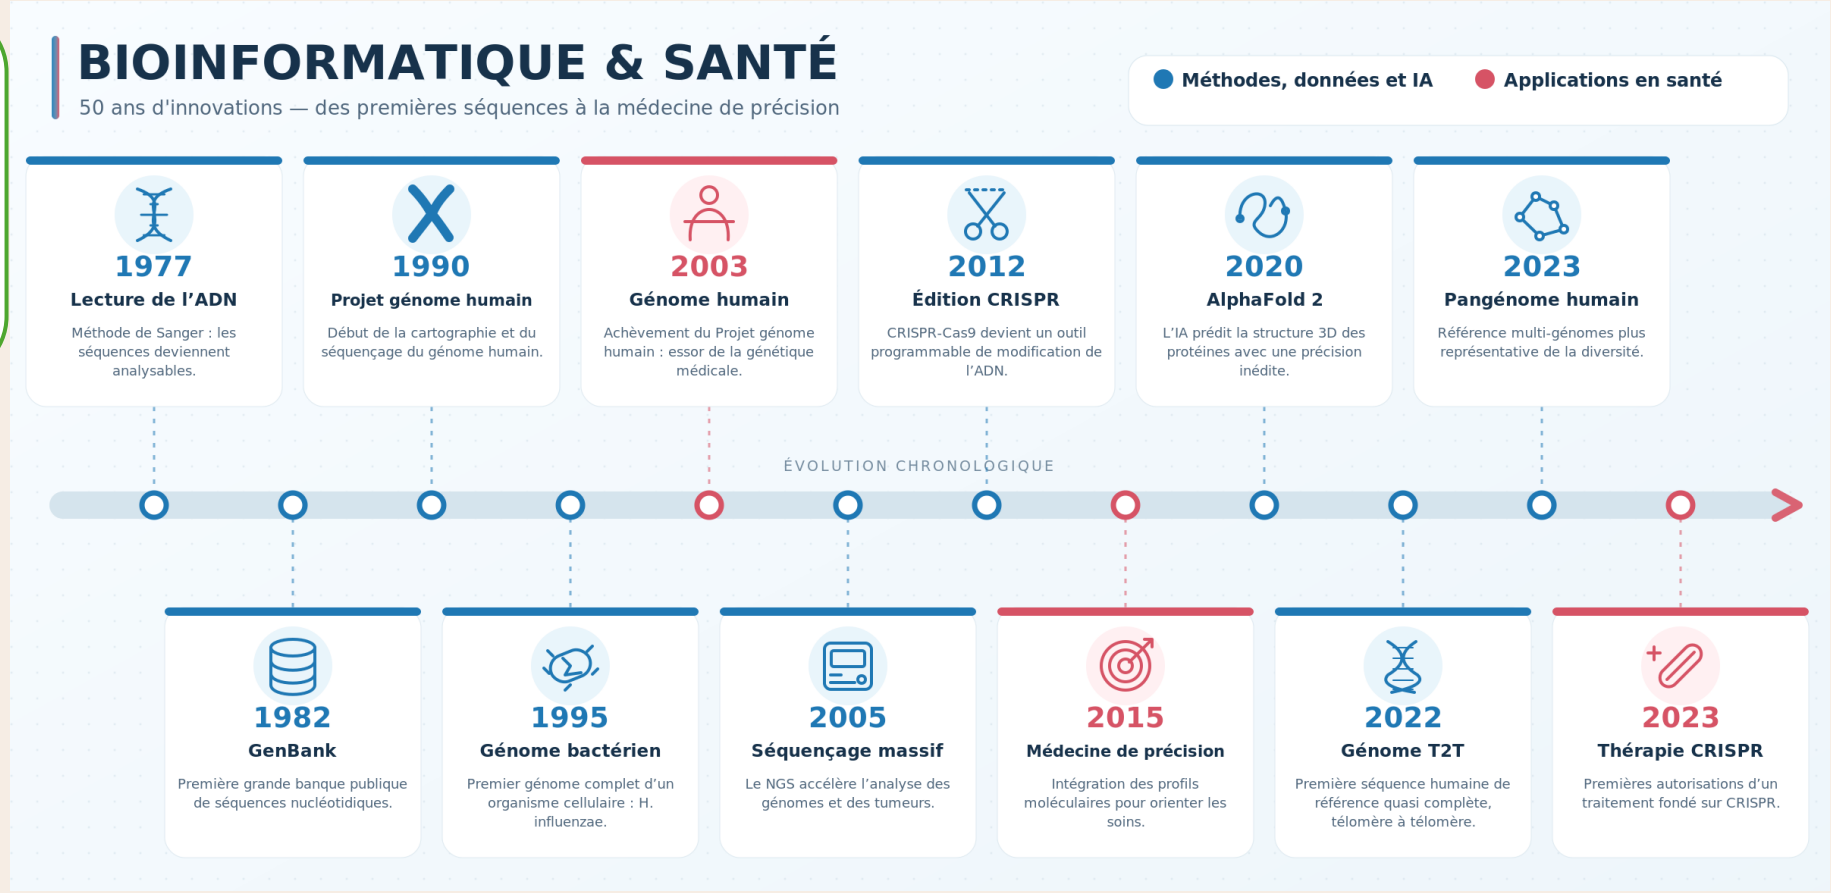
En **Agriculture**: sélection variétale et adaptation

En **Biodiversité**: Population, conservation, évolution

En **microbiologie**: microbiomes et résistances

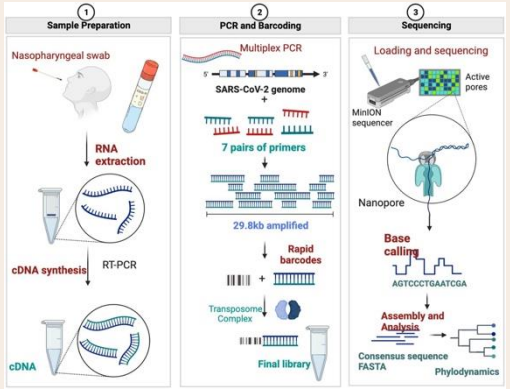
La bioinformatique, quelques exemples:

Santé



La bioinformatique, quelques exemples:

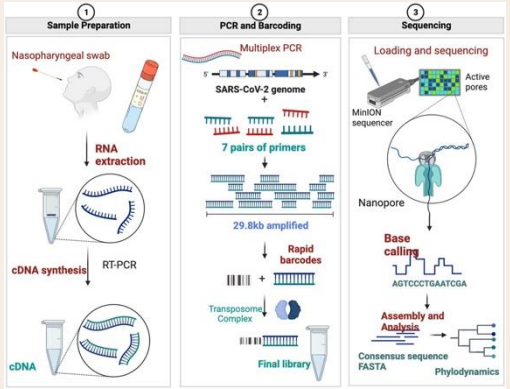
Santé



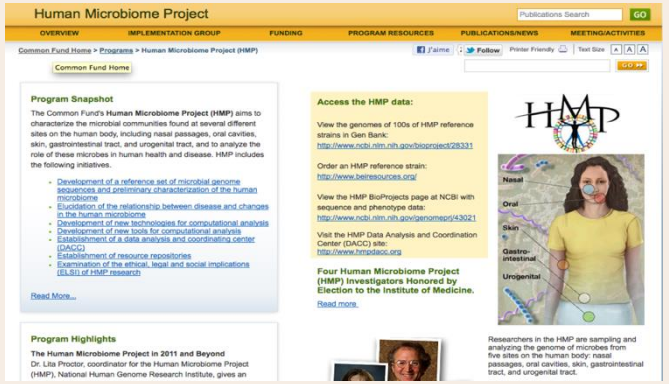
Surveiller les épidémies. Covid19. Le séquençage et la comparaison des génomes de virus permettent de détecter de nouveaux variants

La bioinformatique, quelques exemples:

Santé



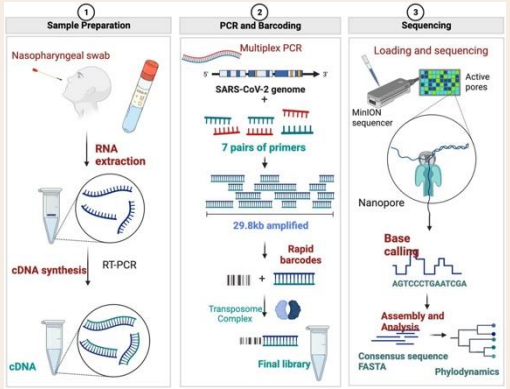
Surveiller les épidémies.
Covid19. Le séquençage et la comparaison des génomes de virus permettent de détecter de nouveaux variants



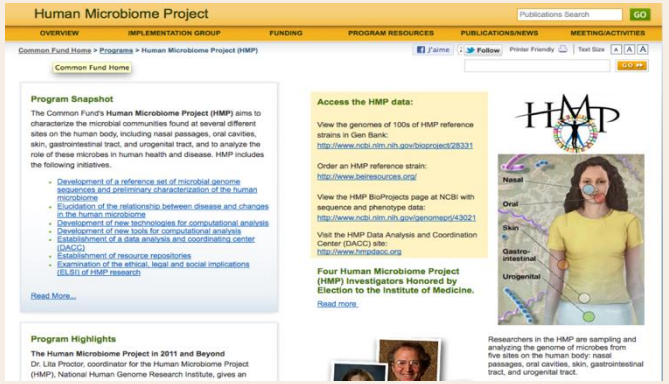
Étudier le microbiote intestinal
L'analyse de l'ADN des microorganismes présents dans l'intestin permet d'identifier les communautés bactériennes et leurs fonctions

La bioinformatique, quelques exemples:

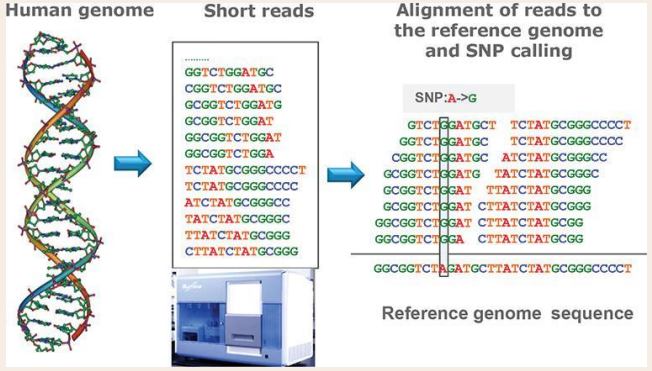
Santé



Surveiller les épidémies. Covid19. Le séquençage et la comparaison des génomes de virus permettent de détecter de nouveaux variants



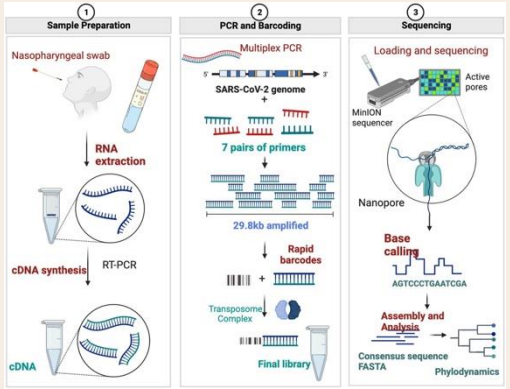
Diagnostiquer les maladies génétiques. Identifier des mutations responsables de maladies héréditaires, comme la mucoviscidose ou la drépanocytose



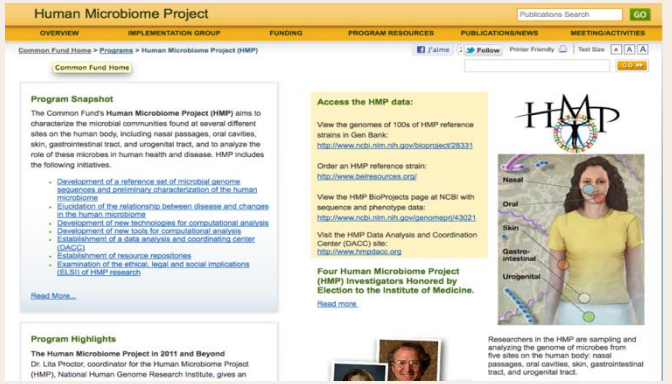
Étudier le microbiote intestinal
L'analyse de l'ADN des microorganismes présents dans l'intestin permet d'identifier les communautés bactériennes et leurs fonctions

La bioinformatique, quelques exemples:

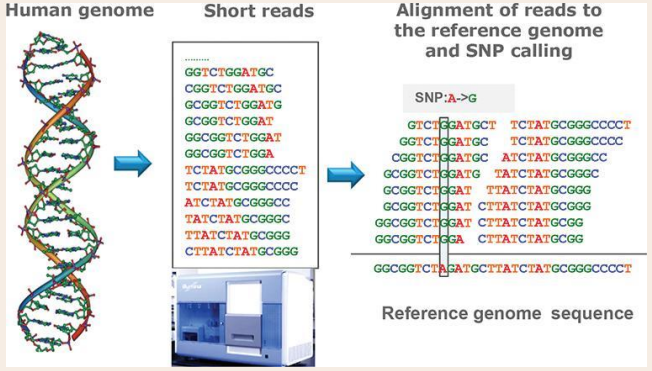
Santé



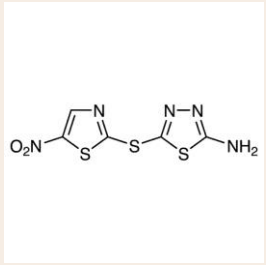
Surveiller les épidémies. Covid19. Le séquençage et la comparaison des génomes de virus permettent de détecter de nouveaux variants



Diagnostiquer les maladies génétiques. Identifier des mutations responsables de maladies héréditaires, comme la mucoviscidose ou la drépanocytose



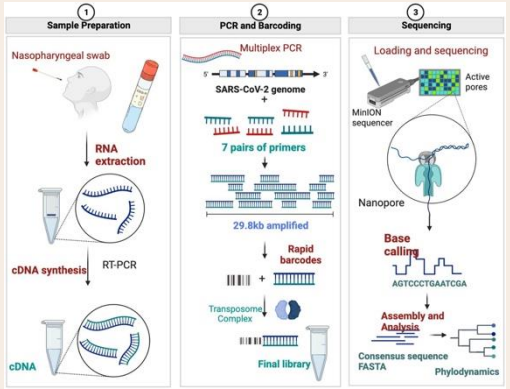
Étudier le microbiote intestinal
L'analyse de l'ADN des microorganismes présents dans l'intestin permet d'identifier les communautés bactériennes et leurs fonctions



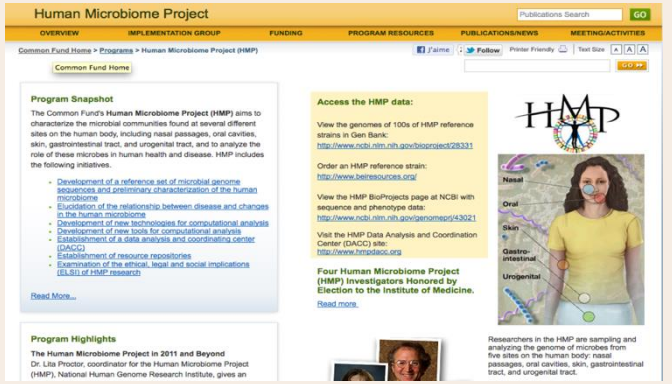
2020: Découverte de l'Halicine par IA in antibiotique expérimental. Entrainement sur 2300 molécule, apprentissage et prédiction

La bioinformatique, quelques exemples:

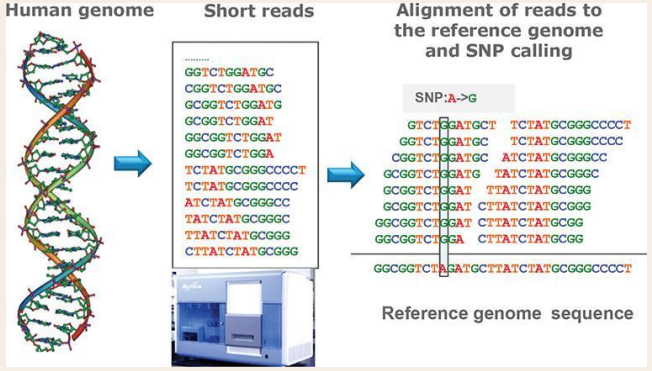
Santé



Surveiller les épidémies. Covid19. Le séquençage et la comparaison des génomes de virus permettent de détecter de nouveaux variants



Diagnostiquer les maladies génétiques. Identifier des mutations responsables de maladies héréditaires, comme la mucoviscidose ou la drépanocytose

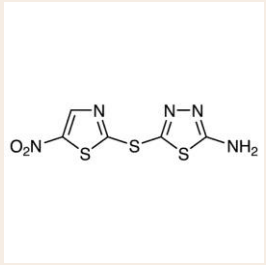




Étudier le microbiote intestinal

L'analyse de l'ADN des microorganismes présents dans l'intestin permet d'identifier les communautés bactériennes et leurs fonctions

Comprendre les protéines et développer des médicaments: Les outils comme AlphaFold permettent de prédire la structure tridimensionnelle de nombreuses protéines à partir de leur séquence.



2020: Découverte de l'Halicine par IA in antibiotique expérimental. Entrainement sur 2300 molécule, apprentissage et prédiction

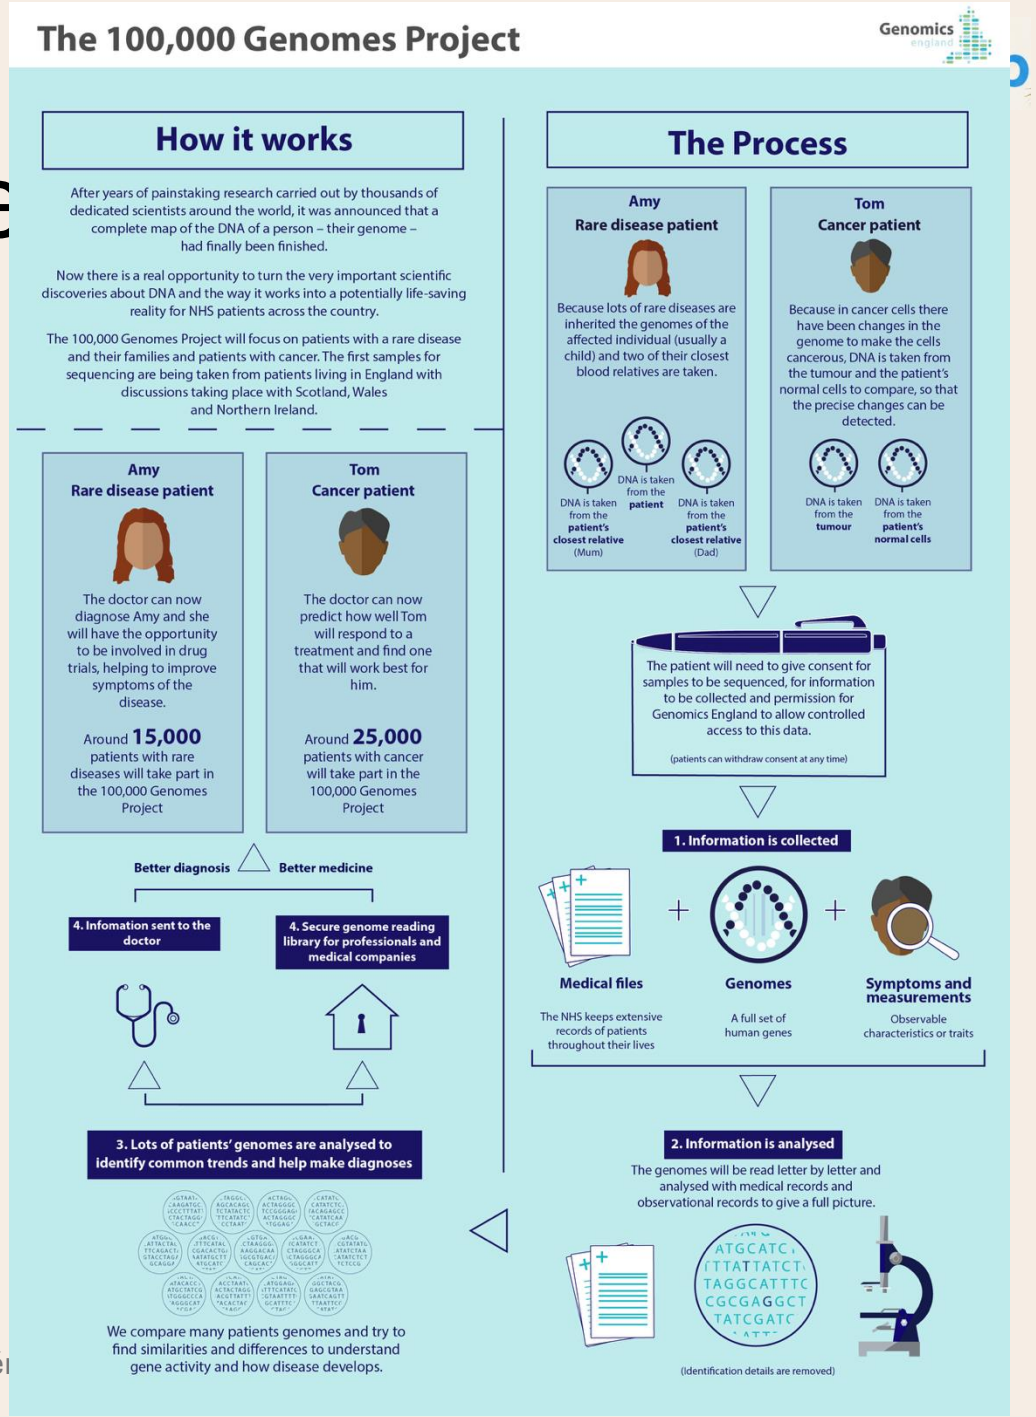
La bioinformatique, quelque

Santé



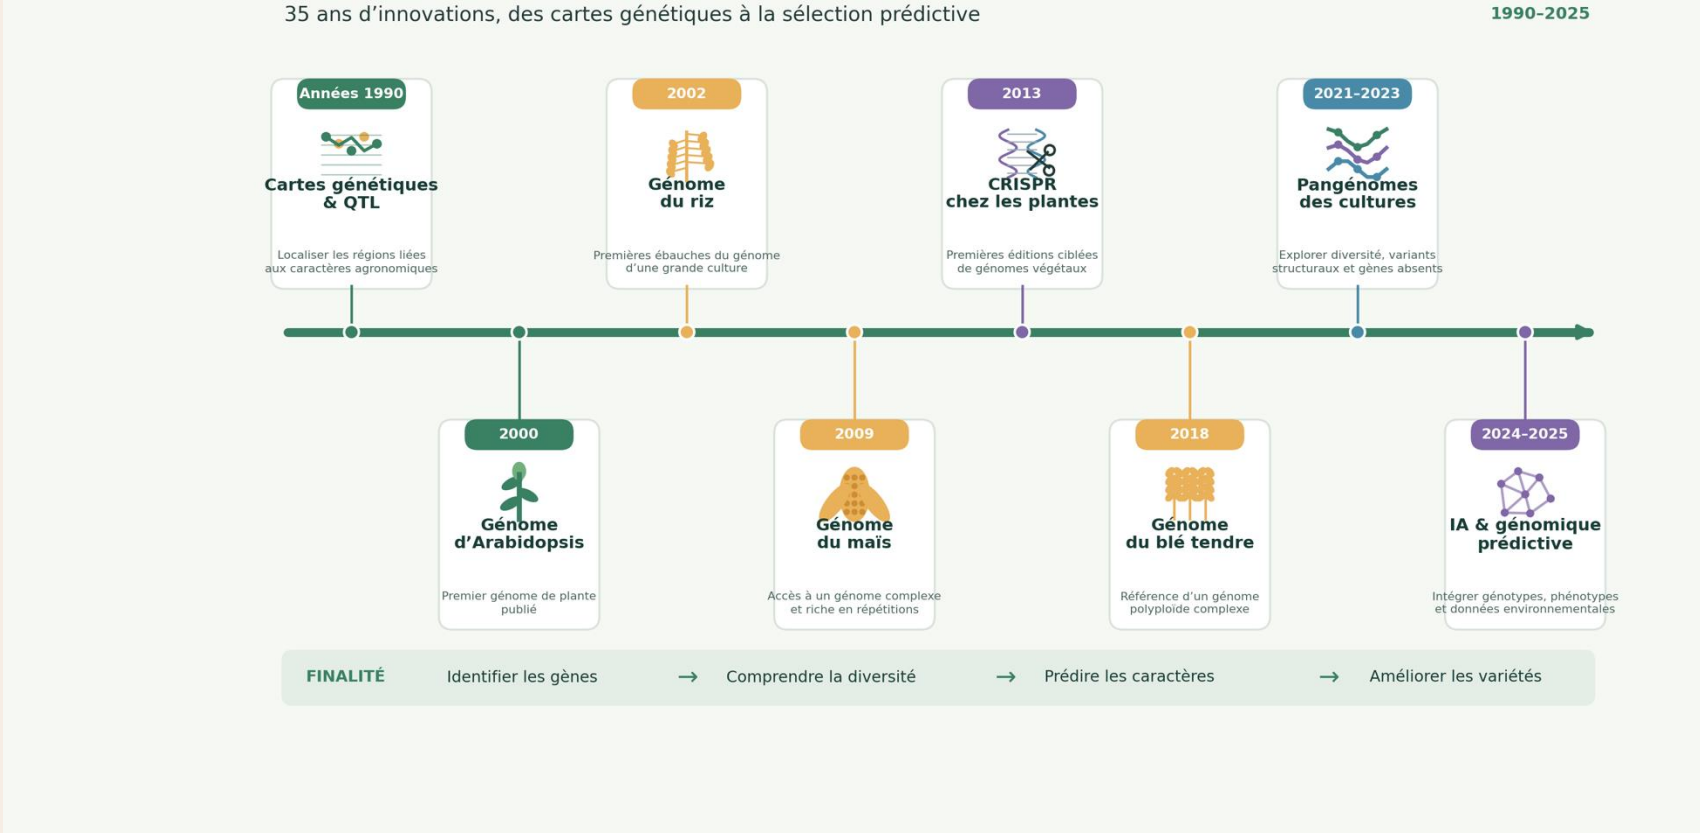
2012: séquencer 100 000 génomes issus de patients du National Health Service (NHS) pour identifier des maladies rares, cancers et développer à terme la médecine personnalisée.

https://www.genomicsengland.co.uk/initiatives/100000-genomes-project



La bioinformatique, quelques exemples:

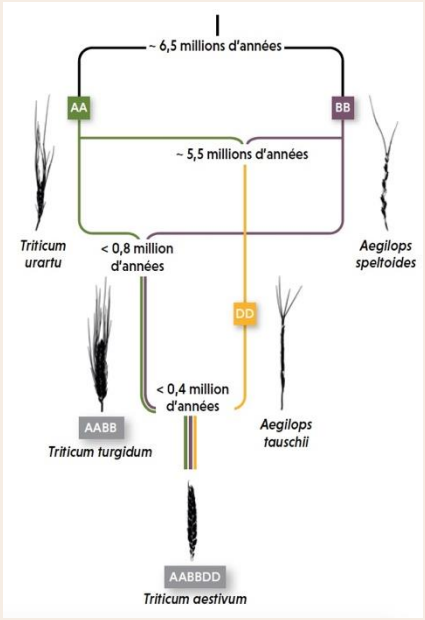
Agriculture



La bioinformatique, quelques exemples:

Agriculture

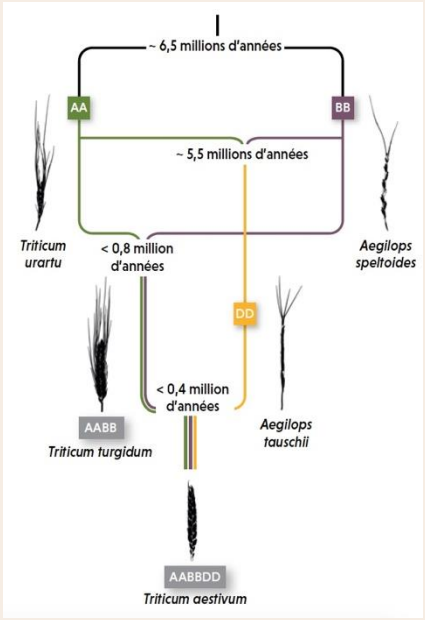
2018: projet Génome du Blé. Espèce hexaploïde plus grande que le génome humain (5X), permettant d'identifier les gènes d résistances et de qualité du grain. https://www.wheatgenome.org/

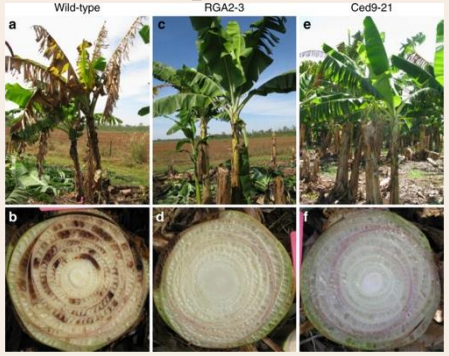


La bioinformatique, quelques exemples:

Agriculture

2018: projet Génome du Blé. Espèce hexaploïde plus grande que le génome humain (5X), permettant d'identifier les gènes d résistances et de qualité du grain. https://www.wheatgenome.org/



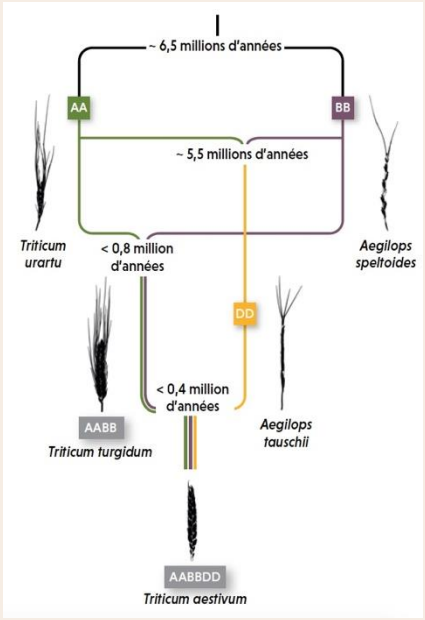


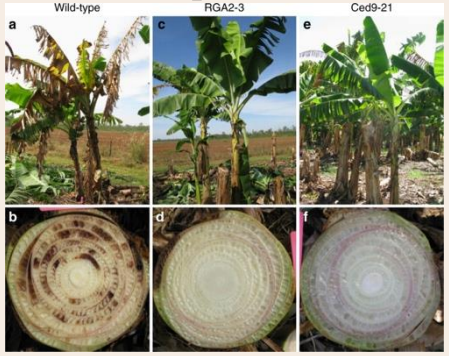
2017: Identifier le gène de résistance (RGA2) au champignon fusarium dans une espèce sauvage de bananier. https://pmc.ncbi.nlm.nih.gov/articles/PMC5684404/

La bioinformatique, quelques exemples:

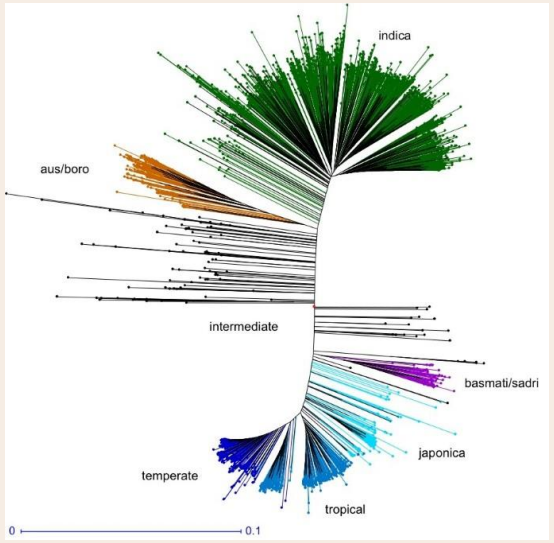
Agriculture

2018: projet Génome du Blé. Espèce hexaploïde plus grande que le génome humain (5X), permettant d'identifier les gènes d résistances et de qualité du grain. https://www.wheatgenome.org/





2017: Identifier le gène de résistance (RGA2) au champignon fusarium dans une espèce sauvage de bananier. https://pmc.ncbi.nlm.nih.gov/articles/PMC5684404/

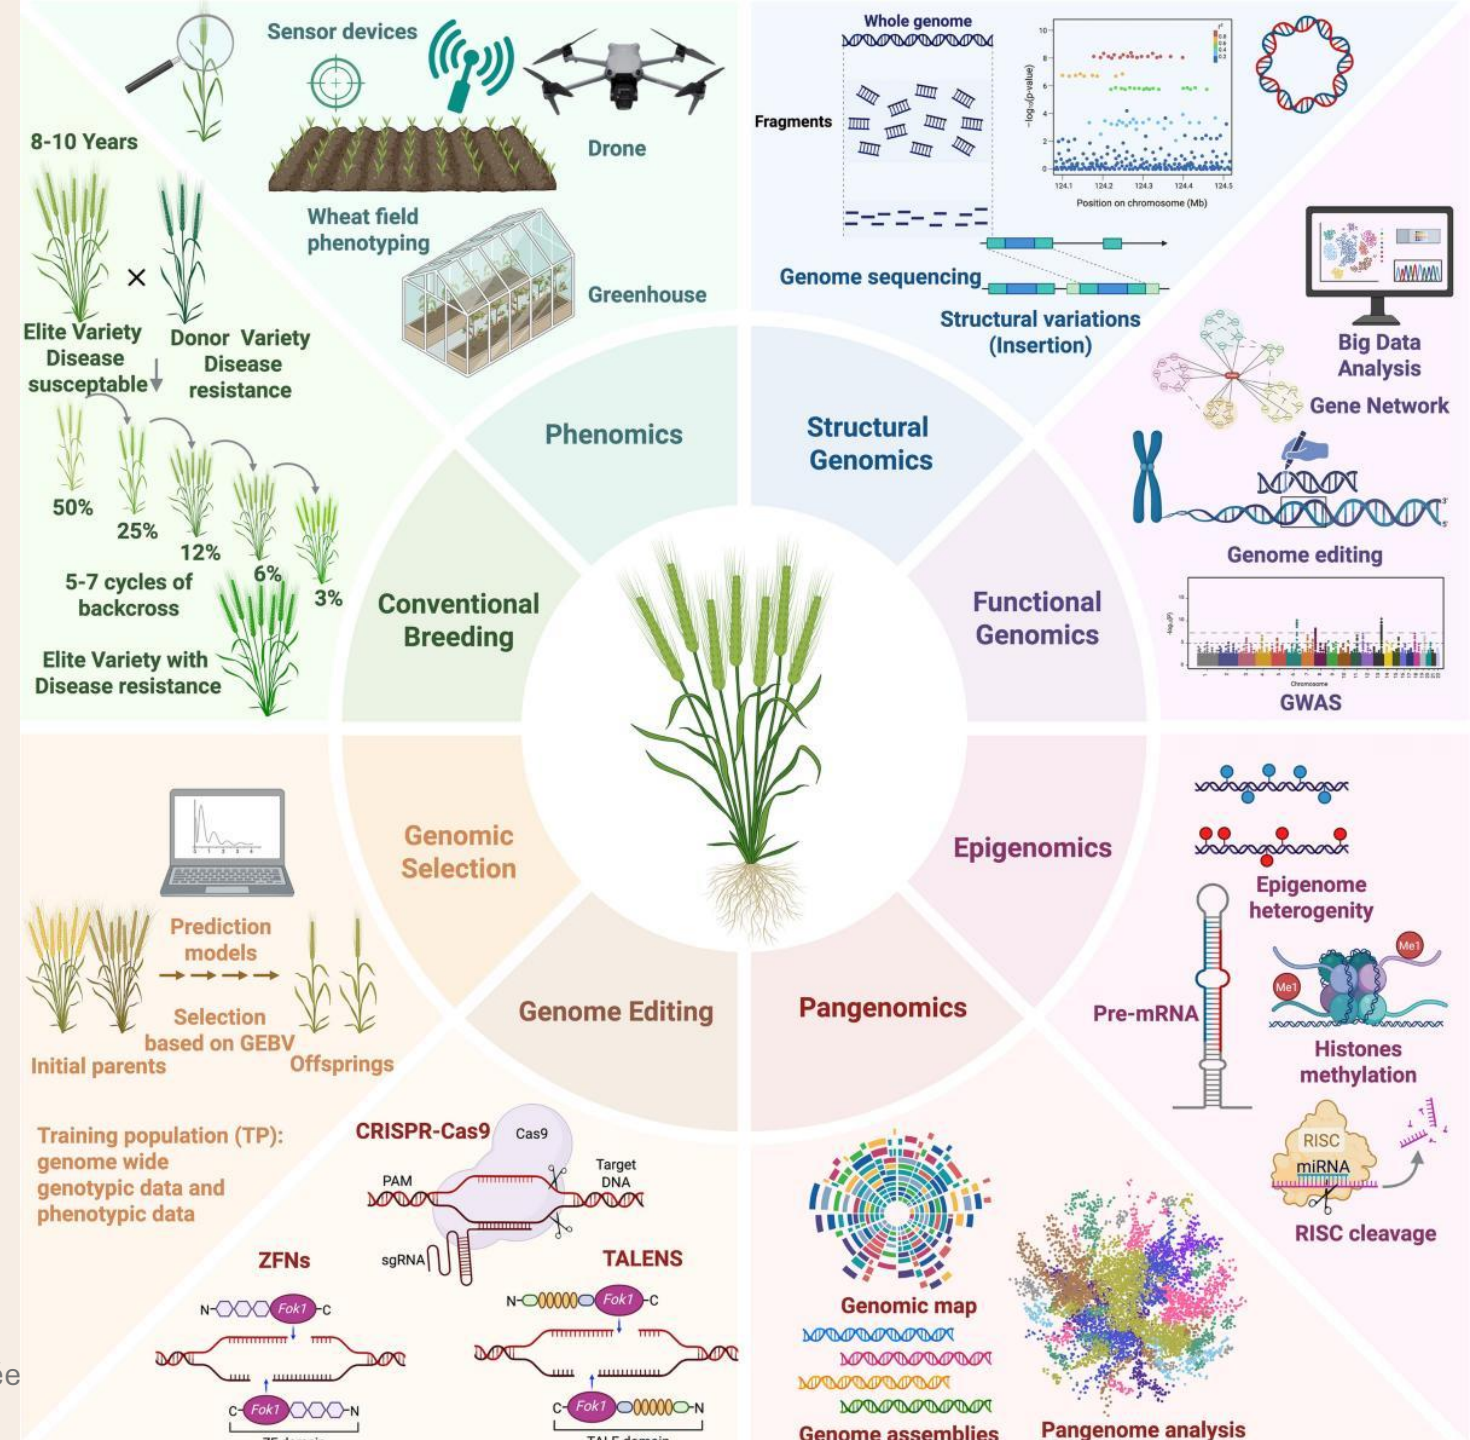


projet 3,000 *Rice Genomes*: Découverte de 19 millions de SNP, permettant la selection de riz plus résistants. https://gigadb.org/dataset/200001



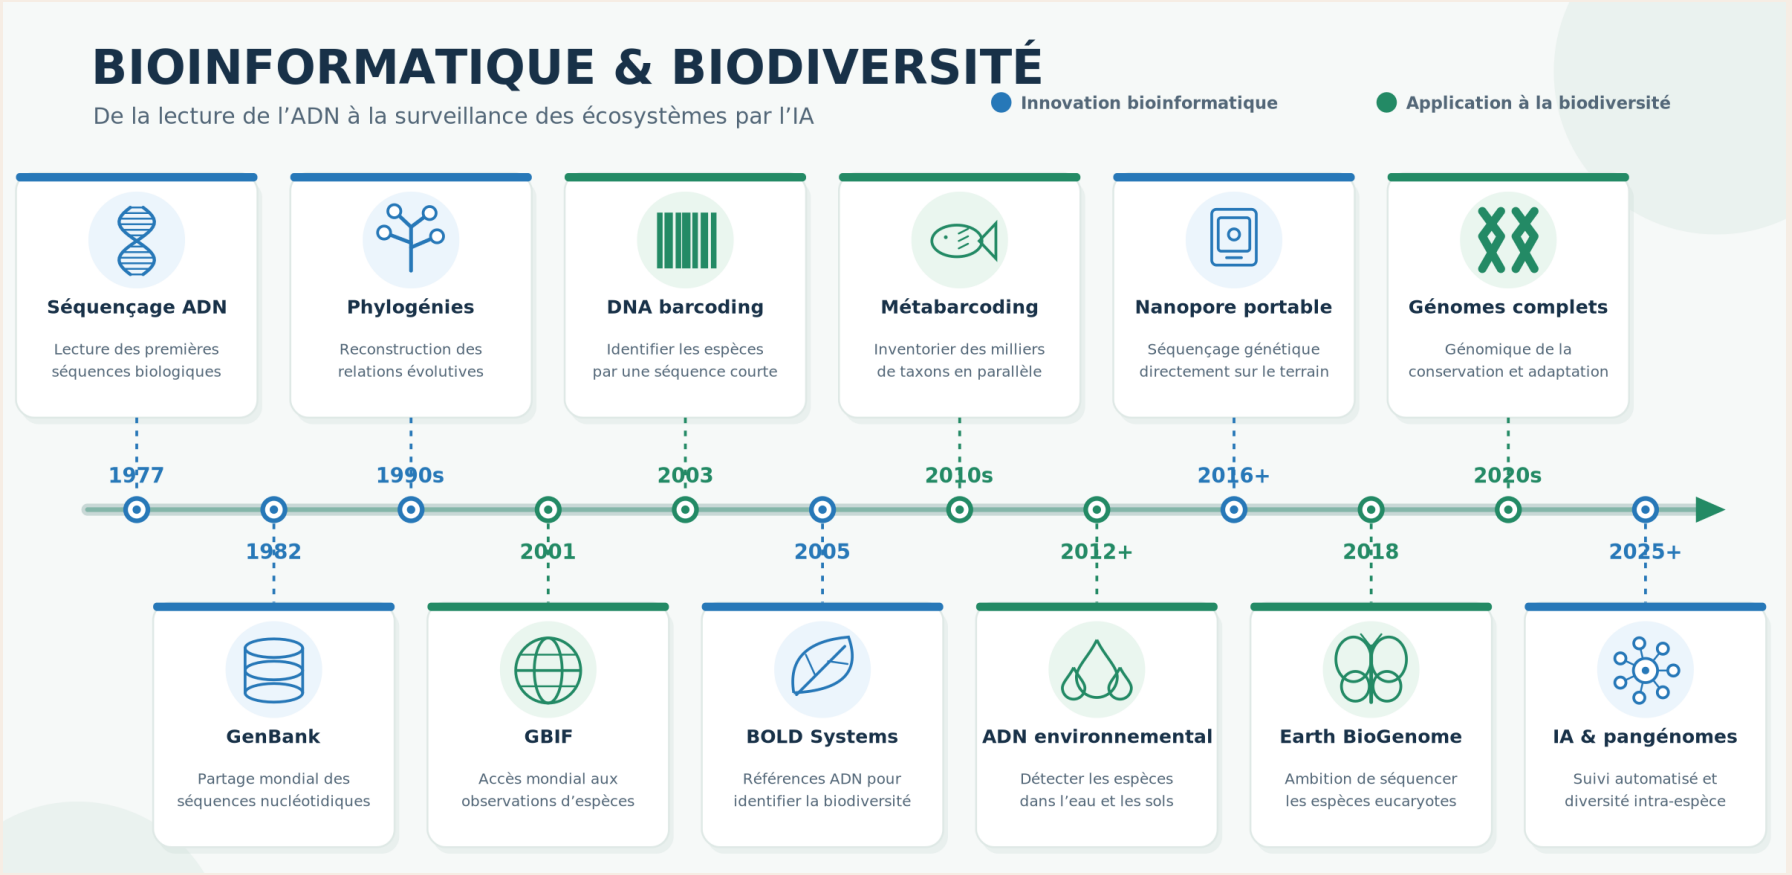
Mais aussi accélérer la création de variétés (Manioc) de variétés tolérantes à la sécheresse (Mais, Café) et exploiter la diversité génétique des espèces sauvages

Agriculture



La bioinformatique, quelques exemples:

Biodiversité

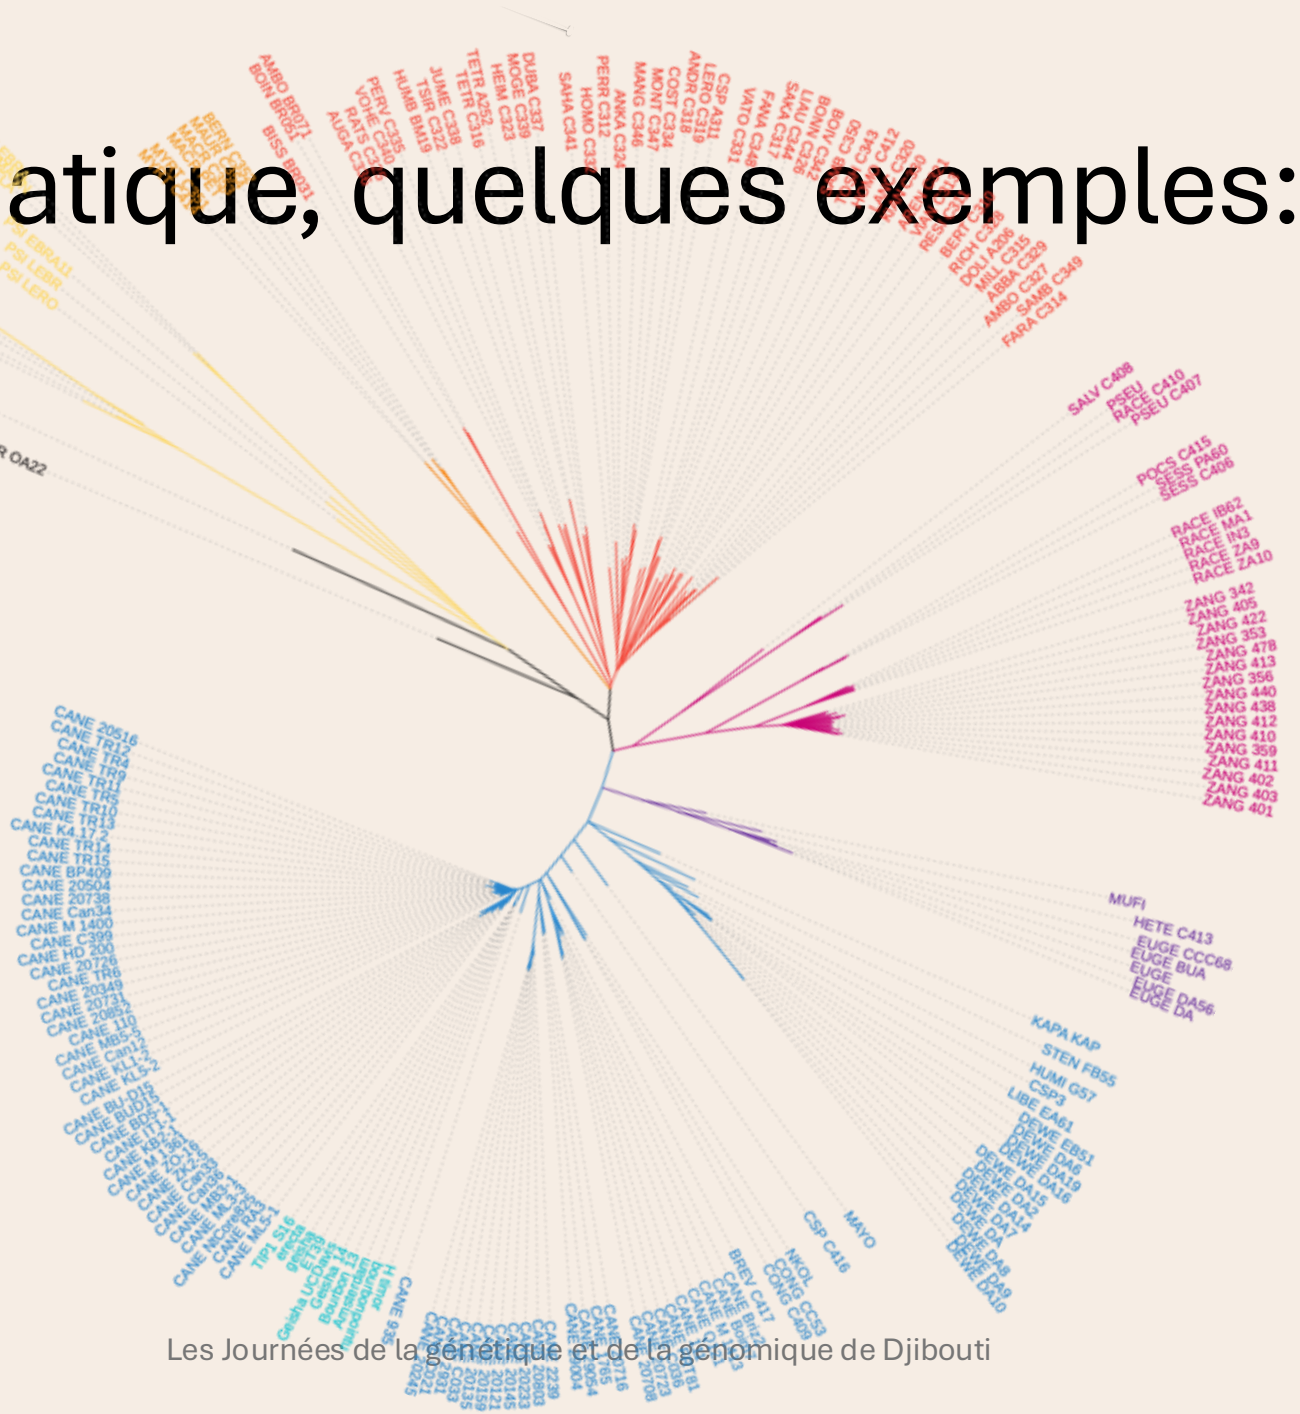


La bioinformatique, quelques exemples:

Biodiversité



Découvrir la biodiversité invisible grâce à l'ADN environnemental (ADNe)



6,708,319
SNP markers

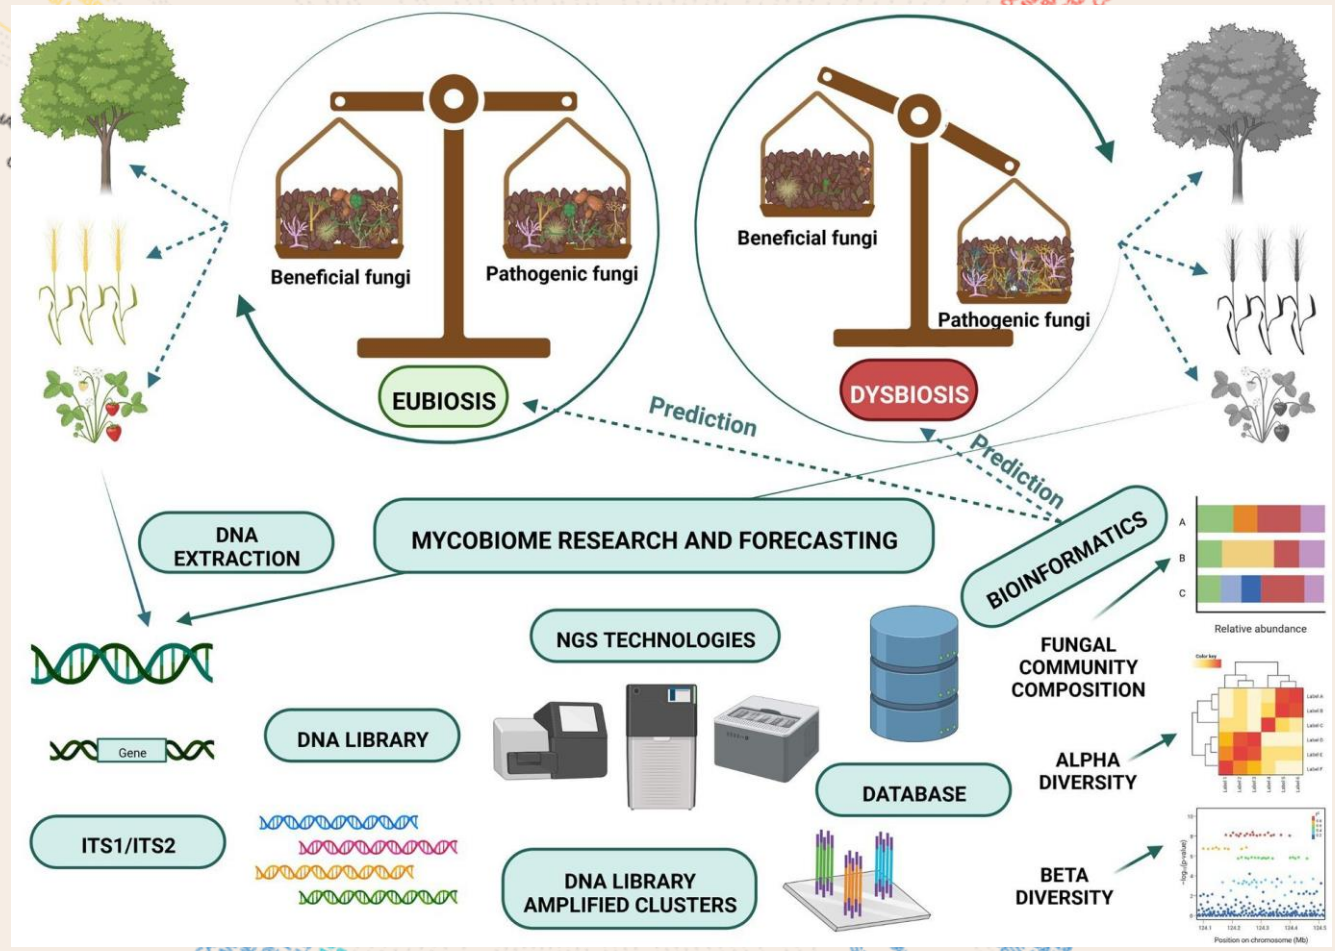
Reconstituer l'histoire évolutive du vivant, identifier des lignées distinctes et étudier l'apparition de nouveaux caractères

La bioinformatique, quelques exemples:

Biodiversité



Découvrir la biodiversité invisible grâce à l'ADN environnemental (ADNe)



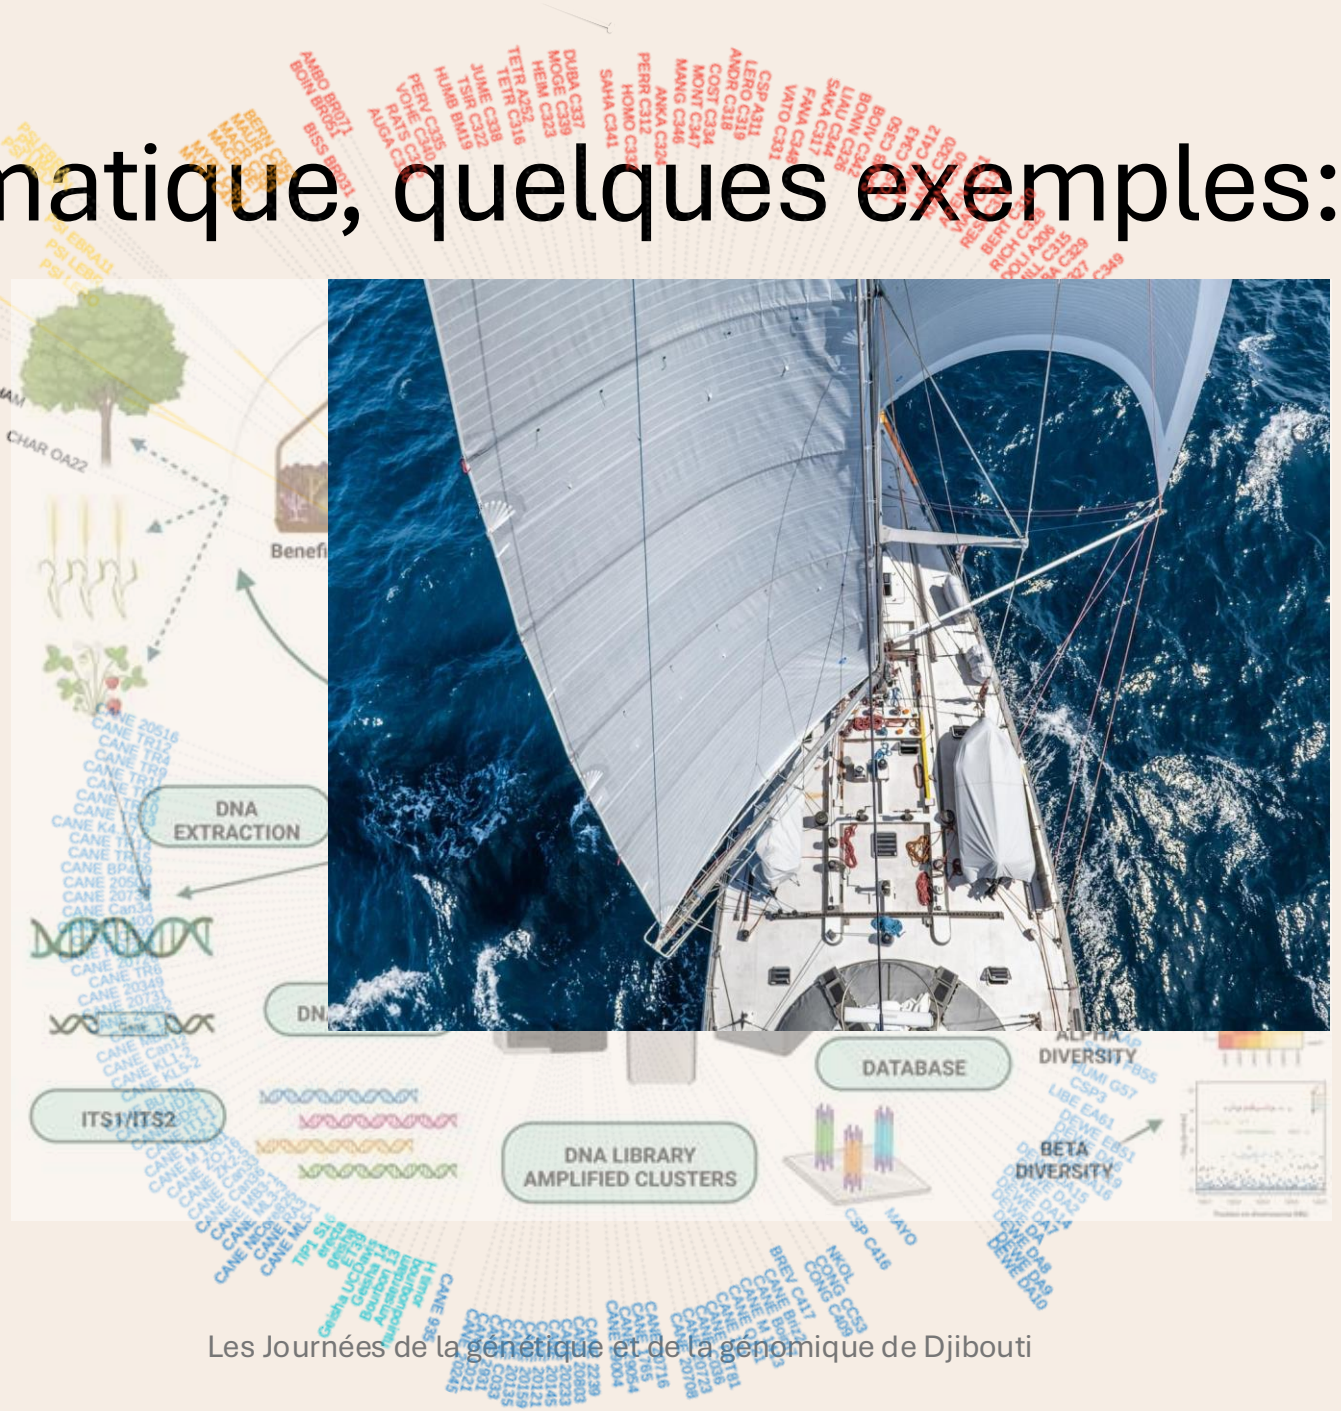
Explorer la biodiversité microbienne par la métagénomique et son utilisation

La bioinformatique, quelques exemples:

Biodiversité



Découvrir la biodiversité invisible grâce à l'ADN environnemental (ADNe)

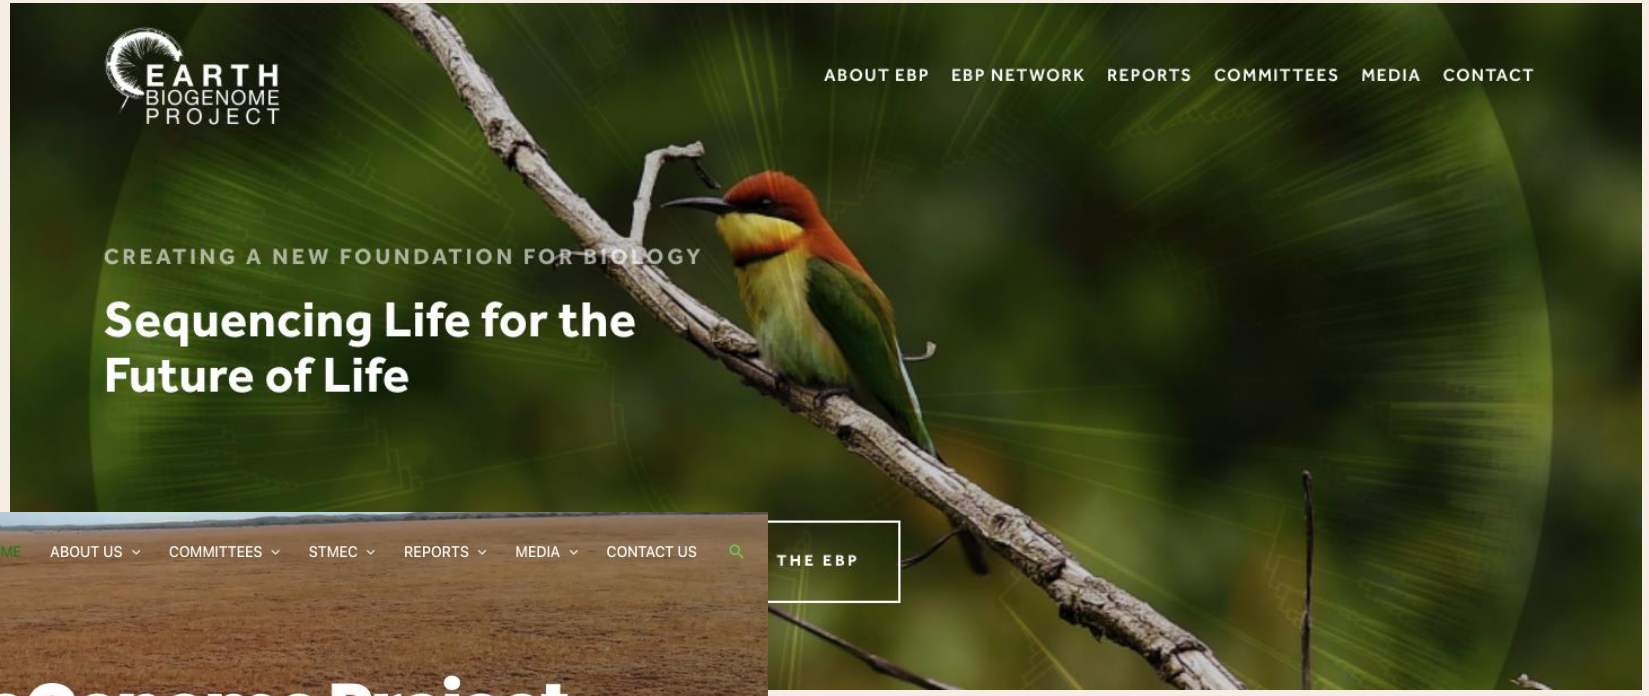


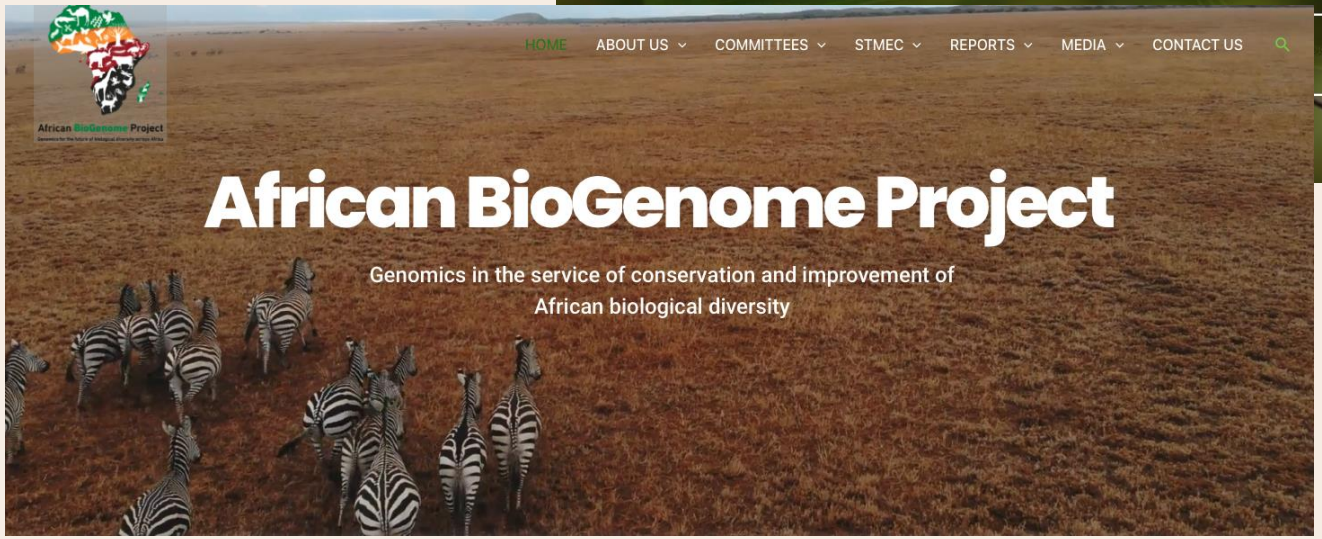
Projet Tara Oceans (2009-2013): 25 000 échantillons, 150000 types de protiste, 40 millions de gènes microbiens inconnus,

https://fondationtaraocean.org/expedition/tara-oceans/

La bioinformatique, quelques exemples:

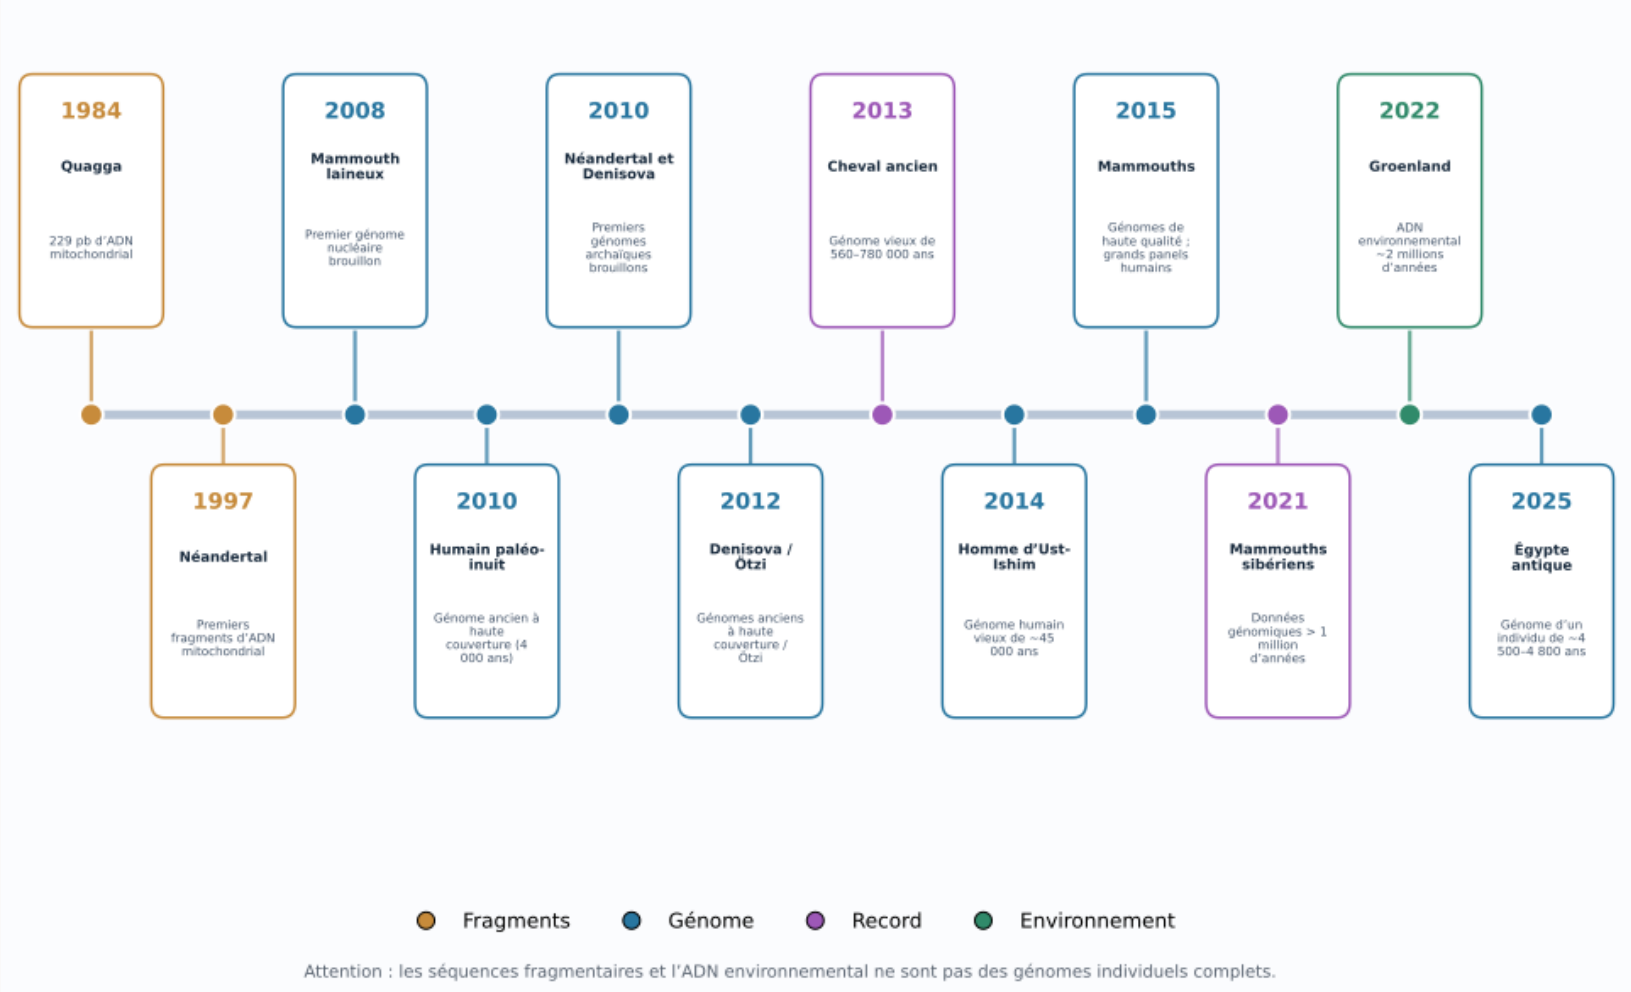
Biodiversité





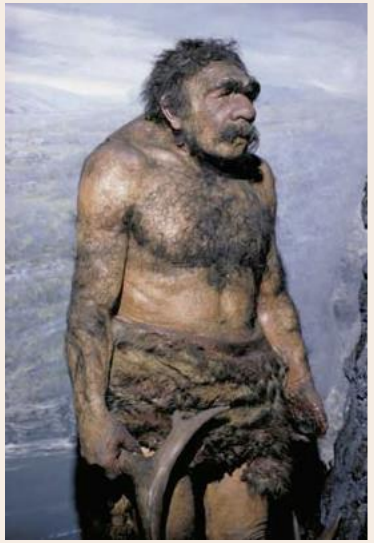
La bioinformatique, quelques exemples:

ADN ancien
(paléogénomique)

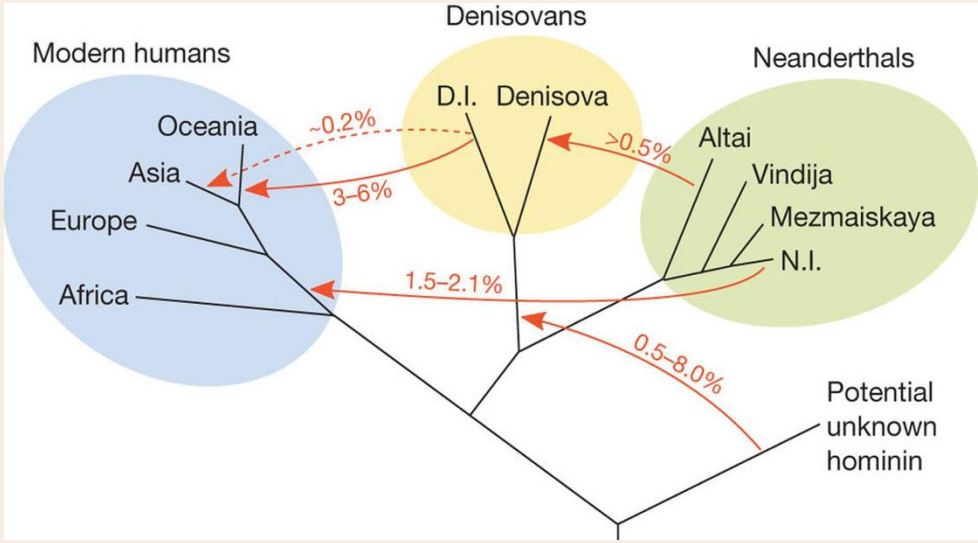


La bioinformatique, quelques exemples:

ADN ancien
(paléogénomique)



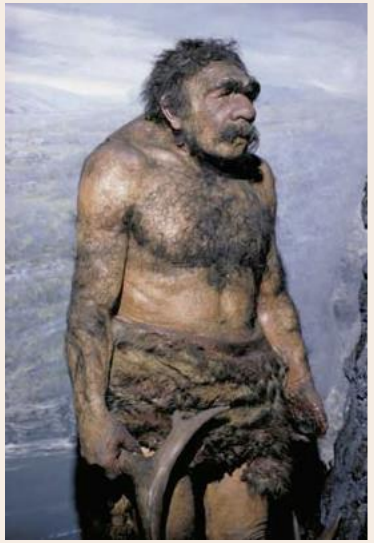




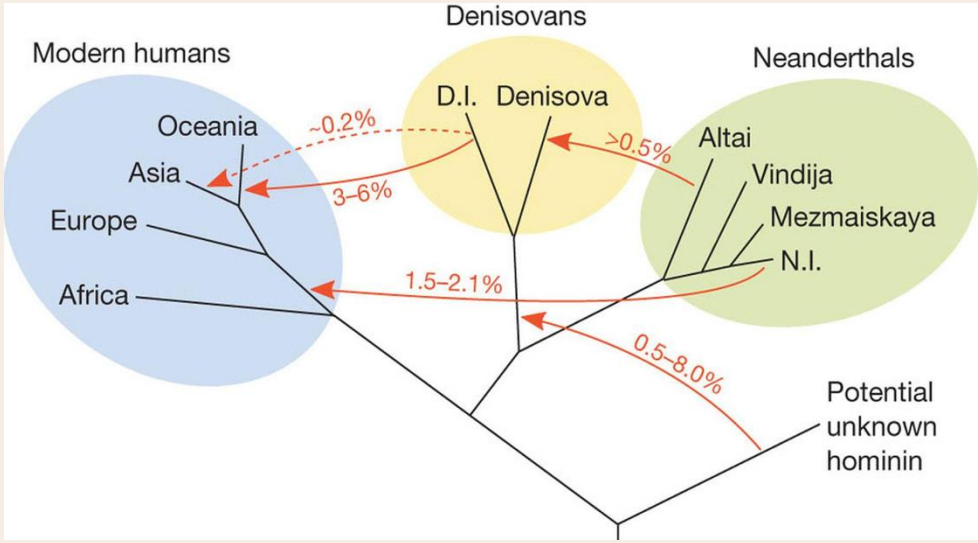
Découverte du génome de l'homme de Denisova (200 000 ans) et de l'histoire de l'hybridation humaine

La bioinformatique, quelques exemples:

ADN ancien
(paléogénomique)







Découverte du génome de l'homme de Denisova (200 000 ans) et de l'histoire de l'hybridation humaine

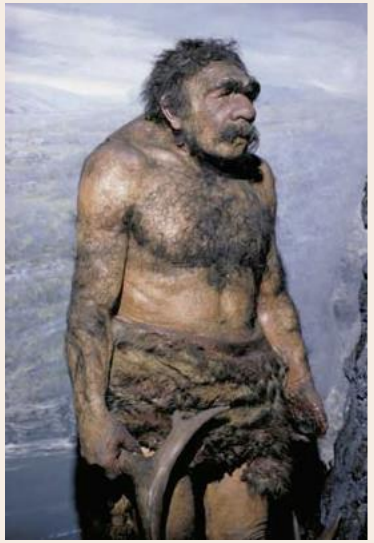
Séquençage d'herbier *(C. arabica)*



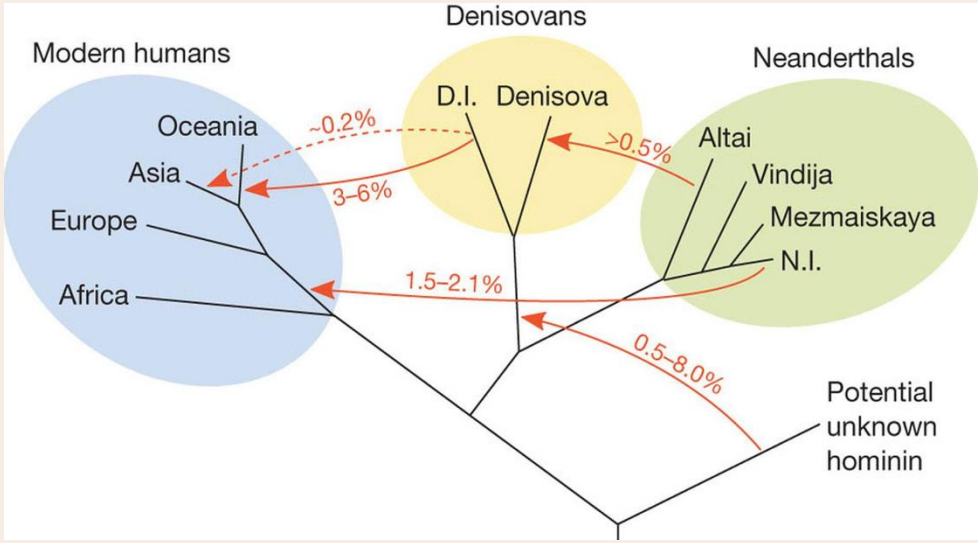


La bioinformatique, quelques exemples:

ADN ancien
(paléogénomique)





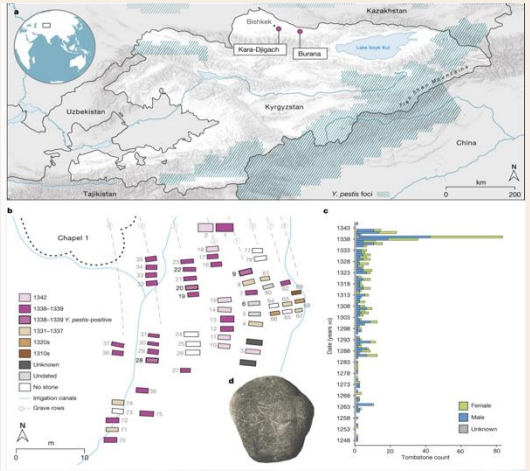


Découverte du génome de l'homme de Denisova (200 000 ans) et de l'histoire de l'hybridation humaine

Séquençage d'herbier *(C. arabica)*





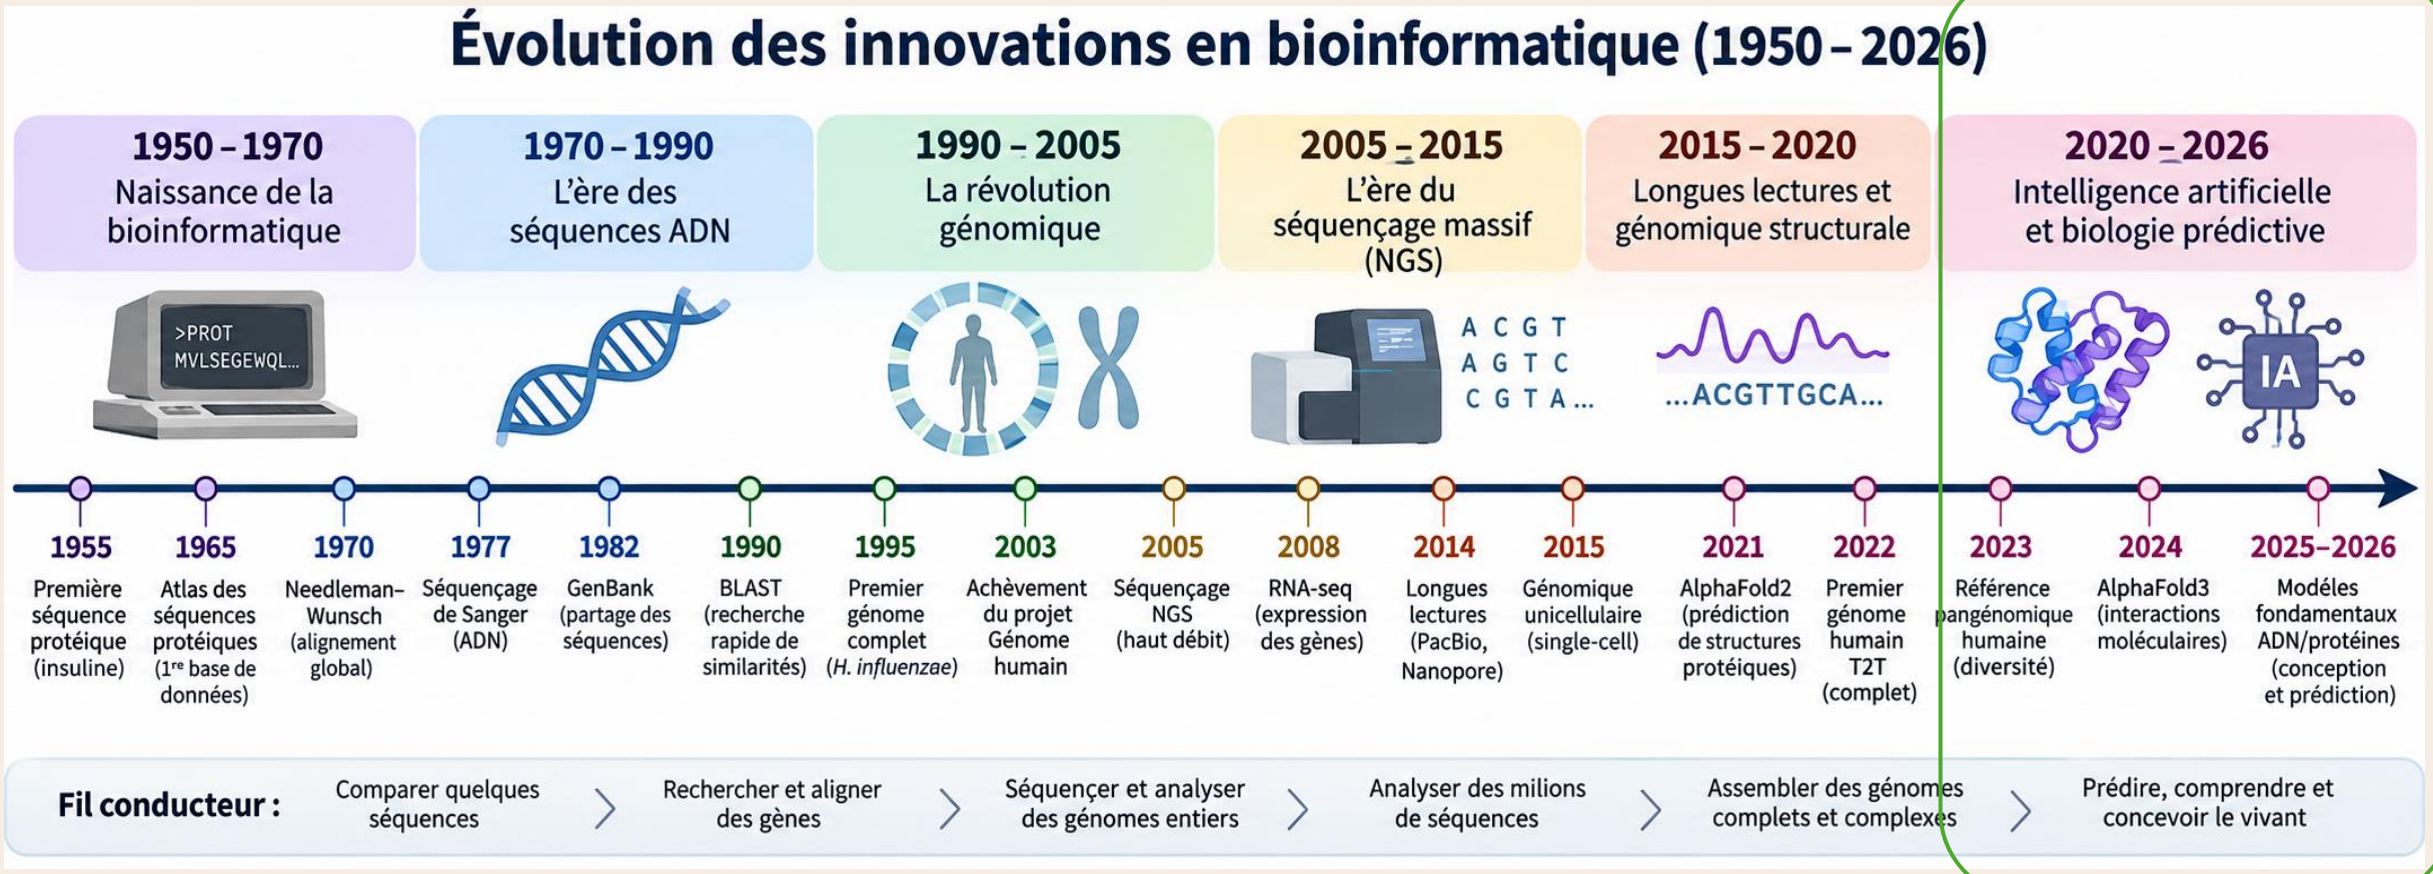


La traque des épidémies du passé: Origine de la peste noire *(Yersinia pestis) 1347-1352. 45 millions de morts*

Limites de la Bioinformatique

Qualité	Biais	Causalité	Validation
Les données peuvent contenir des erreurs: **Savoir les détecter**	Les résultats dépendent de l'echantillonage et des méthodes (qui doivent être reproductible)	Une association ne prouve pas une cause	

Quel avenir pour la bioinformatique ?



Quel avenir pour la bioinformatique ?

une bioinformatique descriptive à une bioinformatique plus prédictive

IA

L'IA permet de traiter de grand volume de données, de prédire et d'identifier des relations complexes. Par exemple prédire les annotations, les fonctions, interactions, voies métaboliques. Apparition de modèle comme Alphagenome qui prédit l'effet de mutation non codante. **De l'analyse vers la prédiction**

https://www.nature.com/articles/s41592-025-02918-6?utm_source=chatgpt.com

Multi-Omique

Quand l'étude de l'ADN ne suffit pas à comprendre le fonctionnement d'un organisme: Intégrer la génomique, la transcriptomique la protéomique et la métabolomique. Par exemple comprendre la réponse d'une plante à la sécheresse. **Vers le multi-omique cellulaire et spatial**

Médecine personnelle

Ou **médecine de précision**. 2 patients atteint de la même maladie peuvent ne pas répondre de la même manière à un traitement. Exemple: traitement contre le cancer, prévoir la réponse à un médicament, diagnostique de maladie génétique, …

Biodiversité et environnement

Surveillance génétique en temps réel des écosystèmes, intégration des données environnementale, télédétection (satellites), prédiction des adaptations aux changements, simulation des écosystèmes (jumeaux numériques).

A Retenir

La bioinformatique associe biologie, informatique et statistique

Elle répond à des questionnements sur les génomes, les fonctions et l'évolution

Ces résultats doivent etre interpréter et si possible validés biologiquement

Et vous quelle question aimeriez-vous répondre avec la bioinformatique ?